# systemd для администраторов

# Lennart Poettering (автор)\* Сергей Пташник (русский перевод)<sup>†</sup>

Данный документ доступен на условиях лицензии СС-ВҮ-SA 3.0 Unported

### 15 июля 2017 г.

# Содержание

Ш	редисловие автора	3
1	Контроль процесса загрузки	3
2	О службах и процессах	7
3	Преобразование SysV init-скрипта в systemd service-файл	19
4	Убить демона	23
5	Три уровня выключения	<b>2</b> 4
6	Смена корня	26
7	Поиск виновных	30
8	Новые конфигурационные файлы	34
9	O судьбе /etc/sysconfig и /etc/default	37
10	Экземпляры служб	41
11	Службы с активацией в стиле inetd	45
12	К вопросу о безопасности         12.1 Изолирование служб от сети          12.2 Предоставление службам независимых каталогов /tmp          12.3 Ограничение доступа служб к отдельным каталогам          12.4 Принудительное отключение полномочий (capabilities) для служб          12.5 Запрет форка, ограничение на создание файлов          12.6 Контроль доступа служб к файлам устройств          12.7 Прочие настройки	49 50 51 51 52 53 53
13	Отчет о состоянии службы и ее журнал	54
14	Самодокументированный процесс загрузки	55
<b>15</b>	Сторожевые таймеры	57

<sup>\*</sup>Первоисточник (на английском языке) опубликован на сайте автора: http://Opointer.de/blog/projects

<sup>†</sup>Актуальная версия перевода доступна на личной странице переводчика: http://www2.kangran.su/ nnz/pub/s4a/

<b>16</b>	Запуск getty на последовательных (и не только) консолях	60
	16.1 Виртуальные консоли	60
	16.2 Последовательные консоли	61
<b>17</b>	Работа с Journal	62
	17.1 Сохранение логов на диск	63
	17.2 Основы	63
	17.3 Контроль доступа	64
	17.4 Отслеживание логов в реальном времени	64
	17.5 Простейшие методы выборки записей	64
	17.6 Продвинутые методы выборки	65
	17.7 И немного магии	66
18	Управление ресурсами с помощью cgroups	67
	18.1 Процессор	68
	18.2 Отслеживание использования ресурсов	69
	18.3 Память	70
	18.4 Ввод-вывод	70
	18.5 Прочие параметры	7
19	Проверка на виртуальность	72
	19.1 Условия на запуск юнитов	73
	19.2 В скриптах	73
	19.3 В программах	73
20	Сокет-активация служб и контейнеров	74
	20.1 Сокет-активация сетевых служб	74
	20.2 Сокет-активация контейнеров	75
<b>21</b>	Интеграция с контейнерами	78
A	$\mathbf{FAQ}$ (часто задаваемые вопросы) $^1$	85
В	Диагностика неполадок $^2$	89
	В.1 Диагностика проблем с загрузкой	89
	В.1.1 Если у вас нет доступа к оболочке	89
	В.1.2 Если у вас есть доступ к оболочке	91
	В.2 Диагностика проблем с выключением системы	92
	В.2.1 Система очень долго выключается	92
	В.2.2 Система не может выключиться самостоятельно	92
	В.3 Просмотр состояния службы и ее журнала	92
	В.4 Подготовка сообщений об ошибках	93
	В.4.1 Что нужно включить в сообщение об ошибке	93
$\mathbf{C}$	Совместимость с $SysV^3$	94
D	Предсказуемые имена сетевых интерфейсов <sup>4</sup>	96
	D.1 3ayem?	96
	D.2 Что именно было изменено в версии 197?	97
	D.3 Еще раз, что здесь хорошего?	98
	D.4 Мне не нравится ваша схема. Как ее отключить?	98
	F 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1	

<sup>&</sup>lt;sup>1</sup>Прим. перев.: Перевод статьи «Frequently Asked Questions» с официального сайта проекта, по состоянию на 2013-05-26 08:17:02 (коммит 8cf2b).

<sup>2</sup>Прим. перев.: Перевод статьи «Debugging systemd Problems» с официального сайта проекта, по состоянию на 2017-01-29 06:18:38 (коммит 903f7).

<sup>3</sup>Прим. перев.: Перевод статьи «Compatibility with SysV» с официального сайта проекта, по состояние серойности проекта проекта, по состояние серойности проекта, по состояние серойности проекта проекта, по состояние серойности проекта проек

нию на 2016-06-21 15:06:36 (коммит 3b3b2).

 $<sup>^4</sup>$ Прим. перев.: Перевод статьи «Predictable Network Interface Names» с официального сайта проекта, по состоянию на 2016-11-17 17:52:54 (коммит fe089).

	D.5 Как именно работает новая схема?	99				
${f E}$ Специальные файловые системы $^5$						
$\mathbf{F}$	Запуск служб после появления сети <sup>6</sup>					
	F.1 Как это реализовано в systemd	104				
	F.2 Короче, как заставить network.target работать?	105				
	F.3 А что делать нам, разработчикам?	106				
$\mathbf{G}$	Моя служба не может получить приоритет realtime <sup>7</sup>	106				

## Предисловие автора

Многие из вас, наверное, уже знают, что systemd — это новая система инициализации дистрибутива Fedora, начиная с Fedora  $14^8$ . Помимо Fedora, systemd также поддерживает и другие дистрибутивы, в частности, OpenSUSE<sup>9</sup>. systemd предоставляет администраторам целый ряд новых возможностей, значительно упрощающих процесс обслуживания системы. Эта статья является первой в серии публикаций, планируемых в ближайшие месяцы. В каждой из этих статей я попытаюсь рассказать об очередной новой возможности systemd. Большинство этих возможностей можно описать легко и просто, и подобные статьи должны быть интересны довольно широкой аудитории. Однако, время от времени мы будем рассматривать ключевые новшества systemd, что может потребовать несколько более подробного изложения.

Lennart Poettering, 23 августа 2010 г.

## 1 Контроль процесса загрузки

Как правило, во время загрузки Linux по экрану быстро пробегает огромное количество различных сообщений. Так как мы интенсивно работаем над параллелизацией и ускорением процесса загрузки, с каждой новой версией systemd эти сообщения будут пробегать все быстрее и быстрее, вследствие чего, читать их будет все труднее. К тому же, многие пользователи применяют графические оболочки загрузки (например, Plymouth), полностью скрывающие эти сообщения. Тем не менее, информация, которую они несут, была и остается чрезвычайно важной — они показывают, успешно ли запустилась каждая служба, или попытка ее запуска закончилась ошибкой (зеленое [ ОК ] или красное [ FAILED ] соответственно). Итак, с ростом скорости загрузки систем, возникает неприятная ситуация: информация о результатах запуска служб бывает очень важна, а просматривать ее все тяжелее. systemd предлагает выход из этой ситуации: он отслеживает и запоминает факты успешного или неудачного запуска служб на этапе загрузки, а также сбои служб во время работы. К таким случаям относятся выходы с ненулевым кодом, ошибки сегментирования и т.п. Введя systemctl status в своей командной оболочке, вы можете ознакомиться с состоянием всех служб, как «родных» (native) для systemd, так и классических SysV/LSB служб, поддерживаемых в целях совместимости:

 $<sup>^5</sup>$  Прим. перев.: Перевод статьи «API File Systems» с официального сайта проекта, по состоянию на 2015-02-20 15:48:02 (коммит e2db9).

 $<sup>^6</sup>$ Прим. перев.: Перевод статьи «Running Services After the Network is up» с официального сайта проекта, по состоянию на 2016-08-21 13:14:53 (коммит 4d5d5).

 $<sup>^7</sup>$ Прим. перев.: Перевод статьи «My Service Can't Get Realtime!» с официального сайта проекта, по состоянию на 2013-05-18 08:20:36 (коммит 2f77b).

<sup>&</sup>lt;sup>8</sup>Прим. перев.: к сожалению, разработчики Fedora приняли решение оставить в Fedora 14 в качестве системы инициализации по умолчанию upstart, однако systemd все равно включен в этот релиз и может быть использован в качестве альтернативной системы инициализации. Окончательный переход на systemd произошел лишь в Fedora 15.

 $<sup>^9</sup>$ Прим. перев.: Сейчас systemd поддерживается практически во всех популярных дистрибутивах для настольных систем.

[root@lambda] ~# systemctl	TOAD	ACTIVE	SUB	JOB	DECOLOTION
UNIT	LOAD			JUB	DESCRIPTION
dev-hugepages.automount		active	running		Huge Pages File System Automount Point
dev-mqueue.automount		active	running		POSIX Message Queue File System Automount Point
proc-sys-fs-binfmt_misc.automount		active	waiting		Arbitrary Executable File Formats File System Automount Poin
sys-kernel-debug.automount		active	waiting		Debug File System Automount Point
sys-kernel-security.automount		active	waiting		Security File System Automount Point
sys-devices-pc0000:02:00.0-net-eth0.device []	loaded	active	plugged		82573L Gigabit Ethernet Controller
sys-devices-virtual-tty-tty9.device	loaded	active	plugged		/sys/devices/virtual/tty/tty9
mount	loaded	active	mounted		
boot.mount	loaded	active	mounted		/boot
dev-hugepages.mount	loaded	active	mounted		Huge Pages File System
dev-mqueue.mount	loaded	active	mounted		POSIX Message Queue File System
home.mount	loaded	active	mounted		/home
proc-sys-fs-binfmt_misc.mount	loaded	active	mounted		Arbitrary Executable File Formats File System
abrtd.service	loaded	active	running		ABRT Automated Bug Reporting Tool
accounts-daemon.service	loaded	active	running		Accounts Service
acpid.service	loaded	active	running		ACPI Event Daemon
atd.service	loaded	active	running		Execution Queue Daemon
auditd.service	loaded	active	running		Security Auditing Service
avahi-daemon.service	loaded	active	running		Avahi mDNS/DNS-SD Stack
bluetooth.service	loaded	active	running		Bluetooth Manager
console-kit-daemon.service	loaded	active	running		Console Manager
cpuspeed.service	loaded	active	exited		LSB: processor frequency scaling support
crond.service	loaded	active	running		Command Scheduler
cups.service	loaded	active	running		CUPS Printing Service
dbus.service	loaded	active	running		D-Bus System Message Bus
getty@tty2.service	loaded	active	running		Getty on tty2
getty@tty3.service	loaded	active	running		Getty on tty3
getty@tty4.service	loaded	active	running		Getty on tty4
getty@tty5.service	loaded	active	running		Getty on tty5
getty@tty6.service	loaded	active	running		Getty on tty6
haldaemon.service	loaded	active	running		Hardware Manager
hdapsd@sda.service	loaded	active	running		sda shock protection daemon
irqbalance.service	loaded	active	running		LSB: start and stop irqbalance daemon

iscsi.service	loaded active	exited	LSB: Starts and stops login and scanning of iSCSI devices.
iscsid.service	loaded active	exited	LSB: Starts and stops login iSCSI daemon.
livesys-late.service	loaded active	exited	LSB: Late init script for live image.
livesys.service	loaded active	exited	LSB: Init script for live image.
lvm2-monitor.service	loaded active	exited	LSB: Monitoring of LVM2 mirrors, snapshots etc. using dmeventd or progr
mdmonitor.service	loaded active	running	LSB: Start and stop the MD software RAID monitor
modem-manager.service	loaded active	running	Modem Manager
netfs.service	loaded active	exited	LSB: Mount and unmount network filesystems.
NetworkManager.service	loaded active	running	Network Manager
ntpd.service	loaded maintenance	maintenance	Network Time Service
polkitd.service	loaded active	running	Policy Manager
prefdm.service	loaded active	running	Display Manager
rc-local.service	loaded active	exited	/etc/rc.local Compatibility
rpcbind.service	loaded active	running	RPC Portmapper Service
rsyslog.service	loaded active	running	System Logging Service
rtkit-daemon.service	loaded active	running	RealtimeKit Scheduling Policy Service
sendmail.service	loaded active	running	LSB: start and stop sendmail
sshd@172.31.0.53:22-172.31.0.4:36368.service	loaded active	running	SSH Per-Connection Server
sysinit.service	loaded active	running	System Initialization
systemd-logger.service	loaded active	running	systemd Logging Daemon
udev-post.service	loaded active	exited	LSB: Moves the generated persistent udev rules to /etc/udev/rules.d
udisks.service	loaded active	running	Disk Manager
upowerd.service	loaded active	running	Power Manager
wpa_supplicant.service	loaded active	running	Wi-Fi Security Service
avahi-daemon.socket	loaded active	listening	Avahi mDNS/DNS-SD Stack Activation Socket
cups.socket	loaded active	listening	CUPS Printing Service Sockets
dbus.socket	loaded active	running	dbus.socket
rpcbind.socket	loaded active	listening	RPC Portmapper Socket
sshd.socket	loaded active	listening	sshd.socket
systemd-initctl.socket	loaded active	listening	systemd /dev/initctl Compatibility Socket
systemd-logger.socket	loaded active	running	systemd Logging Socket
systemd-shutdownd.socket	loaded active	listening	systemd Delayed Shutdown Socket
dev-disk-by\x1x1db22a\x1d870f1adf2732.swap	loaded active	active	/dev/disk/by-uuid/fd626ef7-34a4-4958-b22a-870f1adf2732
basic.target	loaded active	active	Basic System
bluetooth.target	loaded active	active	Bluetooth
dbus.target	loaded active	active	D-Bus

getty.target	loaded active	active	Login Prompts					
graphical.target	loaded active	active	Graphical Interface					
local-fs.target	loaded active	active	Local File Systems					
multi-user.target	loaded active	active	Multi-User					
network.target	loaded active	active	Network					
remote-fs.target	loaded active	active	Remote File Systems					
sockets.target	loaded active	active	Sockets					
swap.target	loaded active	active	Swap					
sysinit.target	loaded active	active	System Initialization					
LOAD = Reflects whether the unit definition was properly loaded.								
ACTIVE = The high-level unit activation state, i.e. generalization of SUB.								
SUB = The low-level unit activation state, values depend on unit type.								

= Pending job for the unit.

221 units listed. Pass --all to see inactive units, too. [root@lambda] ~#

(Листинг был сокращен за счет удаления строк, не относящихся к теме статьи.)

Обратите внимание на графу ACTIVE, в которой отображается обобщенный статус службы (или любого другого юнита systemd: устройства, сокета, точки монтирования — их мы рассмотрим подробнее в последующих статьях). Основными значениями обобщенного статуса являются астіче (служба выполняется) и inactive (служба не была запущена). Также существуют и другие статусы. Например, внимательно посмотрев на листинг выше, вы можете заметить, что служба ntpd (сервер точного времени) находится в состоянии, обозначенном как maintenance. Чтобы узнать, что же произошло с ntpd, воспользуемся командой systemct1 status<sup>10</sup>:

systemd сообщает нам, что ntpd был запущен (с идентификатором процесса 953) и аварийно завершил работу (с кодом выхода 255)<sup>11</sup>.

В последующих версиях systemd, мы планируем добавить возможность вызова в таких ситуациях ABRT (Automated Bug Report Tool), но для этого необходима поддержка со стороны самого ABRT. Соответствующий запрос уже направлен его разработчикам, однако пока не встретил среди них поддержки.

Резюме: использование systemctl и systemctl status является современной, более удобной и эффективной альтернативой разглядыванию быстро пробегающих по экрану сообщений в классическом SysV. systemctl status дает возможность получить развернутую информацию о характере ошибки и, кроме того, в отличие от сообщений SysV, показывает не только ошибки при запуске, но и ошибки, возникшие во время исполнения службы.

# 2 О службах и процессах

В большинстве современных Linux-систем количество одновременно работающих процессов обычно весьма значительно. Понять, откуда взялся и что делает тот или иной процесс, становится все сложнее и сложнее. Многие службы используют сразу несколько рабочих процессов, и это отнюдь не всегда можно легко распознать по выводу команды рв. Встречаются еще более сложные ситуации, когда демон запускает сторонние процессы — например, веб-сервер выполняет СGI-программы, а демон стоп — команды, предписанные ему в crontab.

Немного помочь в решении этой проблемы может древовидная иерархия процессов, отображаемая по команде ps xaf. Именно «немного помочь», а не решить полностью. В частности, процессы, родители которых умирают раньше их самих, становят потомками PID 1 (процесса init), что сразу затрудняет процесс выяснения их происхождения. Кроме того, процесс может избавиться от связи с родителем через две последовательные операции fork() (в целом, эта возможность признается нужной и полезной, и является частью используемого в Unix подхода к разработке демонов). Также, не будем забывать, что процесс легко может изменить свое имя посредством PR\_SETNAME, или задав значение argv[0], что также усложняет процесс его опознания<sup>12</sup>.

 $<sup>^{10}</sup>$ Прим. перев.: Стоит заметить, что формат вывода данной команды менялся по мере развития systemd — появлялись дополнительные поля с информацией, был добавлен вывод журнала службы (см. главу 13) и т.д. Здесь приведен пример вывода этой команды на момент написания исходной статьи (лето 2010 года).

 <sup>11</sup> Прим. перев.: Впоследствии, про просьбам пользователей, считавших, что слово «maintenance» недостаточно точно отражает ситуацию, оно было заменено на «failed».
 12 Прим. перев.: Стоит отметить, что перечисленные ситуации могут возникнуть не только вследствие

<sup>&</sup>lt;sup>12</sup>Прим. перев.: Стоит отметить, что перечисленные ситуации могут возникнуть не только вследствие ошибок в коде и/или конфигурации программ, но и в результате злого умысла. Например, очень часто встречается ситуация, когда установленный на взломанном сервере процесс-бэкдор маскируется под нормального демона, меняя себе имя, скажем, на httpd.

systemd предлагает простой путь для решения обсуждаемой задачи. Запуская новый процесс, systemd помещает его в отдельную контрольную группу с соответствующим именем. Контрольные группы Linux предоставляют очень удобный инструмент для иерархической структуризации процессов: когда какой-либо процесс порождает потомка, этот потомок автоматически включается в ту же группу, что и родитель. При этом, что очень важно, непривилегированные процессы не могут изменить свое положение в этой иерархии. Таким образом, контрольные группы позволяют точно установить происхождение конкретного процесса, вне зависимости от того, сколько раз он форкался и переименовывал себя — имя его контрольной группы невозможно спрятать или изменить. Кроме того, при штатном завершении родительской службы, будут завершены и все порожденные ею процессы, как бы они ни пытались сбежать. С systemd уже невозможна ситуация, когда после остановки web-сервера, некорректно форкнувшийся ССІ-процесс продолжает исполняться вплоть до последних секунд работы системы.

В этой статье мы рассмотрим две простых команды, которые позволят вам наглядно оценить схему взаимоотношений systemd и порожденных им процессов. Первая из этих команд— все та же **ps**, однако на этот раз в ее параметры добавлено указание выводить сведения по контрольным группам, а также другую интересную информацию:

```
9
```

```
$ ps xawf -eo pid,user,cgroup,args
 PID USER
               CGROUP
                                                   COMMAND
   2 root
                                                   [kthreadd]
    3 root
                                                    \_ [ksoftirqd/0]
Γ...1
4281 root
                                                    \_ [flush-8:0]
              name=systemd:/systemd-1
                                                   /sbin/init
   1 root
  455 root
               name=systemd:/systemd-1/sysinit.service/sbin/udevd-d
28188 root
               name=systemd:/systemd-1/sysinit.service \_ /sbin/udevd -d
28191 root
               name=systemd:/systemd-1/sysinit.service \_ /sbin/udevd -d
1096 dbus
               name=systemd:/systemd-1/dbus.service/bin/dbus-daemon --system --address=systemd: --nofork --systemd-activation
               name=systemd:/systemd-1/auditd.service auditd
1131 root
               name=systemd:/systemd-1/auditd.service \_ /sbin/audispd
1133 root
                                                           \_ /usr/sbin/sedispatch
1135 root
               name=systemd:/systemd-1/auditd.service
1171 root
               name=systemd:/systemd-1/NetworkManager.service /usr/sbin/NetworkManager --no-daemon
4028 root
               name=systemd:/systemd-1/NetworkManager.service \_ /sbin/dhclient -d -4 -sf /usr/libexec/nm-dhcp-client.action -pf /var/run/dhclient-wlan0.pid
1175 avahi
               name=systemd:/systemd-1/avahi-daemon.service avahi-daemon: running [epsilon.local]
1194 avahi
               name=systemd:/systemd-1/avahi-daemon.service \_ avahi-daemon: chroot helper
1193 root
               name=systemd:/systemd-1/rsyslog.service /sbin/rsyslogd -c 4
1195 root
               name=systemd:/systemd-1/cups.service cupsd -C /etc/cups/cupsd.conf
1207 root
               name=systemd:/systemd-1/mdmonitor.service mdadm --monitor --scan -f --pid-file=/var/run/mdadm/mdadm.pid
1210 root
               name=systemd:/systemd-1/irqbalance.service irqbalance
1216 root
               name=systemd:/systemd-1/dbus.service/usr/sbin/modem-manager
1219 root
               name=systemd:/systemd-1/dbus.service /usr/libexec/polkit-1/polkitd
1242 root
               name=systemd:/systemd-1/dbus.service /usr/sbin/wpa_supplicant -c /etc/wpa_supplicant/wpa_supplicant.conf -B -u -f /var/log/wpa_supplicant.log -
1249 68
               name=systemd:/systemd-1/haldaemon.service hald
1250 root
               name=systemd:/systemd-1/haldaemon.service \_ hald-runner
1273 root
               name=systemd:/systemd-1/haldaemon.service
                                                              \_ hald-addon-input: Listening on /dev/input/event3 /dev/input/event9 /dev/input/event1 /dev/inp
1275 root
               name=systemd:/systemd-1/haldaemon.service
                                                              \_ /usr/libexec/hald-addon-rfkill-killswitch
1284 root
               name=systemd:/systemd-1/haldaemon.service
                                                              \_ /usr/libexec/hald-addon-leds
1285 root
               name=systemd:/systemd-1/haldaemon.service
                                                              \_ /usr/libexec/hald-addon-generic-backlight
1287 68
               name=systemd:/systemd-1/haldaemon.service
                                                              \_ /usr/libexec/hald-addon-acpi
1317 root
               name=systemd:/systemd-1/abrtd.service /usr/sbin/abrtd -d -s
1332 root
               name=systemd:/systemd-1/getty@.service/tty2 /sbin/mingetty tty2
1339 root
               name=systemd:/systemd-1/getty@.service/tty3 /sbin/mingetty tty3
1342 root
              name=systemd:/systemd-1/getty@.service/tty5 /sbin/mingetty tty5
```

```
1343 root
              name=systemd:/systemd-1/getty@.service/tty4 /sbin/mingetty tty4
1344 root
              name=systemd:/systemd-1/crond.service crond
1346 root
              name=systemd:/systemd-1/getty@.service/tty6 /sbin/mingetty tty6
1362 root
              name=systemd:/systemd-1/sshd.service /usr/sbin/sshd
1376 root
              name=systemd:/systemd-1/prefdm.service /usr/sbin/gdm-binary -nodaemon
1391 root
              name=systemd:/systemd-1/prefdm.service \_ /usr/libexec/gdm-simple-slave --display-id /org/gnome/DisplayManager/Display1 --force-active-vt
                                                          \_ /usr/bin/Xorg :0 -nr -verbose -auth /var/run/gdm/auth-for-gdm-f2KUOh/database -nolisten tcp vt1
1394 root
              name=systemd:/systemd-1/prefdm.service
              name=systemd:/user/lennart/1
1495 root
                                                       \_ pam: gdm-password
             name=systemd:/user/lennart/1
                                                           \_ gnome-session
1521 lennart
1621 lennart
             name=systemd:/user/lennart/1
                                                               \_ metacity
1635 lennart
             name=systemd:/user/lennart/1
                                                               \_ gnome-panel
1638 lennart
             name=systemd:/user/lennart/1
                                                               \_ nautilus
             name=systemd:/user/lennart/1
                                                               \_ /usr/libexec/polkit-gnome-authentication-agent-1
1640 lennart
                                                               \_ /usr/bin/seapplet
1641 lennart
             name=systemd:/user/lennart/1
1644 lennart
             name=systemd:/user/lennart/1
                                                               \_ gnome-volume-control-applet
1646 lennart
             name=systemd:/user/lennart/1
                                                               \_ /usr/sbin/restorecond -u
1652 lennart
             name=systemd:/user/lennart/1
                                                               \_ /usr/bin/devilspie
1662 lennart
             name=systemd:/user/lennart/1
                                                               \_ nm-applet --sm-disable
1664 lennart
             name=systemd:/user/lennart/1
                                                               \_ gnome-power-manager
             name=systemd:/user/lennart/1
                                                               \_ /usr/libexec/gdu-notification-daemon
1665 lennart
             name=systemd:/user/lennart/1
                                                               \_ /usr/libexec/evolution/2.32/evolution-alarm-notify
1670 lennart
             name=systemd:/user/lennart/1
                                                               \_ /usr/bin/python /usr/share/system-config-printer/applet.py
1672 lennart
1674 lennart
             name=systemd:/user/lennart/1
                                                               \_ /usr/lib64/deja-dup/deja-dup-monitor
             name=systemd:/user/lennart/1
                                                               \_ abrt-applet
1675 lennart
1677 lennart
             name=systemd:/user/lennart/1
                                                               \_ bluetooth-applet
1678 lennart
             name=systemd:/user/lennart/1
                                                               \_ gpk-update-icon
1408 root
              name=systemd:/systemd-1/console-kit-daemon.service /usr/sbin/console-kit-daemon --no-daemon
1419 gdm
              name=systemd:/systemd-1/prefdm.service /usr/bin/dbus-launch --exit-with-session
1453 root
              name=systemd:/systemd-1/dbus.service /usr/libexec/upowerd
1473 rtkit
              name=systemd:/systemd-1/rtkit-daemon.service /usr/libexec/rtkit-daemon
1496 root
              name=systemd:/systemd-1/accounts-daemon.service/usr/libexec/accounts-daemon
1499 root.
              name=systemd:/systemd-logger.service/lib/systemd/systemd-logger
1511 lennart
             name=systemd:/systemd-1/prefdm.service /usr/bin/gnome-keyring-daemon --daemonize --login
             name=systemd:/user/lennart/1
1534 lennart
                                                  dbus-launch --sh-syntax --exit-with-session
             name=systemd:/user/lennart/1
                                                  /bin/dbus-daemon --fork --print-pid 5 --print-address 7 --session
1535 lennart
1603 lennart name=systemd:/user/lennart/1
                                                  /usr/libexec/gconfd-2
```

```
1612 lennart name=systemd:/user/lennart/1
                                                   /usr/libexec/gnome-settings-daemon
1615 lennart
              name=systemd:/user/lennart/1
                                                   /usr/libexec/gvfsd
1626 lennart
              name=systemd:/user/lennart/1
                                                   /usr/libexec//gvfs-fuse-daemon /home/lennart/.gvfs
1634 lennart
              name=systemd:/user/lennart/1
                                                   /usr/bin/pulseaudio --start --log-target=syslog
              name=systemd:/user/lennart/1
                                                   \_ /usr/libexec/pulse/gconf-helper
1649 lennart
              name=systemd:/user/lennart/1
                                                   /usr/libexec/bonobo-activation-server --ac-activate --ior-output-fd=24
1645 lennart
              name=systemd:/user/lennart/1
1668 lennart
                                                   /usr/libexec/im-settings-daemon
              name=systemd:/user/lennart/1
1701 lennart
                                                   /usr/libexec/gvfs-gdu-volume-monitor
              name=systemd:/user/lennart/1
                                                   /usr/bin/gnote --panel-applet --oaf-activate-iid=OAFIID:GnoteApplet_Factory --oaf-ior-fd=22
1707 lennart
              name=systemd:/user/lennart/1
1725 lennart
                                                   /usr/libexec/clock-applet
1727 lennart
              name=systemd:/user/lennart/1
                                                   /usr/libexec/wnck-applet
1729 lennart
              name=systemd:/user/lennart/1
                                                   /usr/libexec/notification-area-applet
              name=systemd:/systemd-1/dbus.service /usr/libexec/udisks-daemon
1733 root
               name=systemd:/systemd-1/dbus.service
1747 root
                                                    \_ udisks-daemon: polling /dev/sr0
1759 lennart
             name=systemd:/user/lennart/1
                                                   gnome-screensaver
1780 lennart
              name=systemd:/user/lennart/1
                                                   /usr/libexec/gvfsd-trash --spawner :1.9 /org/gtk/gvfs/exec_spaw/0
1864 lennart
              name=systemd:/user/lennart/1
                                                   /usr/libexec/gvfs-afc-volume-monitor
1874 lennart
              name=systemd:/user/lennart/1
                                                   /usr/libexec/gconf-im-settings-daemon
1903 lennart
              name=systemd:/user/lennart/1
                                                   /usr/libexec/gvfsd-burn --spawner :1.9 /org/gtk/gvfs/exec_spaw/1
              name=systemd:/user/lennart/1
1909 lennart
                                                   gnome-terminal
              name=systemd:/user/lennart/1
                                                   \_ gnome-pty-helper
1913 lennart
              name=systemd:/user/lennart/1
1914 lennart
                                                   \ bash
29231 lennart
              name=systemd:/user/lennart/1
                                                       \_ ssh tango
2221 lennart
              name=systemd:/user/lennart/1
                                                   \_ bash
4193 lennart
              name=systemd:/user/lennart/1
                                                    | \_ ssh tango
              name=systemd:/user/lennart/1
                                                   \ bash
2461 lennart
29219 lennart
              name=systemd:/user/lennart/1
                                                       \_ emacs systemd-for-admins-1.txt
15113 lennart
              name=systemd:/user/lennart/1
                                                   name=systemd:/user/lennart/1
27251 lennart
                                                        \_ empathy
                                                       \_ ps xawf -eo pid,user,cgroup,args
29504 lennart
              name=systemd:/user/lennart/1
1968 lennart
              name=systemd:/user/lennart/1
1994 lennart
              name=systemd:/user/lennart/1
                                                   gpg-agent --daemon --write-env-file
18679 lennart
              name=systemd:/user/lennart/1
                                                   /bin/sh /usr/lib64/firefox-3.6/run-mozilla.sh /usr/lib64/firefox-3.6/firefox
              name=systemd:/user/lennart/1
                                                   \_ /usr/lib64/firefox-3.6/firefox
18741 lennart
                                                        \_ /usr/lib64/nspluginwrapper/npviewer.bin --plugin /usr/lib64/mozilla/plugins/libflashplayer.so --com
              name=systemd:/user/lennart/1
28900 lennart
4016 root
              name=systemd:/systemd-1/sysinit.service /usr/sbin/bluetoothd --udev
```

```
4094 smmsp
              name=systemd:/systemd-1/sendmail.service sendmail: Queue runner@01:00:00 for /var/spool/clientmqueue
 4096 root
               name=systemd:/systemd-1/sendmail.service sendmail: accepting connections
               name=systemd:/systemd-1/ntpd.service /usr/sbin/ntpd -n -u ntp:ntp -g
 4112 ntp
27262 lennart
              name=systemd:/user/lennart/1
                                                   /usr/libexec/mission-control-5
27265 lennart name=systemd:/user/lennart/1
                                                   /usr/libexec/telepathy-haze
                                                  /usr/libexec/telepathy-logger
27268 lennart name=systemd:/user/lennart/1
27270 lennart name=systemd:/user/lennart/1
                                                   /usr/libexec/dconf-service
27280 lennart name=systemd:/user/lennart/1
                                                   /usr/libexec/notification-daemon
27284 lennart name=systemd:/user/lennart/1
                                                   /usr/libexec/telepathy-gabble
27285 lennart name=systemd:/user/lennart/1
                                                   /usr/libexec/telepathy-salut
27297 lennart name=systemd:/user/lennart/1
                                                  /usr/libexec/geoclue-yahoo
```

(Данный листинг был сокращен за счет удаления из него строк, описывающих потоки ядра, так как они никак не относятся к обсуждаемой нами теме.)

Обратите внимание на третий столбец, показывающий имя контрольной группы, в которую systemd поместил данный процесс. Например, процесс udev находится в группе name=systemd:/systemd-1/sysinit.service. В эту группу входят процессы, порожденные службой sysinit.service, которая запускается на ранней стадии загрузки.

Вы можете очень сильно упростить себе работу, если назначите для вышеприведенной команды какой-нибудь простой и короткий псевдоним, например

alias psc='ps xawf -eo pid,user,cgroup,args'

— теперь для получения исчерпывающей информации по процессам достаточно будет нажать всего четыре клавиши.

Альтернативный способ получить ту же информацию — воспользоваться утилитой systemd-cgls, входящей в комплект поставки systemd. Она отображает иерархию контрольных групп в виде псевдографической диаграммы-дерева<sup>13</sup>:

<sup>&</sup>lt;sup>13</sup>Прим. перев.: Стоит заметить, что в нижеприведенном листинге используется ASCII-псевдографика. Между тем, уже довольно давно отображение иерархии процессов в systemd-cgls и systemctl status производится в более выразительной ∤юникодной ¹псевдографике. ASCII-вариант выводится только в том случае, если консоль не поддерживает Unicode.

```
$ systemd-cgls
    2 [kthreadd]
[...]
+ 4281 [flush-8:0]
+ user
| \ lennart
  \ 1
     + 1495 pam: gdm-password
     + 1521 gnome-session
     + 1534 dbus-launch --sh-syntax --exit-with-session
     + 1535 /bin/dbus-daemon --fork --print-pid 5 --print-address 7 --session
     + 1603 /usr/libexec/gconfd-2
     + 1612 /usr/libexec/gnome-settings-daemon
     + 1615 /ushr/libexec/gvfsd
     + 1621 metacity
     + 1626 /usr/libexec//gvfs-fuse-daemon /home/lennart/.gvfs
     + 1634 /usr/bin/pulseaudio --start --log-target=syslog
     + 1635 gnome-panel
     + 1638 nautilus
     + 1640 /usr/libexec/polkit-gnome-authentication-agent-1
     + 1641 /usr/bin/seapplet
     + 1644 gnome-volume-control-applet
     + 1645 /usr/libexec/bonobo-activation-server --ac-activate --ior-output-fd=24
     + 1646 /usr/sbin/restorecond -u
     + 1649 /usr/libexec/pulse/gconf-helper
     + 1652 /usr/bin/devilspie
     + 1662 nm-applet --sm-disable
     + 1664 gnome-power-manager
     + 1665 /usr/libexec/gdu-notification-daemon
     + 1668 /usr/libexec/im-settings-daemon
     + 1670 /usr/libexec/evolution/2.32/evolution-alarm-notify
     + 1672 /usr/bin/python /usr/share/system-config-printer/applet.py
     + 1674 /usr/lib64/deja-dup/deja-dup-monitor
     + 1675 abrt-applet
     + 1677 bluetooth-applet
     + 1678 gpk-update-icon
```

```
+ 1701 /usr/libexec/gvfs-gdu-volume-monitor
     + 1707 /usr/bin/gnote --panel-applet --oaf-activate-iid=OAFIID:GnoteApplet_Factory --oaf-ior-fd=22
     + 1725 /usr/libexec/clock-applet
     + 1727 /usr/libexec/wnck-applet
     + 1729 /usr/libexec/notification-area-applet
     + 1759 gnome-screensaver
     + 1780 /usr/libexec/gvfsd-trash --spawner :1.9 /org/gtk/gvfs/exec_spaw/0
     + 1864 /usr/libexec/gvfs-afc-volume-monitor
     + 1874 /usr/libexec/gconf-im-settings-daemon
     + 1882 /usr/libexec/gvfs-gphoto2-volume-monitor
     + 1903 /usr/libexec/gvfsd-burn --spawner :1.9 /org/gtk/gvfs/exec_spaw/1
     + 1909 gnome-terminal
     + 1913 gnome-pty-helper
     + 1914 bash
     + 1968 ssh-agent
     + 1994 gpg-agent --daemon --write-env-file
     + 2221 bash
     + 2461 bash
     + 4193 ssh tango
     + 15113 bash
     + 18679 /bin/sh /usr/lib64/firefox-3.6/run-mozilla.sh /usr/lib64/firefox-3.6/firefox
     + 18741 /usr/lib64/firefox-3.6/firefox
     + 27251 empathy
     + 27262 /usr/libexec/mission-control-5
     + 27265 /usr/libexec/telepathy-haze
     + 27268 /usr/libexec/telepathy-logger
     + 27270 /usr/libexec/dconf-service
     + 27280 /usr/libexec/notification-daemon
     + 27284 /usr/libexec/telepathy-gabble
     + 27285 /usr/libexec/telepathy-salut
     + 27297 /usr/libexec/geoclue-yahoo
     + 28900 /usr/lib64/nspluginwrapper/npviewer.bin --plugin /usr/lib64/mozilla/plugins/libflashplayer.so --connection /org/wrapper/NSPlugins/libflashplayer
     + 29219 emacs systemd-for-admins-1.txt
     + 29231 ssh tango
     \ 29519 systemd-cgls
\ systemd-1
```

```
+ 1 /sbin/init
+ ntpd.service
| \ 4112 /usr/sbin/ntpd -n -u ntp:ntp -g
+ systemd-logger.service
| \ 1499 /lib/systemd/systemd-logger
+ accounts-daemon.service
| \ 1496 /usr/libexec/accounts-daemon
+ rtkit-daemon.service
| \ 1473 /usr/libexec/rtkit-daemon
+ console-kit-daemon.service
| \ 1408 /usr/sbin/console-kit-daemon --no-daemon
+ prefdm.service
| + 1376 /usr/sbin/gdm-binary -nodaemon
| + 1391 /usr/libexec/gdm-simple-slave --display-id /org/gnome/DisplayManager/Display1 --force-active-vt
| + 1394 /usr/bin/Xorg :0 -nr -verbose -auth /var/run/gdm/auth-for-gdm-f2KUOh/database -nolisten tcp vt1
| + 1419 /usr/bin/dbus-launch --exit-with-session
| \ 1511 /usr/bin/gnome-keyring-daemon --daemonize --login
+ getty@.service
| + tty6
| | \ 1346 /sbin/mingetty tty6
| + ttv4
| | \ 1343 /sbin/mingetty tty4
| + ttv5
| | \ 1342 /sbin/mingetty tty5
| + tty3
| | \ 1339 /sbin/mingetty tty3
| \ tty2
| \ 1332 /sbin/mingetty tty2
+ abrtd.service
| \ 1317 /usr/sbin/abrtd -d -s
+ crond.service
| \ 1344 crond
+ sshd.service
| \ 1362 /usr/sbin/sshd
+ sendmail.service
| + 4094 sendmail: Queue runner@01:00:00 for /var/spool/clientmqueue
```

```
| \ 4096 sendmail: accepting connections
+ haldaemon.service
| + 1249 hald
| + 1250 hald-runner
| + 1273 hald-addon-input: Listening on /dev/input/event3 /dev/input/event9 /dev/input/event1 /dev/input/event7 /dev/input/event2 /dev/input/event0 /dev/input/event0
| + 1275 /usr/libexec/hald-addon-rfkill-killswitch
| + 1284 /usr/libexec/hald-addon-leds
| + 1285 /usr/libexec/hald-addon-generic-backlight
| \ 1287 /usr/libexec/hald-addon-acpi
+ irqbalance.service
| \ 1210 irqbalance
+ avahi-daemon.service
| + 1175 avahi-daemon: running [epsilon.local]
+ NetworkManager.service
| + 1171 /usr/sbin/NetworkManager --no-daemon
| \ 4028 /sbin/dhclient -d -4 -sf /usr/libexec/nm-dhcp-client.action -pf /var/run/dhclient-wlan0.pid -lf /var/lib/dhclient/dhclient-7d32a784-ede9-4cf6-9ee3-
+ rsyslog.service
| \ 1193 /sbin/rsyslogd -c 4
+ mdmonitor.service
| \ 1207 mdadm --monitor --scan -f --pid-file=/var/run/mdadm/mdadm.pid
+ cups.service
| \ 1195 cupsd -C /etc/cups/cupsd.conf
+ auditd.service
| + 1131 auditd
| + 1133 /sbin/audispd
| \ 1135 /usr/sbin/sedispatch
+ dbus.service
| + 1096 /bin/dbus-daemon --system --address=systemd: --nofork --systemd-activation
| + 1216 /usr/sbin/modem-manager
| + 1219 /usr/libexec/polkit-1/polkitd
| + 1242 /usr/sbin/wpa_supplicant -c /etc/wpa_supplicant/wpa_supplicant.conf -B -u -f /var/log/wpa_supplicant.log -P /var/run/wpa_supplicant.pid
| + 1453 /usr/libexec/upowerd
| + 1733 /usr/libexec/udisks-daemon
| + 1747 udisks-daemon: polling /dev/sr0
| \ 29509 /usr/libexec/packagekitd
+ dev-mqueue.mount
```

```
+ dev-hugepages.mount
\ sysinit.service
+ 455 /sbin/udevd -d
+ 4016 /usr/sbin/bluetoothd --udev
+ 28188 /sbin/udevd -d
\ 28191 /sbin/udevd -d
```

(Как и предыдущий, этот листинг был сокращен за счет удаления перечня потоков ядра.)

Как видно из листинга, данная команда наглядно показывает принадлежность процессов к их контрольным группам, а следовательно, и к службам, так как systemd именует группы в соответствии с названиями служб. Например, из приведенного листинга нетрудно понять, что служба системного аудита auditd.service порождает три отдельных процесса: auditd, audispd и sedispatch.

Наиболее внимательные читатели, вероятно, уже заметили, что некоторые процессы помещены в группу /user/lennart/1. Дело в том, что systemd занимается отслеживанием и группировкой не только процессов, относящихся к системным службам, но и процессов, запущенных в рамках пользовательских сеансов. В последующих статьях мы обсудим этот вопрос более подробно.

# 3 Преобразование SysV init-скрипта в systemd serviceфайл

Традиционно, службы Unix и Linux (демоны) запускаются через SysV init-скрипты. Эти скрипты пишутся на языке Bourne Shell (/bin/sh), располагаются в специальном каталоге (обычно /etc/rc.d/init.d/) и вызываются с одним из стандартных параметров (start, stop, reload и т.п.) — таким образом указывается действие, которое необходимо произвести над службой (запустить, остановить, заставить перечитать конфигурацию). При запуске службы такой скрипт, как правило, вызывает бинарник демона, который, в свою очередь, форкается, порождая фоновый процесс (т.е. демонизируется). Заметим, что shell-скрипты, как правило, отличается низкой скоростью работы, излишней подробностью изложения и крайней хрупкостью. Читать их, из-за изобилия всевозможного вспомогательного и дополнительного кода, чрезвычайно тяжело. Впрочем, нельзя не упомянуть, что эти скрипты являются очень гибким инструментом (ведь, по сути, это всего лишь код, который можно модифицировать как угодно). С другой стороны, многие задачи, возникающие при работе со службами, довольно тяжело решить средствами shell-скриптов. К таким задачам относятся: организация параллельного исполнения, корректное отслеживание процессов, конфигурирование различных параметров среды исполнения процесса. systemd обеспечивает совместимость с init-скриптами, однако, с учетом описанных выше их недостатков, более правильным решением будет использование штатных service-файлов systemd для всех установленных в системе служб. Стоит отметить что, в отличие от init-скриптов, которые часто приходится модифицировать при переносе из одного дистрибутива в другой, один и тот же service-файл будет работать в любом дистрибутиве, использующем systemd (а таких дистрибутивов с каждым днем становится все больше и больше). Далее мы вкратце рассмотрим процесс преобразования SysV init-скрипта в service-файл systemd. Вообще говоря, service-файл должен создаваться разработчиками каждого демона, и включаться в комплект его поставки. Если вам удалось успешно создать работоспособный service-файл для какого-либо демона, настоятельно рекомендуем вам отправить этот файл разработчикам. Вопросы по полноценной интеграции демонов с systemd, с максимальным использованием всех его возможностей, будут рассмотрены в последующих статьях этого цикла, пока же ограничимся ссылкой на страницу официальной документации.

Итак, приступим. В качестве примера возьмем init-скрипт демона ABRT (Automatic Bug Reporting Tool, службы, занимающейся сбором crash dump'os). Исходный скрипт (в варианте для дистрибутива Fedora) можно загрузить здесь.

Начнем с того, что прочитаем исходный скрипт (неожиданный ход, правда?) и выделим полезную информацию из груды хлама. Практически у всех init-скриптов бо́льшая часть кода является чисто вспомогательной, и мало чем отличается от одного скрипта к другому. Как правило, при создании новых скриптов этот код просто копируется из уже существующих (разработка в стиле сору-раste). Итак, в исследуемом скрипте нас интересует следующая информация:

• Строка описания службы: «Daemon to detect crashing apps». Как нетрудно заметить, комментарии в заголовке скрипта весьма пространны и описывают не сколь-

ко саму службу, сколько скрипт, ее запускающий. service-файлы systemd тоже содержат описание, но оно относится исключительно к службе, а не к service-файлу.

- LSB-заголовок 14, содержащий информацию о зависимостях. systemd, базирующийся на идеях socket-активации, обычно не требует явного описания зависимостей (либо требует самого минимального описания). Заметим, что основополагающие принципы systemd, включая socket-активацию, рассмотрены в статье Rethinking PID 1, в которой systemd был впервые представлен широкой публике 15. Возвращаясь к нашему примеру: в данном случае ценной информацией о зависимостях является только строка Required-Start: \$syslog, сообщающая, что для работы abrtd требуется демон системного лога. Информация о второй зависимости, \$local\_fs, является избыточной, так как systemd приступает к запуску служб уже после того, как все файловые системы готовы для работы.
- Также, LSB-заголовок сообщает, что данная служба должна быть запущена на уровнях исполнения (runlevels) 3 (консольный многопользовательский) и 5 (графический многопользовательской).
- Исполняемый бинарник демона называется /usr/sbin/abrtd.

Вот и вся полезная информация. Все остальное содержимое 115-строчного скрипта является чисто вспомогательным кодом: операции синхронизации и упорядочивания запуска (код, относящийся к lock-файлам), вывод информационных сообщений (команды echo), разбор входных параметров (монструозный блок case).

На основе приведенной выше информации, мы можем написать следующий service-файл:

```
[Unit]
Description=Daemon to detect crashing apps
After=syslog.target

[Service]
ExecStart=/usr/sbin/abrtd
Type=forking

[Install]
WantedBy=multi-user.target
```

Рассмотрим этот файл поподробнее.

Секция [Unit] содержит самую общую информацию о службе. Не будем забывать, что systemd управляет не только службами, но и многими другими объектами, в частности, устройствами, точками монтирования, таймерами и т.п. Общее наименование всех этих объектов — юнит (unit). Одноименная секция конфигурационного файла определяет наиболее общие свойства, которые могут быть присущи любому юниту. В нашем случае это, во-первых, строка описания, и во-вторых, указание, что данный юнит рекомендуется активировать после запуска демона системного лога 16. Эта информация,

<sup>&</sup>lt;sup>14</sup>LSB-заголовок — определенная в Linux Standard Base схема записи метаданных о службах в блоках комментариев соответствующих init-скриптов. Изначально эта схема была введена именно для того, чтобы стандартизировать init-скрипты во всех дистрибутивах. Однако разработчики многих дистрибутивов не считают нужным точно исполнять требования LSB, и поэтому формы представления метаданных в различных дистрибутивах могут отличаться. Вследствие этого, при переносе init-скрипта из одного дистрибутива в другой, скрипт приходится модифицировать. Например, демон пересылки почты при описании зависимостей может именоваться МТА или smtpdaemon (Fedora), smtp (openSUSE), mail-transport-agent (Debian и Ubuntu), mail-transfer-agent. Таким образом, можно утверждать, что стандарт LSB не справляется с возложенной на него задачей.

 $<sup>^{15}</sup>$ Прим. перев.: Ее русский перевод (сделанный совершенно независимо от данного документа, совсем другим человеком) можно прочитать здесь: часть 1, часть 2.

<sup>&</sup>lt;sup>16</sup>Строго говоря, эту зависимость здесь указывать не нужно — в системах, в которых демон системного лога активируется через сокет, данная зависимость является избыточной. Современные реализации демона системного лога (например, rsyslog начиная с пятой версии) поддерживают активацию через сокет. В системах, использующих такие реализации, явное указание After=syslog.target будет из-

как мы помним, была указана в LSB-заголовке исходного init-скрипта. В нашем конфигурационном файле мы указываем зависимость от демона системного лога при помощи директивы After, указывающей на юнит syslog.taget. Это специальный юнит, позволяющий ссылаться на любую реализацию демона системного лога, независимо от используемой программы (например, rsyslog или syslog-ng) и типа активации (как обычной службы или через log-сокет). Подробнее о таких специальных юнитах можно почитать страницу официальной документации. Обратите внимание, что директива After, в отсутствие директивы Requires, задает лишь порядок загрузки, но не задает жесткой зависимости. То есть, если при загрузке конфигурация systemd будет предписывать запуск как демона системного лога, так и abrtd, то сначала будет запущен демон системного лога, и только потом abrtd. Если же конфигурация не будет содержать явного указания запустить демон системного лога, он не будет запущен даже при запуске abrtd. И это поведение нас полностью устраивает, так как abrtd прекрасно может обходиться и без демона системного лога. В противном случае, мы могли бы воспользоваться директивой Requires, задающей жесткую зависимость между юнитами.

Следующая секция, [Service], содержит информацию о службе. Сюда включаются настройки, относящие именно к службам, но не к другим типам юнитов. В нашем случае, таких настроек две: ExecStart, определяющая расположение бинарника демона и аргументы, с которыми он будет вызван (в нашем случае они отсутствуют), и Туре, позволяющая задать метод, по которому systemd определит окончание периода запуска службы. Традиционный для Unix метод демонизации процесса, когда исходный процесс форкается, порождая демона, после чего завершается, описывается типом forking (как в нашем случае). Таким образом, systemd считает службу запущенной с момента завершения работы исходного процесса, и рассматривает в качестве основного процесса этой службы порожденный им процесс-демон.

И наконец, третья секция, [Install]. Она содержит рекомендации по установке конкретного юнита, указывающие, в каких ситуациях он должен быть активирован. В нашем случае, служба abrtd запускается при активации юнита  $\operatorname{multi-user.target}$ . Это специальный юнит, примерно соответствующий роли третьего уровня исполнения классического  $\operatorname{SysV^{17}}$ . Директива  $\operatorname{WantedBy}$  никак не влияет на уже работающую службу, но она играет важную роль при выполнении команды  $\operatorname{systemctl}$  enable, задавая, в каких условиях должен активироваться устанавливаемый юнит. В нашем примере, служба  $\operatorname{abrtd}$  будет активироваться при переходе в состояние  $\operatorname{multi-user.target}$ , т.е., при каждой нормальной  $\operatorname{18}$   $\operatorname{3arpy3ke^{19}}$ .

Вот и все. Мы получили минимальный рабочий service-файл systemd. Чтобы проверить его работоспособность, скопируем его в /etc/systemd/system/abrtd.service, после чего командой systemctl daemon-reload уведомим systemd об изменении конфигурации. Теперь нам остается только запустить нашу службу: systemctl start abrtd.service. Проверить состояние службы можно командой systemctl status abrtd.service, а чтобы остановить ее, нужно скомандовать systemctl stop abrtd.service. И наконец, команда systemctl enable abrtd.service выполнит установку service-файла, обеспечив его активацию при каждой загрузке (аналог chkconfig abrtd on в классическом SysV).

Приведенный выше service-файл является практический точным переводом исходного init-скрипта, и он никак не использует широкий спектр возможностей, предоставляемых systemd. Ниже приведен немного улучшенный вариант этого же файла:

быточным, так как соответствующая функциональность поддерживается автоматически. Однако, эту строчку все-таки стоит указать для обеспечения совместимости с системами, использующими устаревшие реализации демона системного лога.

 $<sup>^{17}{</sup>m B}$  том контексте, в котором он используется в большинстве дистрибутивов семейства Red Hat, а именно, многопользовательский режим без запуска графической оболочки.

<sup>&</sup>lt;sup>18</sup>Прим. перев.: К «ненормальным» загрузкам можно отнести, например, загрузки в режимах emergency.target или rescue.target (является аналогом первого уровня исполнения в классической SvsV)

 $<sup>^{19}</sup>$ Обратите внимание, что режим графической загрузки в systemd (graphical.target, аналог runlevel 5 в SysV) является надстройкой над режимом многопользовательской консольной загрузки (multi-user.target, аналог runlevel 3 в SysV). Таким образом, все службы, запускаемые в режиме multi-user.target, будут также запускаться и в режиме graphical.target.

```
[Unit]
Description=ABRT Automated Bug Reporting Tool
After=syslog.target

[Service]
Type=dbus
BusName=com.redhat.abrt
ExecStart=/usr/sbin/abrtd -d -s

[Install]
WantedBy=multi-user.target
```

Чем же новый вариант отличается от предыдущего? Ну, прежде всего, мы уточнили описание службы. Однако, ключевым изменением является замена значения Туре с forking на dbus и связанные с ней изменения: добавление имени службы в шине D-Bus (директива BusName) и задание дополнительных аргументов abrtd «-d -s». Но зачем вообще нужна эта замена? Каков ее практический смысл? Чтобы ответить на этот вопрос, мы снова возвращаемся к демонизации. В ходе данной операции процесс дважды форкается и отключается от всех терминалов. Это очень удобно при запуске демона через скрипт, но в случае использования таких продвинутых систем инициализации, как systemd, подобное поведение не дает никаких преимуществ, но вызывает неоправданные задержки. Даже если мы оставим в стороне вопрос скорости загрузки, останется такой важный аспект, как отслеживание состояния служб. systemd решает и эту задачу, контролируя работу службы и при необходимости реагируя на различные события. Например, при неожиданном падении основного процесса службы, systemd должен зарегистрировать идентификатор и код выхода процесса, также, в зависимости от настроек, он может попытаться перезапустить службу, либо активировать какой-либо заранее заданный юнит. Операция демонизации несколько затрудняет решение этих задач, так как обычно довольно сложно найти связь демонизированного процесса с исходным (собственно, смысл демонизации как раз и сводится к уничтожению этой связи) и, соответственно, для systemd сложнее определить, какой из порожденных в рамках данной службы процессов является основным. Чтобы упростить для него решение этой задачи, мы и воспользовались типом запуска dbus. Он подходит для всех служб, которые в конце процесса инициализации регистрируют свое имя на шине D-Bus<sup>20</sup>. ABRTd относится к ним. С новыми настройками, systemd запустит процесс abrtd, который уже не будет форкаться (согласно указанным нами ключам «-d -s»), и в качестве момента окончания периода запуска данной службы systemd будет рассматривать момент регистрации имени com.redhat.abrt на шине D-Bus. В этом случае основным для данной службы будет считаться процесс, непосредственно порожденный systemd. Таким образом, systemd располагает удобным методом для определения момента окончания запуска службы, а также может легко отслеживать ее состояние.

Собственно, это все, что нужно было сделать. Мы получили простой конфигурационный файл, в 10 строчках которого содержится больше полезной информации, чем в 115 строках исходного init-скрипта. Добавляя в наш файл по одной строчке, мы можем использовать различные полезные функции systemd, создание аналога которых в традиционном init-скрипте потребовало бы значительных усилий. Например, добавив строку Restart=restart-always, мы приказываем systemd автоматически перезапускать службу после каждого ее падения. Или, например, добавив OMScoreAdjust=-500, мы попросим ядро сберечь эту службу, даже если OOM Killer выйдет на тропу войны. А если мы добавим строчку CPUSchedulingPolicy=idle, процесс abrtd будет работать только в те моменты, когда система больше ничем не занята, что позволит не создавать помех для процессов, активно использующих CPU.

За более подробным описанием всех опций настройки, вы можете обратиться к страницам руководства systemd.unit, systemd.service, systemd.exec. Полный список доступных страниц можно просмотреть здесь.

 $<sup>^{20}{</sup>m B}$  настоящее время практически все службы дистрибутива Fedora после запуска регистрируется на шине D-Bus.

Конечно, отнюдь не все init-скрипты так же легко преобразовать в service-файлы. Но, к счастью, «проблемных» скриптов не так уж и много.

### 4 Убить демона

Убить системного демона нетрудно, правда? Или... все не так просто?

Если ваш демон функционирует как один процесс, все действительно очень просто. Вы командуете killall rsyslogd, и демон системного лога останавливается. Впрочем, этот метод не вполне корректен, так как он действует не только на самого демона, но и на другие процессы с тем же именем. Иногда подобное поведение может привести к неприятным последствиям. Более правильным будет использование pid-файла: kill \$(cat /var/run/syslogd.pid). Вот, вроде бы, и все, что вам нужно... Или мы упускаем еще что-то?

Действительно, мы забываем одну простую вещь: существуют службы, такие, как Арасhe, сгопd, atd, которые по роду служебной деятельности должны запускать дочерние процессы. Это могут быть совершенно посторонние, указанные пользователем программы (например, задачи cron/at, CGI-скрипты) или полноценные серверные процессы (например, Apache workers). Когда вы убиваете основной процесс, он может остановить все дочерние процессы. А может и не остановить. В самом деле, если служба функционирует в штатном режиме, ее обычно останавливают командой stop. К прямому вызову kill администратор, как правило, прибегает только в аварийной ситуации, когда служба работает неправильно и может не среагировать на стандартную команду остановки. Таким образом, убив, например, основной сервер Арасhe, вы можете получить от него в наследство работающие CGI-скрипты, причем их родителем автоматически станет PID 1 (init), так что установить их происхождение будет не так-то просто.

systemd спешит к нам на помощь. Команда systemctl kill позволит отправить сигнал всем процессам, порожденным в рамках данной службы. Например:

#### # systemctl kill crond.service

Вы можете быть уверены, что всем процессам службы стоп будет отправлен сигнал SIGTERM. Разумеется, можно отправить и любой другой сигнал. Скажем, если ваши дела совсем уж плохи, вы можете воспользоваться и SIGKILL:

#### # systemctl kill -s SIGKILL crond.service

После ввода этой команды, служба cron будет жестоко убита вместе со всеми ее дочерними процессами, вне зависимости от того, сколько раз она форкалась, и как бы она ни пыталась сбежать из-под нашего контроля при помощи двойного форка или форк-бомбардировки<sup>21</sup>.

В некоторых случаях возникает необходимость отправить сигнал именно основному процессу службы. Например, используя SIGHUP, мы можем заставить демона перечитать файлы конфигурации. Разумеется, передавать HUP вспомогательным процессам в этом случае совершенно необязательно. Для решения подобной задачи неплохо подойдет и классический метод с ріd-файлом, однако у systemd и на этот случай есть простое решение, избавляющее вас от необходимости искать нужный файл:

#### # systemctl kill -s HUP --kill-who=main crond.service

<sup>&</sup>lt;sup>21</sup>Прим. перев.: Стоит особо отметить, что использование контрольных групп не только упрощает процесс уничтожения форк-бомб, но и значительно уменьшает ущерб от работающей форк-бомбы. Так как systemd автоматически помещает каждую службу и каждый пользовательский сеанс в свою контрольную группу по ресурсу процессорного времени, запуск форк-бомбы одним пользователем или службой не создаст значительных проблем с отзывчивостью системы у других пользователей и служб. Таким образом, в качестве основной угрозы форк-бомбардировки остаются лишь возможности исчерпания памяти и идентификаторов процессов (PID). Впрочем, и их тоже можно легко устранить: достаточно задать соответствующие лимиты в конфигурационном файле службы (см. systemd.exec(5) и systemd.resource-control(5)).

Итак, что же принципиально новое привносит systemd в рутинный процесс убийства демона? Прежде всего: впервые в истории Linux представлен способ принудительной остановки службы, не зависящий от того, насколько добросовестно основной процесс службы выполняет свои обязательства по остановке дочерних процессов. Как уже упоминалось выше, необходимость отправить процессу SIGTERM или SIGKILL обычно возникает именно в нештатной ситуации, когда вы уже не можете быть уверены, что демон корректно исполнит все свои обязанности.

После прочтения сказанного выше у вас может возникнуть вопрос: в чем разница между systemctl kill и systemctl stop? Отличие состоит в том, что kill просто отправляет сигнал заданному процессу, в то время как stop действует по «официально» определенному методу, вызывая команду, определенную в параметре ExecStop конфигурации службы. Обычно команды stop бывает вполне достаточно для остановки службы, и к kill приходится прибегать только в крайних случаях, например, когда служба «зависла» и не реагирует на команды.

Кстати говоря, при использовании параметра «-s», вы можете указывать названия сигналов как с префиксом SIG, так и без него — оба варианта будут работать.

В завершение стоит сказать, что для нас весьма интересным и неожиданным оказался тот факт, что до появления systemd в Linux просто не существовало инструментов, позволяющих корректно отправить сигнал службе в целом, а не отдельному процессу.

## 5 Три уровня выключения

B systemd существует три уровня (разновидности) действий, направленных на прекращение работы службы (или любого другого юнита):

• Вы можете *остановить* службу, то есть прекратить выполнение уже запущенных процессов службы. При этом сохраняется возможность ее последующего запуска, как ручного (через команду systemctl start), так и автоматического (при загрузке системы, при поступлении запроса через сокет или системную шину, при срабатывании таймера, при подключении соответствующего оборудования и т.д.). Таким образом, остановка службы является временной мерой, не дающей никаких гарантий на будущее.

В качестве примера рассмотрим остановку службы NTPd (отвечающей за синхронизацию времени по сети):

systemctl stop ntpd.service

Аналогом этой команды в классическом SysV init является

service ntpd stop

Заметим, что в Fedora 15, использующей в качестве системы инициализации systemd, в целях обеспечения обратной совместимости допускается использование классических SysV-команд, и systemd будет корректно воспринимать их. В частности, вторая приведенная здесь команда будет эквивалентна первой.

• Вы можете отключить службу, то есть отсоединить ее от всех триггеров активации. В результате служба уже не будет автоматически запускаться ни при загрузке системы, ни при обращении к сокету или адресу на шине, ни при подключении оборудования, и т.д. Но при этом сохраняется возможность «ручного» запуска службы (командой systemctl start). Обратите внимание, что при отключении уже запущенной службы, ее выполнение в текущем сеансе не останавливается — это нужно сделать отдельно, иначе процессы службы будут работать до момента выключения системы (но при следующем включении, разумеется, уже не запустятся).

Рассмотрим отключение службы на примере все того же NTPd:

systemctl disable ntpd.service

В классических SysV-системах аналогичная команда будет иметь вид

### chkconfig ntpd off

Как и в предыдущем случае, в Fedora 15 вторая из этих команд будет действовать аналогично первой.

Довольно часто приходится сочетать действия отключения и остановки службы — такая комбинированная операция гарантирует, что уже исполняющиеся процессы службы будут прекращены, и служба больше не будет запускаться автоматически (но может быть запущена вручную):

```
systemctl disable ntpd.service
systemctl stop ntpd.service
```

Подобное сочетание команд используется, например, при деинсталляции пакетов в Fedora.

Обратите внимание, что отключение службы является перманентной мерой, и действует вплоть до явной отмены соответствующей командой. Перезагрузка системы не отменяет отключения службы.

• Вы можете заблокировать (замаскировать) службу. Действие этой операции аналогично отключению, но дает более сильный эффект. Если при отключении отменяется только возможность автоматического запуска службы, но сохраняется возможность ручного запуска, то при блокировке исключаются обе эти возможности. Отметим, что использование данной опции при непонимании принципов ее работы может привести к трудно диагностируемым ошибкам.

Тем не менее, рассмотрим пример блокировки все той же службы NTPd:

```
ln -s /dev/null /etc/systemd/system/ntpd.service
systemctl daemon-reload
```

Итак, блокировка сводится к созданию символьной ссылки с именем соответствующей службы, указывающей на /dev/null<sup>22</sup>. После такой операции служба не может быть запущена ни вручную, ни автоматически. Символьная ссылка создается в каталоге /etc/systemd/system/, а ее имя должно соответствовать имени файла описания службы из каталога /lib/systemd/system/ (в нашем случае ntpd.service).

Заметим, что systemd читает файлы конфигурации из обоих этих каталогов, но файлы из /etc (управляемые системным администратором) имеют приоритет над файлами из /lib (которые управляются пакетным менеджером). Таким образом, создание символьной ссылки (или обычного файла) /etc/systemd/system/ntpd.service предотвращает чтение штатного файла конфигурации /lib/systemd/system/ntpd.service.

B выводе systemctl status заблокированные службы отмечаются словом masked. Попытка запустить такие службы командой systemctl start завершится ошибкой.

В рамках классического SysV init, штатная реализация такой возможности отсутствует. Похожий эффект может быть достигнут с помощью «костылей», например, путем добавления команды exit 0 в начало init-скрипта. Однако, подобные решения имеют ряд недостатков, например, потенциальная возможность конфликтов с пакетным менеджером (при очередном обновлении исправленный скрипт может быть просто затерт соответствующим файлом из пакета).

<sup>&</sup>lt;sup>22</sup>Прим. перев.: Впоследствии в программу systemctl была добавлена поддержка команд mask и unmask, упрощающих процесс блокирования и разблокирования юнитов. Например, для блокирования службы ntpd.service теперь достаточно команды systemctl mask ntpd.service. Фактически она сделает то же самое, что и приведенная выше команда ln.

Стоит отметить, что блокировка службы, как и ее отключение, является перманентной мерой $^{23}$ .

После прочтения изложенного выше, у читателя может возникнуть вопрос: как отменить произведенные изменения? Что ж, ничего сложного тут нет: systemctl start отменяет действия systemctl stop, systemctl enable отменяет действие systemctl disable, а rm отменяет действие ln.

## 6 Смена корня

Практически все администраторы и разработчики рано или поздно встречаются с chroot-окружениями. Системный вызов chroot() позволяет задать для определенного процесса (и его потомков) каталог, который они будут рассматривать как корневой /, тем самым ограничивая для них область видимости иерархии файловой системы отдельной ветвью. Большинство применений chroot-окружений можно отнести к двум классам задач:

- 1. Обеспечение безопасности. Потенциально уязвимый демон chroot'ится в отдельный каталог и, даже в случае успешной атаки, взломщик увидит лишь содержимое этого каталога, а не всю файловую систему он окажется в ловушке chroot'a.
- 2. Подготовка и управление образом операционной системы при отладке, тестировании, компиляции, установке или восстановлении. При этом вся иерархия файловых систем гостевой ОС монтируется или создается в каталоге системы-хоста, и при запуске оболочки (или любого другого приложения) внутри этой иерархии, в качестве корня используется данный каталог. Система, которую «видят» такие программы, может сильно отличаться от ОС хоста. Например, это может быть другой дистрибутив, или даже другая аппаратная архитектура (запуск і386-гостя на х86\_64-хосте). Гостевая ОС не может увидеть полного дерева каталогов ОС хоста.

В системах, использующих классический SysV init, использовать chroot-окружения сравнительно несложно. Например, чтобы запустить выбранного демона внутри дерева каталогов гостевой ОС, достаточно смонтировать внутри этого дерева /proc, /sys и остальные АРІ ФС, воспользоваться программой chroot(1) для входа в окружение, и выполнить соответствующий init-скрипт, запустив /sbin/service внутри окружения.

Но в системах, использующих systemd, уже не все так просто. Одно из важнейших достоинств systemd состоит в том, что параметры среды, в которой запускаются демоны, никак не зависят от метода их запуска. В системах, использующих SysV init, многие параметры среды выполнения (в частности, лимиты на системные ресурсы, переменные окружения, и т.п.) наследуются от оболочки, из которой был запущен init-скрипт. При использовании systemd ситуация меняется радикально: пользователь просто уведомляет процесс init о необходимости запустить ту или иную службу, и тот запускает демона в чистом, созданном «с нуля» и тщательно настроенном окружении, параметры которого никак не зависят от настроек среды, из которой была отдана команда. Такой подход полностью отменяет традиционный метод запуска демонов в chroot-окружениях: теперь демон порождается процессом init (PID 1) и наследует корневой каталог от него, вне зависимости от того, находился ли пользователь, отдавший команду на запуск, в chroot-окружении, или нет. Кроме того, стоит особо отметить, что взаимодействие управляющих программ с systemd происходит через сокеты, находящиеся в каталоге /run/systemd, так что программы, запущенные в chroot-окружении, просто не смогут

 $<sup>^{23}</sup>$ Прим. перев.: Подробно описав принцип работы блокировки службы (юнита), автор забывает привести практические примеры ситуаций, когда эта возможность оказывается полезной.

В частности, иногда бывает необходимо полностью предотвратить запуск службы в любой ситуации. При этом не стоит забывать, что в post-install скриптах пакетного менеджера или, скажем, в заданиях сгоп, вместо systemctl try-restart (service condrestart) может быть ошибочно указано systemctl restart (service restart), что является прямым указанием на запуск службы, если она еще не запущена. Вследствие таких ошибок, отключенная служба может «ожить» в самый неподходящий момент.

взаимодействовать с init-подсистемой (и это, в общем, неплохо, а если такое ограничение будет создавать проблемы, его можно легко обойти, используя bind-монтирование).

В свете вышесказанного, возникает вопрос: как правильно использовать chrootокружения в системах на основе systemd? Что ж, постараемся дать подробный и всесторонний ответ на этот вопрос.

Для начала, рассмотрим первое из перечисленных выше применений chroot: изоляция в целях безопасности. Прежде всего, стоит заметить, что защита, предоставляемая chroot'ом, весьма эфемерна и ненадежна, так как chroot не является «дорогой с односторонним движением». Выйти из chroot-окружения сравнительно несложно, и соответствующее предупреждение даже присутствует на странице руководства. Действительно эффективной защиты можно достичь, только сочетая chroot с другими методиками. В большинстве случаев, это возможно только при наличии поддержки chroot в самой программе. Прежде всего, корректное конфигурирование chroot-окружения требует глубокого понимания принципов работы программы. Например, нужно точно знать, какие каталоги нужно bind-монтировать из основной системы, чтобы обеспечить все необходимые для работы программы каналы связи. С учетом вышесказанного, эффективная chroot-защита обеспечивается только в том случае, когда она реализована в коде самого демона. Именно разработчик лучше других знает (обязан знать), как правильно сконфигурировать chroot-окружение, и какой минимальный набор файлов, каталогов и файловых систем необходим внутри него для нормальной работы демона. Уже сейчас существуют демоны, имеющие встроенную поддержку chroot. К сожалению, в системе Fedora, установленной с параметрами по умолчанию, таких демонов всего два: Avahi и RealtimeKit. Оба они написаны одним очень хитрым человеком ;-) (Вы можете собственноручно убедиться в этом, выполнив команду ls -1 /proc/\*/root.)

Возвращаясь к теме нашего обсуждения: разумеется, systemd позволяет помещать выбранных демонов в chroot, и управлять ими точно так же, как и остальными. Достаточно лишь указать параметр RootDirectory= в соответствующем service-файле. Например:

[Unit]
Description=A chroot()ed Service

[Service]
RootDirectory=/srv/chroot/foobar
ExecStartPre=/usr/local/bin/setup-foobar-chroot.sh
ExecStart=/usr/bin/foobard
RootDirectoryStartOnly=yes

Рассмотрим этот пример подробнее. Параметр RootDirectory= задает каталог, в который производится chroot перед запуском исполняемого файла, заданного параметром ExecStart=. Заметим, что путь к этому файлу должен быть указан относительно каталога chroot (так что, в нашем случае, с точки зрения основной системы, на исполнение будет запущен файл /srv/chroot/foobar/usr/bin/foobard). Перед запуском демона будет вызван сценарий оболочки setup-foobar-chroot.sh, который должен обеспечить подготовку chroot-окружения к запуску демона (например, смонтировать в нем /proc и/или другие файловые системы, необходимые для работы демона). Указав RootDirectoryStartOnly=yes, мы задаем, что chroot() будет выполняться только перед выполнением файла из ExecStart=, а команды из других директив, в частности, ExecStartPre=, будут иметь полный доступ к иерархии файловых систем ОС (иначе наш скрипт просто не сможет выполнить bind-монтирование нужных каталогов). Более подробную информацию по опциям конфигурации вы можете получить на страницах руководства.

Поместив приведенный выше текст примера в файл /etc/systemd/system/foobar.service, вы сможете запустить chroot'нутого демона командой systemctl start foobar.service. Информацию о его текущем состоянии можно получить с помощью команды systemctl status foobar.service. Команды управления и мониторинга службы не зависят от того, запущена ли она в chroot'e, или нет. Этим systemd отличается от классического SysV init.

Новые ядра Linux поддерживают возможность создания независимых пространств имен файловых систем (в дальнейшем FSNS, от «file system namespaces»). По функциональности этот механизм аналогичен chroot(), однако предоставляет гораздо более широкие возможности, и в нем отсутствуют проблемы с безопасностью, характерные для chroot. systemd позволяет использовать при конфигурировании юнитов некоторые возможности, предоставляемые FSNS. В частности, использование FSNS часто является гораздо более простой и удобной альтернативой созданию полновесных chrootокружений. Используя директивы ReadOnlyDirectories=, InaccessibleDirectories=, вы можете задать ограничения по использованию иерархии файловых систем для заданной службы: ее корнем будет системный корневой каталог, однако указанные в этих директивах подкаталоги будут доступны только для чтения или вообще недоступны для нее. Например:

[Unit]
Description=A Service With No Access to /home
[Service]

ExecStart=/usr/bin/foobard
InaccessibleDirectories=/home

Такая служба будет иметь доступ ко всей иерархии файловых систем ОС, с единственным исключением — она не будет видеть каталог /home, что позволит защитить данные пользователей от потенциальных хакеров. (Подробнее об этих опциях можно почитать на странице руководства.)

Фактически, FSNS по множеству параметров превосходят chroot(). Скорее всего, Avahi и RealtimeKit в ближайшем будущем перейдут от chroot() к использованию FSNS.

Итак, мы рассмотрели вопросы использования chroot для обеспечения безопасности. Переходим ко второму пункту: подготовка и управление образом операционной системы при отладке, тестировании, компиляции, установке или восстановлении.

сhroot-окружения, по сути, весьма примитивны: они изолируют только иерархии файловых систем. Даже после chroot'а в определенный подкаталог, процесс попрежнему имеет полный доступ к системным вызовам, может убивать процессы, запущенные в основной системе, и т.п. Вследствие этого, запуск полноценной ОС (или ее части) внутри chroot'а несет угрозу для хост-системы: у гостя и хоста отличается лишь содержимое файловой системы, все остальное у них общее. Например, если вы обновляете дистрибутив, установленный в chroot-окружении, и пост-установочный скрипт пакета отправляет SIGTERM процессу init для его перезапуска<sup>24</sup>, на него среагирует именно хост-система! Кроме того, хост и chroot'нутая система будут иметь общую разделяемую память SysV (SysV shared memory), общие сокеты из абстрактных пространств имен (abstract namespace sockets) и другие элементы IPC. Для отладки, тестирования, компиляции, установки и восстановлении ОС не требуется абсолютно неуязвимая изоляция — нужна лишь надежная защита от случайного воздействия на ОС хоста изнутри сhroot-окружения, иначе вы можете получить целый букет проблем, как минимум, от пост-инсталляционных скриптов при установке пакетов в chroot-окружении.

systemd имеет целый ряд возможностей, полезных для работы с chroot-системами:

Прежде всего, управляющая программа systemctl автоматически определяет, что она запущена в chroot-системе. В такой ситуации будут работать только команды systemctl enable и systemctl disable, во всех остальных случаях systemctl просто не будет ничего делать, возвращая код успешного завершения операции. Таким образом, пакетные скрипты смогут включить/отключить запуск «своих» служб при загрузке (или в других ситуациях), однако команды наподобие systemctl restart (обычно выполняется при обновлении пакета) не дадут никакого эффекта внутри chroot-окружения<sup>25</sup>.

<sup>&</sup>lt;sup>24</sup>Прим. перев.: Во избежание путаницы отметим, что перезапуск процесса init (PID 1) «на лету» при получении SIGTERM поддерживается только в systemd, в классическом SysV init такой возможности нет. <sup>25</sup>Прим. перев.: Автор забывает отметить не вполне очевидный момент: такое поведение systemctl проявляется только в «мертвых» окружениях, т.е. в тех, где не запущен процесс init, и соответственно

Однако, куда более интересные возможности предоставляет программа systemdnspawn, входящая в стандартный комплект поставки systemd. По сути, это улучшенный аналог chroot(1) — она не только подменяет корневой каталог, но и создает отдельные пространства имен для дерева файловых систем (FSNS) и для идентификаторов процессов (PID NS), предоставляя легковесную реализацию системного контейнера<sup>26</sup>. systemd-nspawn проста в использовании как chroot(1), однако изоляция от хост-системы является более полной и безопасной. Всего одной командой вы можете загрузить внутри контейнера полноценную ОС (на базе systemd или SysV init). Благодаря использованию независимых пространств идентификаторов процессов, процесс init внутри контейнера получит PID 1, что позволит работать ему в штатном режиме. Также, в отличие от chroot(1), внутри окружения будут автоматически смонтированы /proc и /sys.

Следующий пример иллюстрирует возможность запустить Debian на Fedora-хосте всего тремя командами:

- # yum install debootstrap
  # debootstrap --arch=amd64 unstable debian-tree/
- # systemd-nspawn -D debian-tree/

Вторая из этих команд обеспечивает развертывание в подкаталоге ./debian-tree/ файловой структуры дистрибутива Debian, после чего третья команда запускает внутри полученной системы процесс командной оболочки. Если вы хотите запустить внутри контейнера полноценную ОС, воспользуйтесь командой

#### # systemd-nspawn -D debian-tree/ /sbin/init

После быстрой загрузки вы получите приглашение оболочки, запущенной внутри полноценной ОС, функционирующей в контейнере. Изнутри контейнера невозможно увидеть процессы, которые находятся вне его. Контейнер сможет пользоваться сетью хоста<sup>27</sup>, однако не имеет возможности изменить ее настройки (это может привести к серии ошибок в процессе загрузки гостевой ОС, но ни одна из этих ошибок не должна быть критической). Контейнер получает доступ к /sys и /proc/sys, однако, во избежание вмешательства контейнера в конфигурацию ядра и аппаратного обеспечения хоста, эти каталоги будут смонтированы только для чтения. Обратите внимание, что эта защита блокирует лишь случайные, непредвиденные попытки изменения параметров. При необходимости, процесс внутри контейнера, обладающий достаточными полномочиями, сможет перемонтировать эти файловые системы в режиме чтения-записи.

Итак, что же такого хорошего в systemd-nspawn?

- 1. Использовать эту утилиту очень просто. Вам даже не нужно вручную монтировать внутри окружения /proc и /sys она сделает это за вас, а ядро автоматически отмонтирует их, когда последний процесс контейнера завершится.
- 2. Обеспечивается надежная изоляция, предотвращающая случайные изменения параметров ОС хоста изнутри контейнера.
- 3. Теперь вы можете загрузить внутри контейнера полноценную ОС, а не однуединственную оболочку.

отсутствуют управляющие сокеты в /run/systemd. Такая ситуация возникает, например, при установке системы в chroot через debootstrap/febootstrap. В этом случае возможности systemctl ограничиваются операциями с символьными ссылками, определяющими триггеры активации юнитов, т.е. выполнением действий enable и disable, не требующих непосредственного взаимодействия с процессом init.

<sup>&</sup>lt;sup>26</sup>Прим. перев.: Используемые в systemd-nspawn механизмы ядра Linux, такие, как FS NS и PID NS, также лежат в основе LXC, системы контейнерной изоляции для Linux, которая позиционируется как современная альтернатива классическому OpenVZ. Стоит отметить, что LXC ориентирована прежде всего на создание независимых виртуальных окружений, с поддержкой раздельных сетевых стеков, ограничением на ресурсы, сохранением настроек и т.п., в то время как systemd-nspawn является лишь более удобной и эффективной заменой команды chroot(1), предназначенной прежде всего для развертывания, восстановления, сборки и тестирования операционных систем. Далее автор разъясняет свою точку зрения на этот вопрос.

 $<sup>^{27}</sup>$ Прим. перев.: Впоследствии в systemd-nspawn была добавлена опция --private-network, позволяющая изолировать систему внутри контейнера от сети хоста: такая система будет видеть только свой собственный интерфейс обратной петли.

4. Эта утилита очень компактна и присутствует везде, где установлен systemd. Она не требует специальной установки и настройки.

systemd уже подготовлен для работы внутри таких контейнеров. Например, когда подается команда на выключение системы внутри контейнера, systemd на последнем шаге вызывает не reboot(), а просто exit().

Стоит отметить, что systemd-nspawn все же не является полноценной системой контейнерной виртуализации/изоляции — если вам нужно такое решение, воспользуйтесь LXC. Этот проект использует те же самые механизмы ядра, но предоставляет куда более широкие возможности, включая виртуализацию сети. Могу предложить такую аналогию: systemd-nspawn как реализация контейнера похожа на GNOME 3 — компактна и проста в использовании, опций для настройки очень мало. В то время как LXC больше похож на KDE: опций для настройки больше, чем строк кода. Я создал systemd-nspawn специально для тестирования, отладки, сборки, восстановления. Именно для этих задач вам стоит ее использовать — она неплохо с ними справляется, куда лучше, чем сhroot(1).

Что ж, пора заканчивать. Итак:

- 1. Использование chroot() для обеспечения безопасности дает наилучший результат, когда оно реализовано непосредственно в коде самой программы.
- 2. ReadOnlyDirectories= и InaccessibleDirectories= могут быть удобной альтернативой созданию полновесных chroot-окружений.
- 3. Если вам нужно поместить в chroot-окружение какую-либо службу, воспользуйтесь опцией RootDirectory=.
- 4. systemd-nspawn очень неплохая штука.
- 5. chroot'ы убоги, FSNS 1337.

И все это уже сейчас доступно в Fedora 15.

### 7 Поиск виновных

Fedora 15<sup>28</sup> является первым релизом Fedora, использующим systemd в качестве системы инициализации по умолчанию. Основной нашей целью при работе над выпуском F15 является обеспечение полной взаимной интеграции и корректной работы всех компонентов. При подготовке следующего релиза, F16, мы сконцентрируемся на дальнейшей полировке и ускорении системы. Для этого мы подготовили ряд инструментов (доступных уже в F15), которые должны помочь нам в поиске проблем, связанных с процессом загрузки. В этой статье я попытаюсь рассказать о том, как найти виновников медленной загрузки вашей системы, и о том, что с ними делать дальше.

Первый инструмент, который мы можем вам предложить, очень прост: по завершении загрузки, systemd регистрирует в системном журнале информацию о суммарном времени загрузки:

systemd[1]: Startup finished in 2s 65ms 924us (kernel) + 2s 828ms 195us (initrd)
+ 11s 900ms 471us (userspace) = 16s 794ms 590us.

Эта запись означает следующее: на инициализацию ядра (до момента запуска initrd, т.е. dracut) ушло 2 секунды. Далее, чуть менее трех секунд работал initrd. И наконец, почти 12 секунд было потрачено systemd на запуск программ из пространства пользователя. Итоговое время, начиная с того момента, как загрузчик передал управление коду ядра, до того момента, как systemd завершил все операции, связанные с загрузкой системы, составило почти 17 секунд. Казалось бы, смысл этого числа вполне очевиден... Однако не стоит делать поспешных выводов. Прежде всего, сюда не входит время, затраченное на инициализацию вашего сеанса в GNOME, так как эта задача уже выходит

 $<sup>^{28} \</sup>mbox{Величайший в истории релиз свободной OC.}$ 

за рамки задач процесса init. Кроме того, в этом показателе учитывается только время работы systemd, хотя часто бывает так, что некоторые демоны продолжают *свою* работу по инициализации уже после того, как секундомер остановлен. Проще говоря: приведенные числа позволяют лишь оценить общую скорость загрузки, однако они не являются точной характеристикой длительности процесса.

Кроме того, эта информация носит поверхностный характер: она не сообщает, какие именно системные компоненты заставляют systemd ждать так долго. Чтобы исправить это упущение, мы ввели команду systemd-analyze blame:

```
$ systemd-analyze blame
  6207ms udev-settle.service
  5228ms cryptsetup@luks\x2d9899b85d\x2df790\x2d4d2a\x2da650\x2d8b7d2fb92cc3.service
  735ms NetworkManager.service
  642ms avahi-daemon.service
  600ms abrtd.service
  517ms rtkit-daemon.service
  478ms fedora-storage-init.service
  396ms dbus.service
  390ms rpcidmapd.service
  346ms systemd-tmpfiles-setup.service
  322ms fedora-sysinit-unhack.service
  316ms cups.service
  310ms console-kit-log-system-start.service
  309ms libvirtd.service
  303ms rpcbind.service
  298ms ksmtuned.service
  288ms lvm2-monitor.service
  281ms rpcgssd.service
  277ms sshd.service
  276ms livesys.service
  267ms iscsid.service
  236ms mdmonitor.service
  234ms nfslock.service
  223ms ksm.service
  218ms mcelog.service
```

Она выводит список юнитов systemd, активированных при загрузке, с указанием времени инициализации для каждого из них. Список отсортирован по убыванию этого времени, поэтому наибольший интерес для нас представляют первые строчки. В нашем случае это udev-settle.service и cryptsetup@luks\x2d9899b85d\x2df790\x2d4d2a\x2da650\x2d8b7d2fb92cc3.service, инициализация которых занимает более одной секунды. Стоит отметить, что к анализу вывода команды systemd-analyze blame тоже следует подходить с осторожностью: она не поясняет, novemy тот или иной юнит тратит столько-то времени, она лишь констатирует факт, что время было затрачено. Кроме того, не стоит забывать, что юниты могут запускаться параллельно. В частности, если две службы были запущены одновременно, то время их инициализации будет значительно меньше, чем сумма времен инициализации каждой из них.

Рассмотрим повнимательнее первого осквернителя нашей загрузки: службу udev-settle.service<sup>29</sup> Почему ей требуется так много времени для запуска, и что мы можем с этим сделать? Данная служба выполняет очень простую функцию: она ожидает, пока udev завершит опрос устройств, после чего завершается. Опрос же устройств может занимать довольно много времени. Например, в нашем случае опрос устройств длится более 6 секунд из-за подключенного к компьютеру 3G-модема, в котором отсутствует SIM-карта. Этот модем очень долго отвечает на запросы udev. Опрос

<sup>29</sup>Прим. перев.: После объединения проектов systemd и udev, эта служба называется systemd-udev-settle.service.

устройств является частью схемы, обеспечивающей работу ModemManager'а и позволяющей NetworkManager'у упростить для вас настройку 3G. Казалось бы, очевидно, что виновником задержки является именно ModemManager, так как опрос устройств для него занимает слишком много времени. Но такое обвинение будет заведомо ошибочным. Дело в том, что опрос устройств очень часто оказывается довольно длительной процедурой. Медленный опрос 3G-устройств для ModemManager является частным случаем, отражающим это общее правило. Хорошая система опроса устройств обязательно должна учитывать тот факт, что операция опроса любого из устройств может затянуться надолго. Истинной причиной наших проблем является необходимость ожидать завершения опроса, т.е., наличие службы udev-settle.service как обязательной части нашего процесса загрузки.

Но почему эта служба вообще присутствует в нашем процессе загрузки? На самом деле, мы можем прекрасно обойтись и без нее. Она нужна лишь как часть используемой в Fedora схемы инициализации устройств хранения, а именно, набора скриптов, выполняющих настройку LVM, RAID и multipath-устройств. На сегодняшний день, реализация этих систем не поддерживает собственного механизма поиска и опроса устройств, и поэтому их запуск должен производиться только после того, как эта работа уже проделана — тогда они могут просто последовательно перебирать все диски. Однако, такой подход противоречит одному из фундаментальных требований к современным компьютерам: возможности подключать и отключать оборудование в любой момент, как при выключенном компьютере, так и при включенном. Для некоторых технологий невозможно точно определить момент завершения формирования списка устройств (например, это характерно для USB и iSCSI), и поэтому процесс опроса таких устройств обязательно должен включать некоторую фиксированную задержку, гарантирующую, что все подключенные устройства успеют отозваться. С точки зрения скорости загрузки это, безусловно, негативный эффект: соответствующие скрипты заставляют нас ожидать завершения опроса устройств, хотя большинство этих устройств не являются необходимыми на данной стадии загрузки. В частности, в рассматриваемой нами системе LVM, RAID и multipath вообще не используются!<sup>30</sup>

С учетом вышесказанного, мы можем спокойно исключить udev-settle.service из нашего процесса загрузки, так как мы не используем ни LVM, ни RAID, ни multipath. Замаскируем эти службы, чтобы увеличить скорость загрузки:

```
# ln -s /dev/null /etc/systemd/system/udev-settle.service
# ln -s /dev/null /etc/systemd/system/fedora-wait-storage.service
# ln -s /dev/null /etc/systemd/system/fedora-storage-init.service
# systemctl daemon-reload
```

После перезагрузки мы видим, что загрузка стала на одну секунду быстрее. Но почему выигрыш оказался таким маленьким? Из-за второго осквернителя нашей загрузки — стуртsetup. На рассматриваемой нами системе зашифрован раздел /home. Специально для нашего тестирования я записал пароль в файл, чтобы исключить влияние скорости ручного набора пароля. К сожалению, для подключения шифрованного раздела стуртsetup требует более пяти секунд. Будем ленивы, и вместо того, чтобы исправлять

<sup>&</sup>lt;sup>30</sup>Наиболее правильным решением в данном случае будет ожидание событий подключения устройств (реализованное через libudev или аналогичную технологию) с соответствующей обработкой каждого такого события — подобный подход позволит нам продолжить загрузку, как только будут готовы все устройства, необходимые для ее продолжения. Для того, чтобы загрузка была быстрой, мы должны ожидать завершения инициализации только тех устройств, которые действительно необходимы для ее продолжения на данной стадии. Ожидать остальные устройства в данном случае смысла нет. Кроме того, стоит отметить, что в числе программ, не приспособленных для работы с динамически меняющимся оборудованием и построенных в предположении о неизменности списка устройств, кроме служб хранения, есть и другие подсистемы. Например, в нашем случае работа initrd занимает так много времени главным образом из-за того, что для запуска Plymouth необходимо дождаться завершения инициализации всех устройств видеовывода. По неизвестной причине (во всяком случае, неизвестной для меня) подгрузка модулей для моих видеокарт Intel занимает довольно продолжительное время, что приводит к беспричинной задержке процесса загрузки. (Нет, я возражаю не против опроса устройств как такового, но против необходимости ожидать его завершения, чтобы продолжить загрузку.)

опибку в стуртветир<sup>31</sup>, попробуем найти обходной путь<sup>32</sup>. Во время загрузки systemd должен дождаться, пока все файловые системы, перечисленные в /etc/fstab (кроме помеченных как noauto) будут обнаружены, проверены и смонтированы. Только после этого systemd может продолжить загрузку и приступить к запуску служб. Но первое обращение к /home (в отличие, например, от /var), происходит на поздней стадии процесса загрузки (когда пользователь входит в систему). Следовательно, нам нужно сделать так, чтобы этот каталог автоматически монтировался при загрузке, но процесс загрузки не ожидал завершения работы стуртветир, fsck и mount для этого раздела. Как же сделать точку монтирования доступной, не ожидая, пока завершится процесс монтирования? Этого можно достичь, воспользовавшись магической силой systemd — просто добавим опцию монтирования comment=systemd.automount в /etc/fstab. После этого, systemd будет создавать в /home точку автоматического монтирования, и при первом же обращении к этому каталогу, если файловая система еще не будет готова к работе, systemd подготовит соответствующее устройство, проверит и смонтирует ее.

После внесения изменений в /etc/fstab и перезагрузки мы получаем:

systemd[1]: Startup finished in 2s 47ms 112us (kernel) + 2s 663ms 942us (initrd)
+ 5s 540ms 522us (userspace) = 10s 251ms 576us.

Прекрасно! Несколькими простыми действиями мы выиграли почти семь секунд. И эти два изменения исправляют только две наиболее очевидные проблемы. При более аккуратном и детальном исследовании, обнаружится еще множество моментов, которые можно улучшить. Например, на другом моем компьютере, лаптопе X300 двухлетней давности (и даже два года назад он был не самым быстрым на Земле), после небольшой доработки, время загрузки до полноценной среды GNOME составило около четырех секунд, и это еще не предел совершенства.

systemd-analyze blame — простой и удобный инструмент для поиска медленно запускающихся служб, однако он обладает одним существенным недостатком: он не показывает, насколько эффективно параллельный запуск снижает потерю времени для медленно запускающихся служб. Чтобы вы могли наглядно оценить этот фактор, мы подготовили команду systemd-analyze plot. Использовать ее очень просто:

```
$ systemd-analyze plot > plot.svg
$ eog plot.svg
```

Она создает наглядные диаграммы, показывающие моменты запуска служб и время, затраченное на их запуск, по отношению к другим службам. На текущий момент, она не показывает явно, кто кого ожидает, но догадаться обычно несложно<sup>33</sup>.

Чтобы продемонстрировать эффект, порожденный двумя нашими оптимизациями, приведем ссылки на соответствующие графики: до и после (для полноты описания приведем также и соответствующие данные systemd-analyze blame: до и после).

У наиболее эрудированных читателей может возникнуть вопрос: как это соотносится с программой bootchart? Действительно, systemd-analyze plot и bootchart рисуют похожие графики. Однако, bootchart является намного более мощным инструментом — он детально показывает, что именно происходило во время загрузки, и отображает соответствующие графики использования процессора и ввода-вывода. systemd-analyze plot оперирует более высокоуровневой информацией: сколько времени затратила та или иная служба во время запуска, и какие службы были вынуждены ее ожидать. Используя оба

<sup>&</sup>lt;sup>31</sup>На самом деле, я действительно пытался исправить эту ошибку. Задержки в стурtsetup, по моим наблюдениям, обусловлены, главным образом, слишком большим значением по умолчанию для опции --iter-time. Я попытался доказать сопровождающим пакета стурtsetup, что снижение этого времени с 1 секунды до 100 миллисекунд не приведет к трагическим последствиям для безопасности, однако они мне не поверили.

 $<sup>^{32}</sup>$ Вообще-то я предпочитаю решать проблемы, а не искать пути для их обхода, однако в данном конкретном случае возникает отличная возможность продемонстрировать одну интересную возможность systemd...

<sup>&</sup>lt;sup>33</sup>Прим. перев.: Начиная с systemd 203, добавлена поддержка специальной команды systemd-analyze critical-chain, которая выводит самую медленную цепочку юнитов (цепь в графе зависимостей, формируемом при загрузке). Время запуска всех юнитов в этой цепочке определяет итоговое время загрузки системы.

этих инструмента, вы значительно упростите себе поиск причин замедления вашей загрузки.

Но прежде, чем вы вооружитесь описанными здесь средствами и начнете отправлять багрепорты авторам и сопровождающим программ, которые замедляют вашу загрузку, обдумайте все еще раз. Эти инструменты предоставляют вам «сырую» информацию. Постарайтесь не ошибиться, интерпретируя ее. Например, в при рассмотрении приведенного выше примера я показал, что проблема была вовсе не в udev-settle.service, и не в опросе устройств для ModemManager'a, а в неудачной реализации подсистемы хранения, требующей ожидать окончания опроса устройств для продолжения загрузки. Именно эту проблему и нужно исправлять. Поэтому постарайтесь правильно определить источник проблем. Возлагайте вину на тех, кто действительно виноват.

Как уже говорилось выше, все три описанных здесь инструмента доступны в Fedora 15 «из коробки».

Итак, какие же выводы мы можем сделать из этой истории?

- systemd-analyze отличный инструмент. Фактически, это встроенный профилировщик systemd.
- Постарайтесь не ошибиться, интерпретируя вывод профилировщика!
- Всего два небольших изменения могут ускорить загрузку системы на семь секунд.
- Программное обеспечение, не способное работать с динамически меняющимся набором устройств, создает проблемы, и должно быть исправлено.
- Принудительное использование в стандартной установке Fedora 15 промышленной реализации подсистем хранения, возможно, является не самым правильным решением.

## 8 Новые конфигурационные файлы

Одно из ключевых достоинств systemd — наличие полного набора программ, необходимых на ранних стадиях загрузки, причем эти программы написаны на простом, быстром, надежном и легко поддающемся распараллеливанию языке С. Теперь можно отказаться от «простыней» shell-скриптов, разработанных для этих задач различными дистрибутивами. Наш «Проект нулевой оболочки» увенчался полным успехом. Уже сейчас возможности предоставляемого нами инструментария покрывают практически все нужды настольных и встраиваемых систем, а также большую часть потребностей серверов:

- Проверка и монтирование всех файловых систем.
- Обновление и активация квот на всех файловых системах.
- Установка имени хоста.
- Настройка сетевого интерфейса обратной петли (lo).
- Подгрузка правил SELinux, обновление меток безопасности в динамических каталогах /run и /dev.
- Регистрация в ядре дополнительных бинарных форматов (например, Java, Mono, WINE) через API-файловую систему binfmt\_misc.
- Установка системной локали.
- Настройка шрифта и раскладки клавиатуры в консоли.
- Создание, очистка, удаление временных файлов и каталогов.

<sup>34</sup> Наш девиз — «Первой оболочкой, запускающейся при старте системы, должна быть GNOME shell». Формулировка оставляет желать лучшего, но все же неплохо передает основную идею.

- Применение предписанных в /etc/fstab опций к смонтированным ранее API-файловым системам.
- Применение настроек sysctl.
- Поддержка технологии упреждающего чтения (read ahead), включая автоматический сбор информации.
- Обновление записей в utmp при включении и выключении системы.
- Сохранение и восстановление затравки для генерации случайных чисел (random seed).
- Принудительная загрузка указанных модулей ядра.
- Поддержка шифрованных дисков и разделов.
- Автоматический запуск getty на serial-консолях.
- Взаимодействие с Plymouth.
- Создание уникального идентификатора системы.
- Настройка часового пояса.

В стандартной установке Fedora 15 запуск shell-скриптов требуется только для некоторых устаревших служб, а также для подсистемы хранения данных (поддержка LVM, RAID и multipath). Если они вам не нужны, вы легко можете отключить их, и наслаждаться загрузкой, полностью очищенной от shell-костылей (лично я это сделал уже давно). Такая загрузка является уникальной возможностью Linux-систем.

Большинство перечисленных выше компонентов настраиваются через конфигурационные файлы в каталоге /etc. Некоторые из этих файлов стандартизированы для всех дистрибутивов, и поэтому реализация их поддержки в наших инструментах не представляла особого труда. Например, это относится к файлам /etc/fstab, /etc/crypttab, /etc/sysctl.conf. Однако множество других, нестандартно расположенных файлов и каталогов вынуждали нас добавлять в код огромное количество операторов #ifdef, чтобы обеспечить поддержку различных вариантов расположения конфигураций в разных дистрибутивах. Такое положение дел сильно усложняет жизнь нам всем, и при этом ничем не оправдано — все эти файлы решают одни и те же задачи, просто немного по-разному.

Чтобы улучшить ситуацию и установить единый стандарт расположения базовых конфигурационных файлов во всех дистрибутивах, мы заставили systemd пользоваться дистрибутивно-специфическими конфигурациями только в качестве резервного варианта — основным источником информации становится определенный нами стандартный набор конфигурационных файлов. Разумеется, там, где это возможно, мы старались не придумывать чего-то принципиально нового, а брали лучшее из решений, предложенных существующими дистрибутивами. Ниже приводится небольшой обзор этого нового набора конфигурационных файлов, поддерживаемых systemd во всех дистрибутивах:

- /etc/hostname: имя хоста для данной системы. Одна из наиболее простых и важных системных настроек. В разных дистрибутивах оно настраивалось по-разному: Fedora использовала /etc/sysconfig/network, OpenSUSE /etc/HOSTNAME, Debian /etc/hostname. Мы остановились на варианте, предложенном Debian.
- /etc/vconsole.conf: конфигурация раскладки клавиатуры и шрифта для консо-
- /etc/locale.conf: конфигурация общесистемной локали.

- /etc/modules-load.d/\*.conf: каталог<sup>35</sup> для перечисления модулей ядра, которые нужно принудительно подгрузить при загрузке (впрочем, необходимость в этом возникает достаточно редко).
- /etc/sysctl.d/\*.conf: каталог для задания параметров ядра (sysctl). Дополняет классический конфигурационный файл /etc/sysctl.conf.
- /etc/tmpfiles.d/\*.conf: каталог для управления настройками временных файлов (systemd обеспечивает создание, очистку и удаление временных файлов и каталогов, как во время загрузки, так и во время работы системы).
- /etc/binfmt.d/\*.conf: каталог для регистрации дополнительных бинарных форматов (например, форматов Java, Mono, WINE).
- /etc/os-release: стандарт для файла, обеспечивающего идентификацию дистрибутива и его версии. Сейчас различные дистрибутивы используют для этого разные файлы (например, /etc/fedora-release в Fedora), и поэтому для решения такой простой задачи, как вывод имени дистрибутива, необходимо использовать базу данных, содержащую перечень возможных названий файлов. Проект LSB попытался создать такой инструмент — lsb\_release — однако реализация столь простой функции через скрипт на Python'e является не самым оптимальным решением. Чтобы исправить сложившуюся ситуацию, мы решили перейти к единому простому формату представления этой информации.
- /etc/machine-id: файл с идентификатором данного компьютера (перекрывает аналогичный идентификатор D-Bus). Гарантируется, что в любой системе, использующей systemd, этот файл будет существовать и содержать корректную информацию (если его нет, он автоматически создается при загрузке). Мы вынесли этот файл из-под эгиды D-Bus, чтобы упростить решение множества задач, требующих наличия уникального и постоянного идентификатора компьютера.
- /etc/machine-info: новый конфигурационный файл, хранящий информации о полном (описательном) имени хоста (например, «Компьютер Леннарта») и значке, которым он будет обозначаться в графических оболочках, работающих с сетью (раньше этот значок мог определяться, например, файлом /etc/favicon.png). Данный конфигурационный файл обслуживается демоном systemd-hostnamed.

Одна из важнейших для нас задач — убедить *вас* использовать эти новые конфигурационные файлы в ваших инструментах для настройки системы. Если ваши конфигурационные фронтенды будут использовать новые файлы, а не их старые аналоги, это значительно облегчит портирование таких фронтендов между дистрибутивами, и вы внесете свой вклад в стандартизацию Linux. В конечном счете это упростит жизнь и администраторам, и пользователям. Разумеется, на текущий момент эти файлы полностью поддерживаются только дистрибутивами, основанными на systemd, но уже сейчас в их число входят практически все ключевые дистрибутивы, за исключением одного <sup>36</sup>. В этом есть что-то от «проблемы курицы и яйца»: стандарт становится настоящим стандартом только тогда, когда ему начинают следовать. В будущем мы намерены аккуратно форсировать процесс перехода на новые конфигурационные файлы: поддержка старых файлов будет удалена из systemd. Разумеется, процесс будет идти медленно, шаг

<sup>&</sup>lt;sup>35</sup>Прим. перев.: Для описания этого и трех последующих каталогов автор пользуется термином «dropin directory». Данный термин означает каталог, в который можно поместить множество независимых файлов настроек, и при чтении конфигурации все эти файлы будут обработаны (впрочем, часто накладывается ограничение — обрабатываются только файлы с именами, соответствующими маске, обычно \*.conf). Такой подход позволяет значительно упростить процесс как ручного, так и автоматического конфигурирования различных компонентов — для внесения изменений в настройки уже не нужно редактировать основной конфигурационный файл, достаточно лишь скопировать/переместить в нужный каталог небольшой файл с указанием специфичных параметров.

 $<sup>^{36}</sup>$ Прим. перев.: В конце 2010 года энтузиаст Andrew Edmunds добавил в systemd базовую поддержку Ubuntu и подготовил соответствующие пакеты, однако его инициатива не встретила поддержки среди менеджеров Canonical. На момент написания этих строк проект остается заброшенным с декабря 2010 г.

за шагом. Но конечной его целью является переход всех дистрибутивов на единый набор базовых конфигурационных файлов.

Многие из этих файлов используются не только программами для настройки системы, но и апстримными проектами. Например, мы предлагаем проектам Mono, Java, WINE и другим помещать конфигурацию для регистрации своих бинарных форматов в /etc/binfmt.d/ средствами их собственной сборочной системы. Специфичные для дистрибутивов механизмы поддержки бинарных форматов больше не нужны, и ваш проект будет работать одинаково хорошо во всех дистрибутивах. Аналогичное предложение мы обращаем и ко всем разработчикам программ, которым требуется автоматическое создание/очистка временных файлов и каталогов, например, в каталоге /run (ранее известном как /var/run). Таким проектам достаточно просто поместить соответствующий конфигурационный файл в /etc/tmpfiles.d/, тоже средствами собственной сборочной системы. Помимо прочего, подобный подход позволит увеличить скорость загрузки, так как, в отличие от SysV, не требует множества shell-скриптов, выполняющих тривиальные задачи (регистрация бинарных форматов, удаление/создание временных файлов/каталогов и т.п.). И пример того случая, когда апстримная поддержка стандартной конфигурации дала бы огромные преимущества — X11 (и его аналоги) могли бы устанавливать раскладку клавиатуры на основании данных из /etc/vconsole.conf.

Разумеется, я понимаю, что отнюдь не всех полностью устроят выбранные нами имена и форматы конфигурационных файлов. Но нам все же нужно было что-то выбрать, и мы выбрали то, что должно устроить большинство людей. Форматы конфигурационных файлов максимально просты, и их можно легко читать и записывать даже из shell-скриптов. Да, /etc/bikeshed.conf могло бы быть неплохим именем для файла конфигурации!<sup>37</sup>

Помогите нам стандартизировать Linux! Используйте новые конфигурационные файлы! Поддерживайте их в апстриме, поддерживайте их во всех дистрибутивах!

И если у вас возникнет такой вопрос: да, все эти файлы так или иначе обсуждались с разными разработчиками из различных дистрибутивов. И некоторые из разработчиков планируют обеспечить поддержку новой конфигурации даже в системах без systemd.

# 9 О судьбе /etc/sysconfig и /etc/default

В дистрибутивах, основанных на Red Hat и SUSE, это каталог называется /etc/sysconfig. В дистрибутивах на базе Debian, его зовут /etc/default. Во многих других дистрибутивах также присутствуют каталоги похожего назначения. Связанные с ними вопросы неоднократно появляются в дискуссиях пользователей и разработчиков systemd. В этой статье мне хотелось бы рассказать, что я, как разработчик systemd, думаю об этих каталогах, и пояснить, почему, на мой взгляд, от них лучше отказаться. Стоит отметить, что это мое личное мнение, и оно может не совпадать с позицией проекта Fedora или моего работодателя.

Начнем с небольшого исторического экскурса. Каталог /etc/sysconfig появился в дистрибутивах Red Hat и SUSE задолго до того, как я присоединился к этим проектам — иными словами, это было очень давно. Некоторое время спустя, в Debian появился аналогичный по смыслу каталог /etc/default. Многие дистрибутивы используют такие каталоги, называя их по-разному. Они имеются даже в некоторых ОС семейства Unix. (Например, в SCO. Если эта тема вас заинтересовала — рекомендую обратиться к вашему знакомому ветерану Unix, он расскажет гораздо подробнее и интереснее, чем я.) Несмотря на то, что подобные каталоги широко используются в Linux и Unix, они совершенно не стандартизированы — ни в POSIX, ни в LSB/FHS, и результате мы имеем целый зоопарк их различных реализаций в разных дистрибутивах.

 $<sup>^{37}</sup>$ Прим. перев.: Здесь автор намекает на Паркинсоновский Закон Тривиальности, который гласит, что самые жаркие споры возникают вокруг наиболее простых вопросов. В частности, в качестве примера Паркинсон приводит обсуждение строительства атомной электростанции и гаража для велосипедов (bike shed) — если первое из этих решений принимается довольно быстро, то вокруг второго разгорается множество дискуссий по самым разным аспектам.

Назначение этих каталогов определено весьма расплывчато. Абсолютное большинство находящихся в них файлов являются включаемыми<sup>38</sup> shell-скриптами, содержащими, главным образом, определения переменных. Большинство файлов из этих каталогов включаются в одноименные скрипты SysV init. Данный принцип отражен в Debian Policy Manual (раздел 9.3.2) и в Fedora Packaging Guidelines, однако в обоих дистрибутивах иногда встречаются файлы, не соответствующие описанной схеме, например, не имеющие соответствующего init-скрипта, или даже сами не являющиеся скриптами.

Но почему вообще появились эти каталоги? Чтобы ответить на такой вопрос, обратимся к истории развития концепции SysV init-скриптов. Исторически, сложилось так, что они располагаются в каталоге под названием /etc/rc.d/init.d (или что-то похожее). Отметим, что каталог /etc вообще-то предназначен для хранения файлов конфигурации, а не исполняемого кода (в частности, скриптов). Однако, в начале своей истории, init-скрипты рассматривались именно как файлы конфигурации, и редактирование их администратором было общепринятой практикой. Но со временем, по мере роста и усложнения этих скриптов, их стали рассматривать уже не как файлы конфигурации, а как некие программы. Чтобы упростить их настройку и обеспечить безопасность процесса обновления, настройки были вынесены в отдельные файлы, загружаемые при работе init-скриптов.

Попробуем составить некоторое представление о настройках, которые можно сделать через эти файлы. Вот краткий и неполный список различных параметров, которые могут быть заданы через переменные окружения в таких файлах (составлен мною по результатам исследования соответствующих каталогов в Fedora и Debian):

- Дополнительные параметры командной строки для бинарника демона.
- Настройки локали для демона.
- Тайм-аут остановки для демона.
- Режим остановки для демона.
- Общесистемные настройки, например, системная локаль, часовой пояс, параметры клавиатуры для консоли.
- Избыточная информация о системных настройках, например, указание, установлены ли аппаратные часы по Гринвичу или по местному времени.
- Списки правил брандмауэра, не являются скриптами (!).
- Привязка к процессорным ядрам для демона.
- Настройки, не относящиеся к процессу загрузки, например, информация по установке пакетов с новыми ядрами, конфигурация nspluginwrapper, разрешение на выполнение предварительного связывания (prelinking) библиотек.
- Указание, нужно ли запускать данную службу или нет.
- Настройки сети.
- Перечень модулей ядра, которые должны быть подгружены принудительно.
- Нужно ли отключать питание компьютера при остановке системы (poweroff) или нет (halt).
- Права доступа для файлов устройств (!).
- Описание соответствующей SysV службы.

<sup>&</sup>lt;sup>38</sup>Прим. перев.: Здесь автор использует термин sourcable, происходящий от bash'овской директивы source, обеспечивающей включение в скрипт кода из внешнего файла. В классическом POSIX shell это соответствует оператору-точке «.». В отличие от прямого запуска одного скрипта из другого, включаемый код исполняется той же самой оболочкой, что и основной код, и при возвращении в основной скрипт сохраняются переменные окружения, определенные во включаемом коде. Как правило, код для включения не содержит shebang'a (#!/bin/sh в начале файла).

- Идентификатор пользователя/группы, значение umask для демона.
- Ограничения по ресурсам для демона.
- Приоритет ООМ killer'а для демона.

A теперь давайте ответим на вопрос: что же такого неправильного в /etc/sysconfig (/etc/default) и почему этим каталогам нет места в мире systemd?

- Прежде всего, утрачены основная цель и смысл существования таких каталогов: файлы конфигурации юнитов systemd не являются программами, в отличие от init-скриптов SysV. Эти файлы представляют собой простые, декларативные описания конкретных задач и функций, и обычно содержат не более шести строк. Они легко могут быть сгенерированы и проанализованы без использования Bourne shell. Их легко читать и понимать. Кроме того, их легко модифицировать: достаточно скопировать файл из /lib/systemd/system в /etc/systemd/system, после чего внести в созданную копию необходимые изменения (при этом можно быть уверенным, что изменения не будут затерты пакетным менеджером). Изначальная причина появления обсуждаемых каталогов необходимость разделять код и параметры конфигурации больше не существует, так как файлы описания юнитов не являются кодом. Проще говоря, обсуждаемые каталоги являются решением проблемы, которой уже не существует.
- Обсуждаемые каталоги и файлы в них очень сильно привязаны к специфике дистрибутивов. Мы же планируем, используя systemd, способствовать стандартизации и унификации дистрибутивов. В частности, одним из факторов такой стандартизации является рекомендация распространять соответствующие файлы конфигурации юнитов сразу с апстримным продуктом, а не возлагать эту работу на создателей пакетов, как это делалась во времена SysV. Так как расположение обсуждаемых каталогов и настраиваемые через них параметры сильно отличаются от дистрибутива к дистрибутиву, пытаться поддерживать их в апстримных файлах конфигурации юнитов просто бессмысленно. Хранение параметров конфигурации в этих каталогах один из факторов, превращающих Linux в зоопарк несовместимых решений.
- Большинство настроек, задаваемых через эти каталоги, являются избыточными в мире systemd. Например, различные службы позволяют задать таким методом параметры исполнения процесса, в частности, идентификатор пользователя/группы, ограничения ресурсов, привязки к ядрам СРU, приоритет ООМ killer'а. Однако, эти настройки поддерживаются лишь некоторыми init-скриптами, причем одна и та же настройка в различных скриптах может называться по-разному. С другой стороны, в мире systemd, все эти настройки доступны для всех служб без исключения, и всегда задаются одинаково, через одни и те же параметры конфигурационных файлов.
- Файлы конфигурации юнитов имеют множество удобных и простых в использовании настроек среды исполнения процесса, гораздо больше, чем могут предоставить файлы из /etc/sysconfig.
- Необходимость в некоторых из этих настроек весьма сомнительна. Например, возьмем вышеупомянутую возможность задавать идентификатор пользователя/группы для процесса. Эту задачу должен решать разработчик ПО или дистрибутива. Вмешательство администратора в данную настройку, как правило, лишено смысла только разработчик располагает всей информацией, позволяющий предотвратить конфликты идентификаторов и имен пользователей и групп.
- Формат файлов, используемых для сохранения настроек, плохо подходит для данной задачи. Так как эти файлы, как правило, являются включаемыми shell-скриптами, ошибки при их чтении очень трудно отследить. Например, ошибка в имени переменной приведет к тому, что переменная не будет изменена, однако никакого предупреждения при этом не выводится.

- Кроме того, такая организация не исключает влияния конфигурационных параметров на среду исполнения: например, изменение переменных IFS и LANG может существенно повлиять на результат интерпретации init-скрипта.
- Интерпретация этих файлов требует запуска еще одного экземпляра оболочки, что приводит к задержкам при загрузке<sup>39</sup>.
- Файлы из /etc/sysconfig часто пытаются использовать в качестве суррогатной замены файлов конфигурации для тех демонов, которые не имеют встроенной поддержки конфигурационных файлов. В частности, вводятся специальные переменные, позволяющие задать аргументы командной строки, используемые при запуске демона. Встроенная поддержка конфигурационных файлов является более удобной альтернативой такому подходу, ведь, глядя на ключи «-k», «-a», «-f», трудно догадаться об их назначении. Очень часто, из-за ограниченности словаря, на различных демонов одни и те же ключи действуют совершенно по-разному (для одного демона ключ «-f» содержит указание демонизироваться при запуске, в то время как для другого эта опция действует прямо противоположным образом.) В отличие от конфигурационных файлов, строка запуска не может включать полноценных комментариев.
- Некоторые из настроек, задаваемых в /etc/sysconfig, являются полностью избыточными. Например, во многие дистрибутивах подобным методом указывается, установлены ли аппаратные часы компьютера по Гринвичу, или по местному времени. Однако эта же настройка задается третьей строкой файла /etc/adjtime, поддерживаемого во всех дистрибутивах. Использование избыточного и не стандартизированного параметра конфигурации только добавляет путаницу и не несет никакой пользы.
- Многие файлы настроек из /etc/sysconfig позволяют отключать запуск соответствующей службы. Однако эта операция уже поддерживается штатно для всех служб, через команды systemctl enable/disable (или chkconfig on/off). Добавление дополнительного уровня настройки не приносит никакой пользы и лишь усложняет работу администратора.
- Что касается списка принудительно загружаемых модулей ядра в настоящее время существуют куда более удобные пути для автоматической подгрузки модулей при загрузке системы. Например, многие модули автоматически подгружаются udev'ом при обнаружении соответствующего оборудования. Этот же принцип распространяется на ACPI и другие высокоуровневые технологии. Одно из немногих исключений из этого правила к сожалению, в настоящее время не поддерживается автоматическая загрузка модулей на основании информации о возможностях процессора, однако это будет исправлено в ближайшем будущем 40. В случае, если нужный вам модуль ядра все же не может быть подгружен автоматически, все равно существует гораздо более удобные методы указать его принудительную подгрузку например, путем создания соответствующего файла в каталоге /etc/modules-load.d/ (стандартный метод настройки принудительной подгрузки модулей).
- И наконец, хотелось бы отметить, что каталог /etc определен как место для хранения системных настроек («Host-specific system configuration», согласно FHS). Наличие внутри него подкаталога sysconfig, который тоже содержит системную конфигурацию, является очевидно избыточным.

Что же можно предложить в качестве современной, совместимой с systemd альтернативы настройке системы через файлы в этих каталогах? Ниже приведены несколько

 $<sup>^{39}</sup>$ Прим. перев.: Здесь автор несколько заблуждается. Скрипты, включенные через директиву source, исполняются тем же экземпляром оболочки, что и вызвавший их скрипт.

 $<sup>^{40}</sup>$ Прим. перев.: Необходимые патчи уже приняты в ядро, и соответствующая функция поддерживается Linux, начиная с версии 3.3.

рекомендаций, как лучше поступить с задаваемыми таким образом параметрами конфигурации:

- Попробуйте просто отказаться от них. Если они полностью избыточны (например, настройка аппаратных часов на Гринвич/местное время), то убрать их будет довольно легко (если не рассматривать вопросы обеспечения совместимости). Если аналогичные по смыслу опции штатно поддерживаются systemd, нет никакого смысла дублировать их где-то еще (перечень опций, которые можно задать для любой службы, приведен на страницах справки systemd.exec(5) и systemd.service(5).) Если же ваша настройка просто добавляет еще один уровень отключения запуска службы не плодите лишние сущности, откажитесь от нее.
- Найдите для них более подходящее место. Например, в случае с некоторыми общесистемными настройками (такими, как локаль или часовой пояс), мы надеемся аккуратно подтолкнуть дистрибутивы в правильном направлении (см. предыдущую главу).
- Добавьте их поддержку в штатную систему настройки демона через собственные файлы конфигурации. К счастью, большинство служб, работающих в Linux, являются свободным программным обеспечением, так что сделать это довольно просто.

Существует лишь одна причина поддерживать файлы /etc/sysconfig еще некоторое время: необходимо обеспечить совместимость при обновлении. Тем не менее, как минимум в новых пакетах, от таких файлов лучше отказаться.

В том случае, если требование совместимости критично, вы можете задействовать эти конфигурационные файлы даже в том случае, если настраиваете службы через штатные unit-файлы systemd. Если ваш файл из sysconfig содержит лишь определения переменных, можно воспользоваться опцией EnvironmentFile=-/etc/sysconfig/foobar (подробнее об этой опции см. systemd.exec(5)), позволяющей прочитать из файла набор переменных окружения, который будет установлен при запуске службы. Если же для задания настроек вам необходим полноценный язык программирования — ничто не мешает им воспользоваться. Например, вы можете создать в /usr/lib/<your package>/ простой скрипт, который включает соответствующие файлы, а затем запускает бинарник демона через ехес. После чего достаточно просто указать этот скрипт в опции ExecStart= вместо бинарника демона.

# 10 Экземпляры служб

Большинство служб в Linux/Unix являются одиночными (singleton): в каждый момент времени на данном хосте работает только один экземпляр службы. В качестве примера таких одиночных служб можно привести Syslogd, Postfix, Apache. Однако, существуют службы, запускающие по несколько экземпляров себя на одном хосте. Например, службы наподобие Dovecot IMAP запускают по одному экземпляру на каждый локальный порт и/или IP-адрес. Другой пример, который можно встретить практически во всех системах — qetty, небольшая служба, запускающаяся на каждом TTY (от tty1 до tty6). На некоторых серверах, в зависимости от сделанных администратором настроек или параметров загрузки, могут запускаться дополнительные экземпляры getty, для подключаемых к СОМ-портам терминалов или для консоли системы виртуализации. Еще один пример службы, работающей в нескольких экземплярах (по крайней мере, в мире systemd) — fsck, программа проверки файловой системы, которая запускается по одному экземпляру на каждое блочное устройство, требующее такой проверки. И наконец, стоит упомянуть службы с активацией в стиле inetd — при обращении через сокет, по одному экземпляру на каждое соединение. В этой статье я попытаюсь рассказать, как в systemd реализовано управление «многоэкземплярными» службами, и какие выгоды системный администратор может извлечь из этой возможности.

Если вы читали предыдущие статьи из этого цикла, вы, скорее всего, уже знаете, что службы systemd именуются по схеме foobar.service, где foobar— строка, идентифици-

рующая службу (проще говоря, ее имя), а .service — суффикс, присутствующий в именах всех файлов конфигурации служб. Сами эти файлы могут находиться в каталогах /etc/systemd/systemd и /lib/systemd/system (а также, возможно, и в других $^{41}$ ). Для служб, работающих в нескольких экземплярах, эта схема становится немного сложнее: foobar@quux. service, где foobar — имя службы, общее для всех экземпляров, а quux — идентификатор конкретного экземпляра. Например, serial-gett@ttyS2.service — это служба getty для COM-порта, запущенная на ttyS2.

При необходимости, экземпляры служб можно легко создать динамически. Скажем, вы можете, безо всяких дополнительных настроек, запустить новый экземпляр getty на последовательном порту, просто выполнив systemctl start для нового экземпляра:

#### # systemctl start serial-getty@ttyUSBO.service

Получив такую команду, systemd сначала пытается найти файл конфигурации юнита с именем, точно соответствующим запрошенному. Если такой файл найти не удается (при работе с экземплярами служб обычно так и происходит), из имени файла удаляется идентификатор экземпляра, и полученное имя используется при поиске шаблона конфигурации. В нашем случае, если отсутствует файл с именем serial-getty@ttyUSBO.service, используется файл-шаблон под названием serial-getty@.service. Таким образом, для всех экземпляров данной службы, используется один и тот же шаблон конфигурации. В случае с getty для СОМ-портов, этот шаблон, поставляемый в комплекте с systemd (файл /lib/systemd/system/serial-getty@.service) выглядит примерно так:

```
[Unit]
Description=Serial Getty on %I
BindTo=dev-%i.device
After=dev-%i.device systemd-user-sessions.service

[Service]
ExecStart=-/sbin/agetty -s %I 115200,38400,9600
Restart=always
RestartSec=0
```

(Заметим, что приведенная здесь версия немного сокращена, по сравнению с реально используемой в systemd. Удалены не относящиеся к теме нашего обсуждения параметры конфигурации, обеспечивающие совместимость с SysV, очистку экрана и удаление предыдущих пользователей с текущего TTY. Если вам интересно, можете посмотреть полную версию.)

Этот файл похож на обычный файл конфигурации юнита, с единственным отличием: в нем используются спецификаторы %I и %i. В момент загрузки юнита, systemd заменяет эти спецификаторы на идентификатор экземпляра службы. В нашем случае, при обращении к экземпляру serial-getty@ttyUSBO.service, они заменяются на «ttyUSBO». Результат такой замены можно проверить, например, запросив состояние для нашей службы:

<sup>&</sup>lt;sup>41</sup>Прим. перев.: Перечень каталогов, в которых выполняется поиск общесистемных юнит-файлов, приведен на странице руководства systemd(1) (раздел «System unit directories»). Указанные выше каталоги /etc/systemd/systemd и /lib/systemd/system соответствуют значениям по умолчанию для упомянутых там переменных pkg-config systemdsystemconfdir и systemdsystemunitdir соответственно. Начиная с systemd версии 198, данный перечень, в более точной и развернутой форме, присутствует на странице systemd.unit(5).

Собственно, это и есть ключевая идея организации экземпляров служб. Как видите, systemd предоставляет простой в использовании механизм шаблонов, позволяющих динамически создавать экземпляры служб. Добавим несколько дополнительных замечаний, позволяющих эффективно использовать этот механизм:

Вы можете создавать дополнительные экземпляры таких служб, просто добавляя символьные ссылки в каталоги \*.wants/. Например, чтобы обеспечить запуск getty на ttyUSB0 при каждой загрузке, достаточно создать такую ссылку:

```
# ln -s /lib/systemd/system/serial-getty@.service \
/etc/systemd/system/getty.target.wants/serial-getty@ttyUSBO.service
```

При этом файл конфигурации, на который указывает ссылка (в нашем случае serial-getty@.service), будет вызван с тем именем экземпляра, которое указанно в названии этой ссылки (в нашем случае — ttyUSBO).

Вы не сможете обратиться к юниту-шаблону без указания идентификатора экземпляра. В частности, команда systemctl start serial-getty@.service завершится ошибкой.

Иногда возникает необходимость отказаться от использования общего шаблона для конкретного экземпляра (т.е. конфигурация данного экземпляра настолько сильно отличается от параметров остальных экземпляров данной службы, что механизм шаблонов оказывается неэффективен). Специально для таких случаев, в systemd и заложен предварительный поиск файла с именем, точно соответствующим указанному (прежде чем использовать общий шаблон). Таким образом, вы можете поместить файл с именем, точно соответствующим полному титулу экземпляра, в каталог /etc/systemd/system/ — и содержимое этого файла, при обращении к выбранному экземпляру, полностью перекроет все настройки, сделанные в общем шаблоне.

В приведенном выше файле, в некоторых местах используется спецификатор %І, а в других — %і. У вас может возникнуть закономерный вопрос — чем они отличаются? %і всегда точно соответствует идентификатору экземпляра, в то время, как %І соответствует неэкранированной (unescaped) версии этого идентификатора. Когда идентификатор не содержит спецсимволов (например, ttyUSBO), результат в обоих случаях одинаковый. Но имена устройств, например, содержат слеши («/»), которые не могут присутствовать в имени юнита (и в имени файла на Unix). Поэтому, перед использованием такого имени в качестве идентификатора устройства, оно должно быть экранировано — «/» заменяются на «-», а большинство других специальных символов (включая «-») заменяются последовательностями вида \xAB, где AB — ASCII-код символа, записанный в шестнадцатеричной системе счисления<sup>42</sup>. Например, чтобы обратиться к последовательному USB-порту по его адресу на шине, нам нужно использовать имя наподобие serial/by-path/pci-0000:00:1d.0-usb-0:1.4:1.1-port0. Экранированная версия этоro имени —  $serial-by\x2dpath-pci\x2d0000:00:1d.0\x2dusb\x2d0:1.4:1.1\x2dport0.$ %I будет ссылаться на первую из этих строк, %i — на вторую. C практической точки зрения, это означает, что спецификатор %і можно использовать в том случае, когда надо сослаться на имена других юнитов, например, чтобы описать дополнительные зависимости (в случае с serial-getty@.service, этот спецификатор используется для ссылки на юнит dev-%i.device, соответствующий одноименному устройству). В то время как %I удобно использовать в командной строке (ExecStart) и для формирования читабельных строк описания. Рассмотрим работу этих принципов на примере нашего юнит-файла<sup>43</sup>:

 $<sup>^{42}</sup>$ Согласен, этот алгоритм дает на выходе не очень читабельный результат. Но этим грешат практически все алгоритмы экранирования. В данном случае, был использован механизм экранирования из udev, с одним изменением. В конце концов, нам нужно было выбрать что-то. Если вы собираетесь комментировать наш алгоритм экранирования — пожалуйста, оставьте свой адрес, чтобы я мог приехать к вам и раскрасить ваш сарай для велосипедов в синий с желтыми полосами. Спасибо!

<sup>&</sup>lt;sup>43</sup>Прим. перев.: как видно из нижеприведенного примера, в командной строке systemctl используется экранированное имя юнита, что создает определенные трудности даже при наличии в оболочке «умного» автодополнения. Однако, начиная с systemd v186, при работе с systemctl можно указывать неэкранированные имена юнитов.

Как видите, в качестве идентификатора экземпляра используется экранированная версия, в то время как в строке описания и в командной строке getty фигурирует неэкранированный вариант, как и предполагалось.

(Небольшое замечание: помимо %i и %I, существует еще несколько спецификаторов, и большинство из них доступно и в обычных файлах конфигурации юнитов, а не только в шаблонах. Подробности можно посмотреть на странице руководства, содержащей полный перечень этих спецификаторов с краткими пояснениями.)

# 11 Службы с активацией в стиле inetd

В одной из предыдущих глав (гл. 3) я рассказывал, как можно преобразовать SysV init-скрипт в юнит-файл systemd. В этой главе мы рассмотрим, как провести аналогичное преобразование для служб inetd.

Начнем с небольшого экскурса в историю вопроса. Уже многие годы inetd считается одной из базовых служб Unix-систем. Работая как суперсервер, он слушает сетевые сокеты от имени различных служб, и активирует соответствующие службы при поступлении на эти сокеты входящих соединений. Таким образом, он обеспечивает механизм активации по запросу (on-demand activation). Подобный подход избавляет от необходимости держать постоянно работающими все серверные процессы, что позволяет поддерживать множество служб даже на системах с очень ограниченными ресурсами. В дистрибутивах Linux можно встретить несколько различных реализаций inetd. Наиболее популярные из них — BSD inetd и xinetd. Хотя inetd во многих дистрибутивах до сих пор устанавливается по умолчанию, сейчас он уже редко используется для запуска сетевых служб — теперь большинство из них запускаются автономно при загрузке системы (основной аргумент в пользу такой схемы — она позволяет обеспечить более высокую производительность служб).

Одной из ключевых возможностей systemd (а также launchd от Apple) является сокет-активация — тот же самый механизм, давным-давно реализованный inetd, однако в данном случае ключевые цели немного другие. Сокет-активация в стиле systemd прежде всего ориентирована на локальные сокеты (AF\_UNIX), хотя поддерживаются также и сетевые сокеты (AF\_INET). И более важное отличие — сокет-активация в systemd обеспечивает не только экономию системных ресурсов, но также и эффективную параллелизацию работы (так как она позволяет запускать клиентские и серверные процессы одновременно, непосредственно после создания сокета), упрощение процесса конфигурации (отпадает необходимость явно указывать зависимости между службами) и увеличение надежности (перезапуск службы, служебный или экстренный — в случае падения — не приводит к недоступности сокета). Тем не менее, systemd ничуть не хуже inetd может запускать службы в ответ на входящие сетевые соединения.

Любая сокет-активация требует соответствующей поддержки со стороны самой запускаемой службы. systemd предоставляет очень простой интерфейс, который может быть использован службами для обеспечения сокет-активации. В основе этого простого и минималистичного механизма лежит функция sd\_listen\_fds(). Однако, интерфейс, традиционно используемый в inetd, еще проще. Он позволяет передавать запускаемой службе только один сокет, который формируется из потоков STDIN и STDOUT запущенного процесса. Поддержка этого механизма также присутствует в systemd — для обеспечения совместимости со множеством служб, у которых сокет-активация реализована только в стиле inetd.

Прежде, чем мы перейдем к примерам, рассмотрим три различных схемы, использующих сокет-активацию:

1. Сокет-активация, ориентированная на параллелизацию, упрощение и надежность: сокеты создаются на ранних стадиях загрузки, и единственный экземпляр службы тут же начинает обслуживать все поступающие запросы. Такая схема подходит для часто используемых системных служб — очевидно, что такие службы лучше запускать как можно раньше, и по возможности параллельно. В качестве примера можно привести D-Bus и Syslog.

- 2. Сокет-активация для одиночных служб: сокеты создаются на ранних стадиях загрузки, и единственный экземпляр службы запускается при получении входящих запросов. Такая схема больше подходит для редко используемых служб, позволяя обеспечить экономию системных ресурсов и уменьшить время загрузки, просто отложив активацию службы до того момента, когда она действительно понадобится. Пример CUPS.
- 3. Сокет-активация для служб, запускающих по экземпляру на каждое соединение: сокеты создаются на ранней стадии загрузки, и при каждом входящем соединении запускается экземпляр службы, которому передается сокет соединения (слушающий сокет при этом остается у суперсервера, inetd или systemd). Эта схема подходит для редко используемых служб, не критичных по производительности (каждый новый процесс занимает сравнительно немного ресурсов). Пример: SSH.

Описанные схемы отнюдь не эквивалентны с точки зрения производительности. Первая и вторая схема, после завершения запуска службы, обеспечивают точно такую же производительность, как и в случае с независимой (stand-alone) службой (т.е. службой, запущенной без использования суперсервера и сокет-активации), так как слушающий сокет передается непосредственно процессу службы, и дальнейшая обработка входящих соединений происходит точно так же, как и в независимой службе. В то же время, производительность третьей из предложенных схем порою оставляет желать лучшего: каждое входящее соединение порождает еще один процесс службы, что, при большом количестве соединений, может привести к значительному потреблению системных ресурсов. Впрочем, эта схема имеет и свои достоинства. В частности, обеспечивается эффективная изоляция обработки клиентских запросов и, кроме того, выбор такой схемы активации значительно упрощает процесс разработки службы.

В systemd наибольшее внимание уделяется первой из этих схем, однако остальные две тоже прекрасно поддерживаются. В свое время, я рассказывал, какие изменения в коде службы нужно сделать для обеспечения работы по второй схеме, на примере сервера CUPS. Что же касается inetd, то он предназначен прежде всего для работы по третьей схеме, хотя поддерживает и вторую (но не первую). Именно из-за специфики этой схемы inetd получил репутации «медленного» (что, на самом деле, немного несправедливо).

Итак, изучив теоретическую сторону вопроса, перейдем к практике и рассмотрим, как inetd-служба может быть интегрирована с механизмами сокет-активации systemd. В качестве примера возьмем SSH, известную и широко распространенную службу. На большинстве систем, где она используется, частота обращений к ней не превышает одного раза в час (как правило, она значительно меньше этой величины). SSH уже очень давно поддерживает сокет-активацию в стиле inetd, согласно третьей схеме. Так как необходимость в данной службе возникает сравнительно редко, и число одновременно работающих процессов обычно невелико, она хорошо подходит для использования по этой схеме. Перерасход системных ресурсов должен быть незначителен: большую часть времени такая служба фактически не выполняется и не тратит ресурсы. Когда ктолибо начинает сеанс удаленной работы, она запускается, и останавливается немедленно по завершении сеанса, освобождая ресурсы. Что ж, посмотрим, как в systemd можно воспользоваться режимом совместимости с inetd и обеспечить сокет-активацию SSH.

Так выглядит строка с конфигурацией службы SSH для классического inetd:

```
ssh stream tcp nowait root /usr/sbin/sshd sshd -i
```

Аналогичный фрагмент конфигурации для xinetd:

```
service ssh {
    socket_type = stream
    protocol = tcp
    wait = no
    user = root
    server = /usr/sbin/sshd
    server_args = -i
}
```

Большая часть опций интуитивно понятна, кроме того, нетрудно заметить, что оба этих текста повествуют об одном и том же. Однако, некоторые моменты не вполне очевидны. Например, номер прослушиваемого порта (22) не указывается в явном виде. Он определяется путем поиска имени службы в базе данных /etc/services. Подобный подход был некогда весьма популярен в Unix, но сейчас он уже постепенно выходит из моды, и поэтому в современных версиях xinetd поддерживается возможность явного указания номера порта. Одна из наиболее интересных настроек названа не вполне очевидно — nowait (wait=no). Она определяет, будет ли служба работать по второй (wait) или третьей (nowait) схеме. И наконец, ключ -i активирует inetd-режим в SSH-сервере (без этого ключа он работает в независимом режиме).

Ha языке systemd эти фрагменты конфигурации превращаются в два файла. Первый из них, sshd.socket, содержит информацию о прослушиваемом сокете:

```
[Unit]
Description=SSH Socket for Per-Connection Servers

[Socket]
ListenStream=22
Accept=yes

[Install]
WantedBy=sockets.target
```

Смысл большинства опций вполне очевиден. Сделаю лишь пару замечаний. Accept=yes соответствует режиму nowait. Надеюсь, предложенное мною название более точно отражает смысл опции — в режиме nowait суперсвервер сам вызывает accept() для слушающего сокета, в то время как в режиме wait эта работа ложится на процесс службы. Опция WantedBy=sockets.target обеспечивает активацию данного юнита в нужный момент при загрузке системы.

Второй из этих файлов — sshd@.service:

```
[Unit]
Description=SSH Per-Connection Server

[Service]
ExecStart=-/usr/sbin/sshd -i
StandardInput=socket
```

Большинство представленных здесь опций, как всегда, понятны интуитивно. Особое внимание стоит обратить лишь на строчку StandardInput=socket, которая, собственно, и включает для данной службы режим совместимости с inetd-активацией. Опция StandardInput= позволяет указать, куда будет подключен поток STDIN процесса данной службы (подробности см. на странице руководства). Задав для нее значение socket, мы обеспечиваем подключение этого потока к сокету соединения, как того и требует механизм inetd-активации. Заметим, что явно указывать опцию StandardOutput= в данном случае необязательно — она автоматически устанавливается в то же значение, что и StandardInput, если явно не указано что-то другое. Кроме того, можно отметить наличие «-» перед именем бинарного файла sshd. Таким образом мы указываем systemd игнорировать код выхода процесса sshd. По умолчанию, systemd сохраняет коды выхода для всех экземпляров службы, завершившихся с ошибкой (сбросить эту информацию можно командой systemctl reset-failed). SSH довольно часто завершается с ненулевым кодом выхода, и мы разрешаем systemd не регистрировать подобные «ошибки».

Служба sshd@.service предназначена для работы в виде независимых экземпляров (такие службы мы рассматривали в предыдущей главе 10). Для каждого входящего соединения systemd будет создавать свой экземпляр этой службы, причем идентификатор экземпляра формируется на основе реквизитов соединения.

Быть может, вы спросите: почему для настройки inetd-службы в systemd требуется два файла конфигурации, а не один? Отвечаем: чтобы избежать излишнего усложнения, мы обеспечиваем максимально прозрачную связь между работающими юнитами и

соответствующими им юнит-файлами. Такой подход позволяет независимо оперировать юнитом сокета и юнитами соответствующих служб при формировании графа зависимостей и при управлении юнитами. В частности, вы можете остановить (удалить) сокет, не затрагивая уже работающие экземпляры соответствующей службы, или остановить любой из этих экземпляров, не трогая другие экземпляры и сам сокет.

Посмотрим, как наш пример будет работать. После того, как мы поместим оба предложенных выше файла в каталог /etc/systemd/system, мы сможем включить сокет (то есть, обеспечить его активацию при каждой нормальной загрузке) и запустить его (то есть активировать в текущем сеансе работы):

Итак, наш сокет уже прослушивается, но входящих соединений на него пока не поступало (счетчик Accepted: показывает количество принятых соединений с момента создания сокета, счетчик Connected: — количество активных соединений на текущий момент).

Подключимся к нашему серверу с двух разных хостов, и посмотрим на список служб:

```
$ systemctl --full | grep ssh
sshd@172.31.0.52:22-172.31.0.4:47779.service loaded active running
sshd@172.31.0.52:22-172.31.0.54:52985.service loaded active running
sshd.socket loaded active listening
SSH Per-Connection Server
SSH Socket for Per-Connection Server
```

Как и следовало ожидать, работают два экземпляра нашей службы, по одному на соединение, и их в названиях указаны IP-адреса и TCP-порты источника и получателя. (Заметим, что в случае с локальными сокетами типа AF\_UNIX там были бы указаны идентификаторы процесса и пользователя, соответствующие подключенному клиенту.) Таким образом, мы можем независимо выслеживать и убивать отдельные экземпляры sshd (например, если нам нужно прервать конкретный удаленный сеанс):

```
# systemctl kill sshd@172.31.0.52:22-172.31.0.4:47779.service
```

Вот, пожалуй, и все, что вам нужно знать о портировании inetd-служб в systemd и дальнейшем их использовании.

Применительно к SSH, в большинстве случаев схема с inetd-активацией позволяет сэкономить системные ресурсы и поэтому оказывается более эффективным решением, чем использование обычного service-файла sshd, обеспечивающего запуск одиночной службы без использования сокет-активации (поставляется в составе пакета и может быть включен при необходимости). В ближайшее время я собираюсь направить соответствующий запрос относительно нашего пакета SSH в багтрекер Fedora.

В завершение нашей дискуссии, сравним возможности xinetd и systemd, и выясним, может ли systemd полностью заменить xinetd, или нет. Вкратце: systemd поддерживает далеко не все возможности xinetd и поэтому отнюдь не является его полноценной заменой на все случаи жизни. В частности, если вы заглянете в список параметров конфигурации xinetd, вы заметите, что далеко не все эти опции доступны в systemd. Например, в systemd нет и никогда не будет встроенных служб есho, time, daytime, discard и т.д. Кроме того, systemd не поддерживает TCPMUX и RPC. Впрочем, большая часть этих опций уже не актуальна в наше время. Подавляющее большинство inetd-служб не используют эти опции (в частности, ни одна из имеющихся в Fedora xinetd-служб не требует поддержки перечисленных опций). Стоит отметить, что xinetd имеет некоторые интересные возможности, отсутствующие в systemd, например, списки контроля

доступа для IP-адресов (IP ACL). Однако, большинство администраторов, скорее всего, согласятся, что настройка брандмауэра является более эффективным решением подобных задач<sup>44</sup>, а для ценителей устаревших технологий systemd предлагает поддержку tcpwrap. С другой стороны, systemd тоже предоставляет ряд возможностей, отсутствующих в xinetd, в частности, индивидуальный контроль над каждым экземпляром службы (см. выше), и внушительный набор настроек для контроля окружения, в котором запускаются экземпляры. Я надеюсь, что возможностей systemd должно быть достаточно для решения большинства задач, а в тех редких случаях, когда вам потребуются специфические опции xinetd — ничто не мешает вам запустить его в дополнение к systemd. Таким образом, уже сейчас в большинстве случаев xinetd можно выкинуть из числа обязательных системных компонентов. Можно сказать, что systemd не просто возвращает функциональность классического юниксового inetd, но еще и восстанавливает ее ключевую роль в Linux-системах.

Теперь, вооруженные этими знаниями, вы можете портировать свои службы с inetd на systemd. Но, конечно, будет лучше, если этим займутся разработчики из апстрима приложения, или сопровождающие вашего дистрибутива.

# 12 К вопросу о безопасности

Одно из важнейших достоинств Unix-систем — концепция разделения привилегий между различными компонентами ОС. В частности, службы обычно работают от имени специальных системных пользователей, имеющих ограниченные полномочия, что позволяет уменьшить ущерб для системы в случае взлома этих служб.

Однако, такой подход предоставляет лишь самую минимальную защиту, так как системные службы, хотя уже и не получают полномочий администратора (root), все равно имеют практически те же права, что и обычные пользователи. Чтобы обеспечить более эффективную защиту, нужно поставить более жесткие ограничения, отняв у служб некоторые привилегии, присущие обычным пользователям.

Такая возможность предоставляется системами мандатного контроля доступа (далее MAC, от Mandatory Access Control), например, SELinux. Если вам нужно обеспечить высокий уровень безопасности на своем сервере, то вам определенно стоит обратить свое внимание на SELinux. Что же касается systemd, то он предоставляет разработчикам и администраторам целый арсенал возможностей по ограничению локальных служб, и эти механизмы работают независимо от систем MAC. Таким образом, вне зависимости от того, смогли ли вы разобраться с SELinux — у вас появляется еще несколько инструментов, позволяющих повысить уровень безопасности.

В этой главе мы рассмотрим несколько таких опций, предоставляемых systemd, и обсудим вопросы их практического применения. Реализация этих опций основана на использовании ряда уникальных технологий безопасности, интегрированных в ядро Linux уже очень давно, но при этом практически неизвестных для большинства разработчиков. Мы постарались сделать соответствующие опции systemd максимально простыми в использовании, чтобы заинтересовать администраторов и апстримных разработчиков. Вот краткий перечень наиболее интересных возможностей 45:

#### • Изолирование служб от сети

<sup>&</sup>lt;sup>44</sup>Прим. перев.: Стоит отметить, что приведенный пример является не единственным случаем, когда возможности брандмауэра Linux дублируются опциями xinetd. Например, количество соединений с каждого хоста может быть ограничено критерием connlimit, а скорость поступления входящих соединений можно контролировать сочетанием критериев limit и conntrack (ctstate NEW). Критерий recent позволяет создать аналог простейшей IDS/IPS, реализованной механизмом SENSORS в xinetd. Кроме того, в ряде случаев возможности брандмауэра значительно превосходят функциональность xinetd. Например, критерий hashlimit, опять-таки в сочетании с conntrack, позволяет ограничить скорость поступления входящих соединений с каждого хоста (не путать с критерием connlimit, ограничивающим количество одновременно открытых соединений). Также стоит отметить, что интегрированная в Linux подсистема ірѕеt гораздо лучше подходит для работы с большими списками разрешенных/запрещенных адресов, нежели встроенные механизмы xinetd.

<sup>&</sup>lt;sup>45</sup>Прим. перев.: В приведенном здесь списке не упомянута встроенная в systemd поддержка фильтров seccomp (опция SystemCallFilter=), так как она была добавлена уже после написания исходной статьи, в выпуске systemd 187.

- Предоставление службам независимых каталогов /tmp
- Ограничение доступа служб к отдельным каталогам
- Принудительное отключение полномочий (capabilities) для служб
- Запрет форка, ограничение на создание файлов
- Контроль доступа служб к файлам устройств

Все эти опции описаны в man-страницах systemd, главным образом, в  $\operatorname{systemd.exec}(5)^{46}$ . Если вам потребуется дополнительная информация, вы можете обратиться к ним.

Все эти опции доступны на системах с systemd, вне зависимости от использования SELinux или любой другой реализации MAC.

Все эти опции не так уж и обременительны, и поэтому их разумнее будет использовать даже в тех случаях, когда явная необходимость в них, казалось бы, отсутствует. Например: даже если вы полагаете, что ваша служба никогда не пишет в каталог /tmp, и поэтому использование PrivateTmp=yes (см. ниже) вроде бы и не обязательно — лучше включить эту опцию, просто потому, что вы не можете знать наверняка, как будут вести себя используемые вами сторонние библиотеки (и плагины для них). В частности, вы никогда не узнаете, какие модули NSS могут быть включены в каждой конкретной системе, и пользуются ли они каталогом /tmp.

Мы надеемся, что перечисленные опции окажутся полезными как для администраторов, защищающих свои системы, так и для апстримных разработчиков, желающих сделать свои службы безопасными «из коробки». Мы настоятельно рекомендуем разработчикам использовать такие опции по умолчанию в апстримных service-файлах — это сравнительно несложно, но дает значительные преимущества в плане безопасности.

# 12.1 Изолирование служб от сети

Простая, но мощная опция, которой вы можете воспользоваться при настройке службы — PrivateNetwork=:

```
...
[Service]
ExecStart=...
PrivateNetwork=yes
...
```

Добавление этой строчки обеспечивает полную изоляцию от сети всех процессов данной службы. Они будут видеть лишь интерфейс обратной петли (10), причем полностью изолированный от обратной петли основной системы. Чрезвычайно эффективная защита против сетевых атак.

Предупреждение: Некоторым службам сеть необходима для нормальной работы. Разумеется, никто и не говорит о том, чтобы применять PrivateNetwork=yes к сетевым службам, таким, как Арасhe. Однако даже те службы, которые не ориентированы на сетевое взаимодействие, могут нуждаться в сети для нормального функционирования, и порой эта потребность не вполне очевидна. Например, если ваша система хранит учетные записи пользователей в базе LDAP, для выполнения системных вызовов наподобие getpwnam() может потребоваться обращение к сети. Впрочем, даже в такой ситуации, как правило, можно использовать PrivateNetwork=yes, за исключением случаев, когда службе может потребоваться информация о пользователях с UID ≥ 1000.

Если вас интересуют технические подробности: эта возможность реализована с использованием технологии сетевых пространств имен (network namespaces). При задействовании данной опции, для службы создается новое пространство имен, в котором настраивается только интерфейс обратной петли.

 $<sup>^{46}</sup>$ Прим. перев.: Начиная с systemd версии 206, значительная часть обсуждаемых здесь настроек вынесена на отдельную страницу systemd.cgroup(5). Начиная с systemd 208, эта страница переименована в systemd.resource-control(5).

# 12.2 Предоставление службам независимых каталогов /tmp

Еще одна простая, но мощная опция настройки служб — PrivateTmp=:

```
[Service]
ExecStart=...
PrivateTmp=yes
```

При задействовании этой опции, служба получит свой собственный каталог /tmp, полностью изолированный от общесистемного /tmp. По давно сложившейся традиции, в Unix-системах каталог /tmp является общедоступным для всех локальных служб и пользователей. За все эти годы, он стал источником огромного количества проблем безопасности. Чаще всего встречаются атаки с использованием символьных ссылок (symlink attacks) и атаки на отказ в обслуживании (DoS attacks). Использование независимой версии данного каталога для каждой службы делает подобные уязвимости практически бесполезными.

Для релиза Fedora 17 утверждена инициатива, направленная на включение этой опции по умолчанию для большинства системных служб.

Предупреждение: Некоторые службы используют /tmp не по назначению, помещая туда сокеты IPC и другие подобные элементы, что само по себе уже является уязвимостью (хотя бы потому, что используемые при передаче информации файлы и каталоги должны иметь предсказуемые имена, что делает подобные службы уязвимыми к атакам через символьные ссылки и атакам на отказ в обслуживании). Подобные объекты лучше помещать в каталог /run, так как в нем присутствует строгое разделение доступа. В качестве примера такого некорректного использования /tmp можно привести X11, размещающий там свои коммуникационные сокеты (впрочем, в данном конкретном случае некоторые меры безопасности все же присутствуют: сокеты размещаются в защищенном подкаталоге, который создается на ранних стадиях загрузки). Разумеется, для служб, использующих /tmp в целях коммуникации, включение опции PrivateTmp=yes недопустимо. К счастью, подобных служб сейчас уже не так уж и много<sup>47</sup>.

Эта опция использует технологию пространств имен файловых систем (filesystem namespaces), реализованную в Linux. При включении данной опции, для службы создается новое пространство имен, отличающееся от иерархии каталогов основной системы только каталогом /tmp.

# 12.3 Ограничение доступа служб к отдельным каталогам

Используя опции ReadOnlyDirectories= и InaccessibleDirectories=, вы можете ограничить доступ службы к указанным каталогам только чтением, либо вообще запретить его:

```
[Service]
ExecStart=...
InaccessibleDirectories=/home
ReadOnlyDirectories=/var
...
```

Добавление этих двух строчек в файл конфигурации приводит к тому, что служба полностью утрачивает доступ к содержимому каталога /home (она видит лишь пустой каталог с правами доступа 000), а также не может писать внутрь каталога /var.

 $<sup>^{47}</sup>$ Прим. перев.: Начиная с systemd 209, поддерживается опция JoinsNamespaceOf= (секция [Unit]), позволяющая поместить два и более юнитов в одну «песочницу» (пространство имен), в результате чего такие юниты смогут взаимодействовать между собой, как через сетевой интерфейс обратной петли, так и через файлы в каталоге /tmp, при этом оставаясь изолированными от остальной системы. Подробности можно уточнить на странице руководства systemd.unit(5).

Предупреждение: К сожалению, в настоящее время опция ReadOnlyDirectories не применяется рекурсивно к точкам монтирования, расположенным в поддереве указанного каталога (т.е. файловые системы, смонтированные в подкаталогах /var, попрежнему останутся доступными на запись, если, конечно, не перечислить их все поименно). Мы собираемся исправить это в ближайшее время.

Механизм работы этой опции тоже реализован с использованием пространств имен файловых систем.

# 12.4 Принудительное отключение полномочий (capabilities) для служб

Еще одна чрезвычайно эффективная опция — CapabilityBoundingSet=, позволяющая контролировать список capabilities, которые смогут получить процессы службы:

```
...
[Service]
ExecStart=...
CapabilityBoundingSet=CAP_CHOWN CAP_KILL
...
```

В нашем примере, служба может иметь лишь полномочия CAP\_CHOWN и CAP\_KILL. Попытки какого-либо из процессов службы получить любые другие полномочия, даже с использованием suid-бинарников, будут пресекаться. Список возможных полномочий приведен на странице документации capabilities(7). К сожалению, некоторые из них являются слишком общими (разрешают очень многое), например, CAP\_SYS\_ADMIN, однако выборочное делегирование полномочий все же является неплохой альтернативой запуску службы с полными административными (рутовыми) привилегиями.

Как правило, определение списка полномочий, необходимых для работы конкретной службы, является довольно трудоемким процессом, требующим ряда проверок. Чтобы немного упростить эту задачу, мы добавили возможность создания «черного списка» привилегий, как альтернативы описанному выше механизму «белого списка». Вместо того, чтобы указывать, какие привилегии можно оставить, вы можете перечислить, какие из них оставлять точно нельзя. Например: привилегия CAP\_SYS\_PTRACE, предназначенная для отладчиков, дает очень широкие полномочия в отношении всех процессов системы. Очевидно, что такие службы, как Арасће, не занимаются отладкой чужих процессов, и поэтому мы можем спокойно отнять у них данную привилегию:

```
[Service]
ExecStart=...
CapabilityBoundingSet=~CAP_SYS_PTRACE
```

Наличие символа ~ после знака равенства инвертирует принцип работы опции: следующий за ним перечень привилегий рассматривается уже не как белый, а как черный список.

**Предупреждение:** Некоторые службы, при отсутствии определенных привилегий, могут вести себя некорректно. Как уже говорилось выше, формирование списка необходимых полномочий для каждой конкретной службы может оказаться довольно трудной задачей, и лучше всего будет обратиться с соответствующим запросом к разработчикам службы.

**Предупреждение 2:** Привилегии — отнюдь не лекарство от всех бед. Чтобы они работали действительно эффективно, возможно, придется дополнить их другими методиками защиты.

Чтобы проверить, какие именно привилегии имеют сейчас ваши процессы, вы можете воспользоваться программой pscap из комплекта libcap-ng-utils.

Применение опции CapabilityBoundingSet= является простой, прозрачной и удобной альтернативой введению аналогичных ограничений через модификацию исходного кода всех системных служб.

# 12.5 Запрет форка, ограничение на создание файлов

Некоторые меры безопасности можно ввести при помощи механизма ограничения ресурсов. Как следует из его названия, этот механизм предназначен прежде всего для контроля использования ресурсов, а не для контроля доступа. Однако, две его настройки могут быть использованы для запрета определенных действий: с помощью RLIMIT\_NPROC можно запретить службе форкаться (запускать дополнительные процессы), а RLIMIT\_FSIZE позволяет блокировать запись в файлы ненулевого размера:

```
[Service]
ExecStart=...
LimitNPROC=1
LimitFSIZE=0
```

Обратите внимание, что эти ограничения будут эффективно работать только в том случае, если служба запускается от имени простого пользователя (не root) и без привилегии САР\_SYS\_RESOURCE (блокирование этой привилегии можно обеспечить, например, описанной выше опцией CapabilityBoundingSet=). В противном случае, ничто не мешает процессу поменять соответствующие ограничения.

Предупреждение: LimitFSIZE= действует очень жестко. Если процесс пытается записать файл ненулевого размера, он немедленно получает сигнал SIGXFSZ, который, как правило, прекращает работу процесса (в случае, если не назначен обработчик сигнала). Кроме того, стоит отметить, что эта опция не запрещает создание файлов нулевого размера.

Подробности об этих и других опциях ограничения ресурсов можно уточнить на странице документации  $\operatorname{setrlimit}(2)$ .

# 12.6 Контроль доступа служб к файлам устройств

Файлы устройств предоставляют приложениям интерфейс для доступа к ядру и драйверам. Причем драйверы, как правило, менее тщательно тестируются и не так аккуратно проверяются на предмет наличия уязвимостей, по сравнению с основными компонентами ядра. Именно поэтому драйверы часто становятся объектами атаки злоумышленников. systemd позволяет контролировать доступ к устройствам индивидуально для каждой службы:

```
[Service]
ExecStart=...
DeviceAllow=/dev/null rw
...
```

Приведенная конфигурация разрешит службе доступ только к файлу /dev/null, запретив доступ ко всем остальным файлам устройств.

Реализация данной опции построена на использовании cgroups-контроллера devices.

# 12.7 Прочие настройки

Помимо приведенных выше, простых и удобных в использовании опций, существует и ряд других других настроек, позволяющих повысить уровень безопасности. Но для их использования, как правило, уже требуются определенные изменения в исходном коде службы, и поэтому такие настройки представляют интерес прежде всего для апстримных разработчиков. В частности, сюда относится опция RootDirectory= (позволяющая

запустить службу chroot()-окружении), а также параметры User= и Group=, определяющие пользователя и группу, от имени которых работает служба. Использование этих опций значительно упрощает написание демонов, так как работа по понижению привилегий ложится на плечи systemd.

Возможно, у вас возникнет вопрос, почему описанные выше опции не включены по умолчанию. Отвечаем: чтобы не нарушать совместимость. Многие из них несколько отступают от традиций, принятых в Unix. Например, исторически сложилось, так что /tmp является общим для всех процессов и пользователей. Существуют программы, использующие этот каталог для IPC, и включение по умолчанию режима изоляции для /tmp нарушит работу таких программ.

И несколько слов в заключение. Если вы занимаетесь сопровождением unit-файлов в апстримном проекте или в дистрибутиве, пожалуйста, подумайте о том, чтобы воспользоваться приведенными выше настройками. Если сопровождаемая вами служба станет более защищенной в конфигурации по умолчанию («из коробки»), от этого выиграют не только ваши пользователи, но и все мы, потому что Интернет станет чуть более безопасным.

# 13 Отчет о состоянии службы и ее журнал

При работе с системами, использующими systemd, одной из наиболее важных и часто используемых команд является systemctl status. Она выводит отчет о состоянии службы (или другого юнита). В таком отчете приводится статус службы (работает она или нет), список ее процессов и другая полезная информация.

В Fedora 17 мы ввели Journal, новую реализацию системного журнала, обеспечивающую структурированное, индексированное и надежное журналирование, при сохранении совместимости с классическими реализациями syslog. Собственно, мы начали работу над Journal только потому, что хотели добавить одну, казалось бы, простую, возможность: включить в вывод systemctl status последние 10 сообщений, поступивших от службы в системный журнал. Но на практике оказалось, что в рамках классических механизмов syslog, реализация этой возможности чрезвычайно сложна и малоэффективна. С другой стороны, сообщения службы в системный журнал несут очень важную информацию о ее состоянии, и такая возможность действительно была бы очень полезной, особенно при диагностике нештатных ситуаций.

Итак, мы интегрировали Journal в systemd, и научили systemctl работать с ним. Результат выглядит примерно так:

```
$ systemctl status avahi-daemon.service
avahi-daemon.service - Avahi mDNS/DNS-SD Stack
         Loaded: loaded (/usr/lib/systemd/system/avahi-daemon.service; enabled)
         Active: active (running) since Fri, 18 May 2012 12:27:37 +0200; 14s ago
        Main PID: 8216 (avahi-daemon)
          Status: "avahi-daemon 0.6.30 starting up."
          CGroup: name=systemd:/system/avahi-daemon.service
                   8216 avahi-daemon: running [omega.local]
                  8217 avahi-daemon: chroot helper
May 18 12:27:37 omega avahi-daemon[8216]: Joining mDNS multicast group on interface eth1. IPv4 with address 1
May 18 12:27:37 omega avahi-daemon[8216]: New relevant interface eth1.IPv4 for mDNS.
May 18 12:27:37 omega avahi-daemon[8216]: Network interface enumeration completed.
May 18 12:27:37 omega avahi-daemon[8216]: Registering new address record for 192.168.122.1 on virbr0.IPv4.
May 18 12:27:37 omega avahi-daemon[8216]: Registering new address record for fd00::e269:95ff:fe87:e282 on et
May 18 12:27:37 omega avahi-daemon[8216]: Registering new address record for 172.31.0.52 on eth1.IPv4.
May 18 12:27:37 omega avahi-daemon[8216]: Registering HINFO record with values 'X86_64'/'LINUX'.
May 18 12:27:38 omega avahi-daemon[8216]: Server startup complete. Host name is omega.local. Local service of
May 18 12:27:38 omega avahi-daemon[8216]: Service "omega" (/services/ssh.service) successfully established.
```

May 18 12:27:38 omega avahi-daemon[8216]: Service "omega" (/services/sftp-ssh.service) successfully establis

Очевидно, это отчет о состоянии всеми любимого демона mDNS/DNS-SD, причем после списка процессов, как мы и обещали, приведены сообщения этого демона в системный журнал. Миссия выполнена!

Команда systemctl status поддерживает ряд опций, позволяющих настроить вывод информации в соответствии с вашими пожеланиями. Отметим две наиболее интересные из них: ключ -f позволяет в реальном времени отслеживать обновление сведений (по аналогии c tail -f), а ключ -n задает количество выводимых журнальных записей (как нетрудно догадаться, по аналогии c tail -n).

Журнальные записи собираются из трех различных источников. Во-первых, это сообщения службы в системный журнал, отправленные через функцию libc syslog(). Во-вторых, это сообщения, отправленные через штатный API системы Journal. И наконец, это весь текст, выводимый демоном в STDOUT и STDERR. Проще говоря, все, что демон считает нужным сказать администратору, собирается, упорядочивается и отображается в одинаковом формате.

Добавленная нами возможность, при всей своей простоте, может оказаться чрезвычайно полезной практически любому администратору. По-хорошему, ее стоило реализовать еще 15 лет назад.

# 14 Самодокументированный процесс загрузки

Нам часто приходится слышать жалобы, что процесс загрузки при использовании systemd очень сложен для понимания. Не могу с этим согласиться. Более того, я берусь даже утверждать обратное: по сравнению с тем, что мы имели раньше (когда для того, чтобы разобраться в загрузке, нужно было иметь хорошие навыки программирования на языке Bourne Shell<sup>48</sup>), процесс загрузки стал более простым и прозрачным. Но определенная доля истины в этом критическом замечании все же есть: даже опытному Unix-администратору при переходе на systemd нужно изучить некоторые новые для себя вещи. Мы, разработчики systemd, обязаны максимально упростить такое обучение. Решая поставленную задачу, мы подготовили для вас кое-какие приятные сюрпризы, и предоставили хорошую документацию даже там, где это казалось невозможным.

Уже сейчас systemd располагает довольно обширной документацией, включая страницы руководства (на данный момент, их около сотни), wiki-сайт проекта, а также ряд статей в моем блоге. Тем не менее, большое количество документации еще не гарантирует простоты понимания. Огромные груды руководств выглядят пугающе, и неподготовленный читатель не может разобраться, с какого места ему начинать чтение, если его интересует просто общая концепция.

Чтобы решить данную проблему, мы добавили в systemd небольшую, но очень изящную возможность: самодокументированный процесс загрузки. Что мы под этим подразумеваем? То, что для каждого элемента процесса загрузки теперь имеется документация, прозрачно привязанная к этому элементу, так что ее поиск не представляет трудности.

Иными словами, все штатные юниты systemd (которые, собственно, и формируют процесс загрузки, вызывая соответствующие программы) включают ссылки на страницы документации, описывающие назначение юнита/программы, используемые ими конфигурационные файлы и т.д. Если пользователь хочет узнать, для чего предназначен какой-либо юнит, какова его роль в процессе загрузки и как его можно настроить, может получить ссылки на соответствующую документацию, просто воспользовавшись давно известной командой systemctl status. Возьмем для примера systemd-logind.service:

```
$ systemctl status systemd-logind.service
systemd-logind.service - Login Service
Loaded: loaded (/usr/lib/systemd/system/systemd-logind.service; static)
Active: active (running) since Mon, 25 Jun 2012 22:39:24 -0200; 1 day and 18h ago
Docs: man:systemd-logind.service(7)
```

 $<sup>^{48} \</sup>mbox{Чья}$  привлекательность очень коварна и обманчива.

<sup>&</sup>lt;sup>49</sup>Прим. перев.: В оригинале использован термин «self-explanatory», который также можно перевести как «само-объясняющий», «самоочевидный».

На первый взгляд, в выводе этой команды почти ничего не изменилось. Но если вы вглядитесь повнимательнее, то заметите новое поле Docs, в котором приведены ссылки на документацию по данной службе. В нашем случае случае это два URI, ссылающихся на man-страницы, и один URL, указывающий на веб-страницу. man-страницы описывают соответственно предназначение службы и ее настройки, а веб-страница — базовые концепции, которые реализуются этой службой.

Тем, кто использует современные графические эмуляторы терминала, чтобы открыть соответствующую страницу документации, достаточно щелкнуть мышью по  $\mathrm{URI}^{50}$ . Иными словами, доступ к документации компонентов загрузки становится предельно простым: достаточно вызвать systemctl status, после чего щелкнуть по полученным ссылкам.

Если же вы используете не графический эмулятор терминала (где можно просто щелкнуть по URI), а настоящий терминал, наличие URI где-то в середине вывода systemctl status вряд ли покажется вам удобным. Чтобы упростить обращение к соответствующим страницам документации без использования мыши и копирования/вставки, мы ввели новую команду

## systemctl help systemd-logind.service

которая просто откроет в вашем терминале соответствующие man-страницы.

URI, ссылающиеся на документацию, формируются в соответствии со страницей руководства uri(7). Поддерживаются схемы http/https (URL для веб-страниц) и man/info (локальные страницы руководства).

Разумеется, добавленная нами возможность не обеспечивает полной очевидности абсолютно всего, хотя бы потому, что пользователь должен как минимум знать про команду systemctl status (а также вообще про программу systemctl и про то, что такое юнит). Но при наличии этих базовых знаний, пользователю уже не составит труда получить информацию по интересующим его вопросам.

Мы надеемся, что добавленный нами механизм для связи работающего кода и соответствующей документации станет значительным шагом к полностью прозрачному и предельно простому для понимания процессу загрузки.

Описанная функциональность частично присутствует в Fedora 17, а в полном объеме она будет представлена в Fedora 18.

В завершение, стоит отметить, что использованная нами идея не является такой уж новой: в SMF, системе инициализации Solaris, уже используется практика указания ссылок на документацию в описании службы. Однако, в Linux такой подход является принципиально новым, и systemd сейчас является наиболее документированной и прозрачной системой загрузки для данной платформы.

Если вы занимаетесь разработкой или сопровождением пакетов и создаете файл конфигурации юнита, пожалуйста, включите в него ссылки на документацию. Это

 $<sup>^{50}</sup>$ Для нормальной работы данной функции, в эмуляторе терминала должен быть исправлена эта ошибка, а в программе просмотра страниц помощи — вот эта.

очень просто: достаточно добавить в секции [Unit] поле Documentation= и перечислить в нем соответствующие URI. Подробнее об этом поле см. на странице руководства systemd.unit(5). Чем больше будет документированных юнитов, тем проще станет работа системного администратора. (В частности, я уже направил в FPC предложение внести соответствующие пожелания в нормативные документы, регулирующие подготовку пакетов для Fedora.)

Да, кстати: если вас интересует общий обзор процесса загрузки systemd, то вам стоит обратить внимание на новую страницу руководства, где представлена псевдографическая потоковая диаграмма, описывающая процесс загрузки и роль ключевых юнитов.

# 15 Сторожевые таймеры

Разрабатывая systemd, мы ориентируемся на три основных области его применения: мобильные/встраиваемые устройства, настольные системы и промышленные серверы. Мобильные и встраиваемые системы, как правило, располагают очень скромными ресурсами и вынуждены очень экономно расходовать энергию. Настольные системы уже не так сильно ограничены по мощности, хотя все же проигрывают в этом плане промышленным серверам. Но, как ни странно, существуют возможности, востребованные в обоих крайних случаях (встраиваемые системы и серверы), но не очень актуальные в промежуточной ситуации (десктопы). В частности, к ним относится поддержка сторожевых таймеров (watchdogs), как аппаратных, так и программных.

Во встраиваемых системах часто используются аппаратные сторожевые таймеры, выполняющие сброс системы, когда программа перестает отвечать (точнее, перестает периодически посылать таймеру сигнал «все в порядке»). Таким образом, обеспечивается повышение надежности системы: что бы ни случилось, система обязательно попытается привести себя в рабочее состояние. На десктопах такая функциональность практически не востребована<sup>51</sup>. С другой стороны, она весьма актуальна для высокодоступных серверных систем.

Начиная с версии 183, systemd полностью поддерживает аппаратные сторожевые таймеры (доступные через интерфейс /dev/watchdog), а также обеспечивает программный сторожевой контроль системных служб. В целом эта схема (если она задействована) работает так. systemd периодически посылает сигналы аппаратному таймеру. В том случае, если systemd или ядро зависают, аппаратный таймер, не получив очередного сигнала, автоматически перезапустит систему. Таким образом, ядро и systemd защищены от бесконечного зависания — на аппаратном уровне. В то же время, сам systemd предоставляет интерфейс, реализующий логику программных сторожевых таймеров для отдельных служб. Таким образом можно обеспечить, например, принудительный перезапуск службы в случае ее зависания. Для каждой службы можно независимо настроить частоту опроса и задать соответствующее действие. Соединив оба звена (аппаратный сторожевой таймер, контролирующий ядро и systemd, и программные сторожевые таймеры, посредством которых systemd контролирует отдельные службы), мы получаем надежную схему надзора за всеми системными компонентами.

Чтобы задействовать аппаратный таймер, достаточно задать ненулевое значение параметра RuntimeWatchdogSec= в файле /etc/systemd/system.conf. По умолчанию этот параметр равен нулю (т.е. аппаратный таймер не задействован). Установив его равным, например, «20s», мы включим аппаратный сторожевой таймер. Если в течение 20 секунд таймер не получит очередного сигнала «все в порядке», система автоматически перезагрузится. Отметим, что systemd отправляет такие сигналы с периодом, равным половине заданного интервала — в нашем случае, через каждые 10 секунд. Собственно, это все. Просто задав один параметр, вы обеспечите аппаратный контроль работоспособности systemd и ядра<sup>52</sup>.

<sup>51</sup> Тем не менее, сейчас аппаратные сторожевые таймеры все чаще появляются и в настольных системах, так как стоят они относительно дешево и доступны практически во всех современных чипсетах.

 $<sup>^{52}</sup>$ Небольшой совет: если вы занимаетесь отладкой базовых системных компонентов — не забудьте отключить сторожевой таймер. Иначе ваша система может неожиданно перезагрузиться, когда отладчик остановит процесс init и тот не может вовремя отправить сообщение таймеру.

Заметим, что с аппаратным сторожевым таймером (/dev/watchdog) должна работать только одна программа. Этой программой может быть либо systemd, либо отдельный демон сторожевого таймера (например, watchdogd) — выбор остается за вами.

Стоит упомянуть здесь еще одну опцию из файла /etc/systemd/system.conf — ShutdownWatchdogSec=. Она позволяет настроить аппаратный сторожевой таймер для контроля процесса перезагрузки. По умолчанию она равна «10min». Если в процессе остановки системы перед перезагрузкой она зависнет, аппаратный таймер принудительно перезагрузит ее по истечении данного интервала.

Это все, что я хотел сказать об аппаратных таймерах. Двух вышеописанных опций должно быть вполне достаточно для полноценного использования их возможностей. А сейчас мы рассмотрим логику программных сторожевых таймеров, обеспечивающих контроль работоспособности отдельных служб.

Прежде всего отметим, что для полноценной поддержки сторожевого контроля, программа должна содержать специальный код, периодически отправляющий таймеру сигналы «все в порядке». Добавить поддержку такой функциональности довольно просто. Для начала, демон должен проверить переменную окружения WATCHDOG\_USEC=. Если она определена, то ее значение задает контрольный интервал в микросекундах, сформатированный в виде текстовой (ASCII) строки. В этом случае демон должен регулярно выполнять вызов sd\_notify("WATCHDOG=1") с периодом, равным половине указанного интервала. Таким образом, поддержка программного сторожевого контроля со стороны демона сводится к проверке значения переменной окружения, и выполнении определенных действий в соответствии с этим значением.

Если интересующая вас служба обеспечивает поддержку такой функциональности, вы можете включить для нее сторожевой контроль, задав опцию WatchdogSec= в ее юнит-файле. Эта опция задает период работы таймера (подробнее см. systemd.service(5)). Если вы зададите ее, то systemd при запуске службы передаст ей соответствующее значение WATCHDOG\_USEC= и, если служба перестанет своевременно отправлять сигналы «все в порядке», присвоит ей статус сбойной (failure state).

Очевидно, что одного только присвоения статуса недостаточно для обеспечения надежной работы системы. Поэтому нам также пригодятся настройки, определяющие, нужно ли перезапускать зависшую службу, количество попыток перезапуска, и дальнейшие действия, если она все равно продолжает сбоить. Чтобы включить автоматический перезапуск службы при сбое, нужно задать опцию Restart=on-failure в ее юнитфайле. Чтобы настроить, сколько раз systemd будет пытаться перезапустить службу, воспользуйтесь настройками StartLimitBurst= StartLimitInterval= (первая из них определяет предельное количество попыток, вторая — интервал времени, в течение которого они подсчитываются). В том случае, если достигнут предел количества попыток за указанное время, выполняется действие, заданное параметром StartLimitAction=. По умолчанию он установлен в none (никаких дополнительных действий не будет, службу просто оставят в покое со статусом сбойной). В качестве альтернативы можно указать одно из трех специальных действий: reboot, reboot-force и reboot-immediate. reboot соответствует обычной перезагрузке системы, с выполнением всех сопутствующих процедур (корректное завершение всех служб, отмонтирование файловых систем и т.д.). reboot-force действует более грубо — даже не пытаясь корректно остановить службы, оно просто убивает все их процессы, отмонтирует файловые системы и выполняет принудительную перезагрузку (в результате, перезагрузка происходит быстрее, чем обычно, но файловые системы остаются неповрежденными). И наконец, reboot-immediate даже не пытается отдать дань вежливости (убить процессы и отмонтировать файловые системы) — оно немедленно выполняет жесткую перезагрузку системы (это поведение практически аналогично срабатыванию аппаратного сторожевого таймера). Все перечисленный настройки подробно описаны на странице руководства systemd.service(5))<sup>53</sup>.

<sup>&</sup>lt;sup>53</sup>Прим. перев.: Автор упускает из виду одну полезную опцию, непосредственно относящуюся к обсуждаемому вопросу — 0nFailure=, задающую юнит, который будет активирован в случае сбоя исходного юнита. Таким образом можно обеспечить, например, запуск скриптов, отправляющих администратору уведомление о сбое в сочетании с дополнительной информацией (для сбора которой целесообразно задействовать команды systemctl status и journalctl). Кроме того, комбинирование данной настрой-

Таким образом, мы мы получаем гибкий механизм для настройки сторожевого контроля служб, их перезапуска при зависании, и реагирования в ситуации, когда перезапуск не помогает.

Рассмотрим применение этих настроек на простом примере:

[Unit]

Description=My Little Daemon
Documentation=man:mylittled(8)

[Service]
ExecStart=/usr/bin/mylittled
WatchdogSec=30s
Restart=on-failure
StartLimitInterval=5min
StartLimitBurst=4
StartLimitAction=reboot-force

Данная служба будет автоматически перезапущена, если она не передаст системному менеджеру очередной сигнал «все в порядке» в течение 30 секунд после предыдущего (кроме того, перезапуск будет произведен и в случае любого другого сбоя, например, завершения основного процесса службы с ненулевым кодом выхода). Если потребуется более 4 перезапусков службы за 5 минут — будет предпринято специальное действие, в данном случае, быстрая перезагрузка системы с корректным отмонтированием файловых систем.

Это все, что я хотел рассказать о сторожевых таймерах в systemd. Мы надеемся, что поддержки аппаратного отслеживания работоспособности процесса init, в сочетании с контролем функционирования отдельных служб, должно быть достаточно для решения большинства задач, связанных со сторожевыми таймерами. Разрабатываете ли вы встраиваемую либо мобильную систему, или работаете с высокодоступными серверами — вам определенно стоит попробовать наши решения!

(И да, если у вас возникнет вопрос, почему с аппаратным таймером должен работать именно init, и что мешает вынести эту логику в отдельный демон — пожалуйста, перечитайте эту главу еще раз, и попытайтесь увидеть всю цепочку сторожевого контроля как единое целое: аппаратный таймер надзирает за работой systemd, а тот, в свою очередь, следит за отдельными службами. Кроме того, мы полагаем, что отсутствие своевременного ответа от службы нужно рассматривать и обрабатывать так же, как и любые другие ее сбои. И наконец, взаимодействие с /dev/watchdog — одна из самых тривиальных задач в работе ОС (обычно, она сводится к простому вызову ioctl()), и для ее решения достаточно нескольких строк кода. С другой стороны, вынос данной функции в отдельный демон потребует организации сложного межпроцессного взаимодействия между этим демоном и процессом init — очевидно, реализация такой схемы предоставит значительно больший простор для ошибок, не говоря уже о повышенном потреблении ресурсов.)

Отметим, что встроенная в systemd поддержка аппаратного сторожевого таймера в конфигурации по умолчанию отключена, и поэтому никак не мешает работе с этим таймером из других программ. Вы без лишних проблем можете выбрать внешний сторожевой демон, если он лучше подходит для вашей задачи.

Да, и еще: если у вас возникнет вопрос, имеется ли в вашей системе аппаратный таймер — скорее всего да, если ваш компьютер не очень старый. Чтобы получить точный ответ, вы можете воспользоваться утилитой wdctl, включенной в последний релиз utillinux  $^{54}$ . Эта программа выведет всю необходимую информацию о вашем аппаратном сторожевом таймере.

И в завершение, я хотел бы поблагодарить ребят из Pengutronix, которым приндалежит основная заслуга реализации сторожевого контроля в systemd.

ки с опцией OnFailureIsolate= позволяет при сбое юнита перевести систему в определенное состояние (например, остановить некоторые службы, перейти в режим восстановления, выполнить перезагрузку).

 $<sup>^{54}</sup>$ Прим. перев.: Утилита wdctl присутствует в util-linux, начиная с версии 2.22, которая, на момент написания этих строк, еще не вышла.

# 16 Запуск getty на последовательных (и не только) консолях

Eсли вам лень читать всю статью целиком: для запуска getty на последовательной консоли достаточно указать в загрузчике параметр ядра console=ttyS0, и systemd автоматически запустит getty на этом терминале.

Физический последовательный порт RS-232, хотя уже и стал редкостью на современных настольных компьютерах, тем не менее, продолжает играть важную роль как на серверах, так и во встраиваемых системах. Он предоставляет простой и надежный доступ к управлению системой, даже когда сеть упала, а основной интерфейс управления завис. Кроме того, эмуляция последовательной консоли часто используется при управлении виртуальными машинами.

Разумеется, в Linux уже давно реализована поддержка работы с последовательными консолями но, при разработке systemd, мы постарались сделать работу с ними еще проще. В этой статье я хочу рассказать о том, как в systemd реализован запуск getty на терминалах различных типов.

Для начала, хотелось бы отметить один важный момент: в большинстве случаев, чтобы получить приглашение к логину на последовательном терминале, вам не нужно совершать никаких дополнительных действий: systemd сам проверит настройки ядра, определит их них используемую ядром консоль, и автоматически запустит на ней getty. Таким образом, вам достаточно лишь правильно указать ядру соответствующую консоль (например, добавив к параметрам ядра в загрузчик console=ttyS0).

Тем не менее, для общего образования все же стоит рассмотреть некоторые тонкости запуска getty в systemd. Эта задача решается двумя шаблонами юнитов $^{56}$ :

- getty@.service отвечает за виртуальные консоли (virtual terminals, VT, известные в системе под именами /dev/tty1, /dev/tty2 и т.д.) те, которые вы можете увидеть безо всякого дополнительного оборудования, просто переключившись на них из графического сеанса.
- serial-getty@.service обеспечивает поддержку всех прочих разновидностей терминалов, в том числе, подключаемых к последовательным портам (/dev/ttyS0 и т.д.). Этот шаблон имеет ряд отличий от getty@.service, в частности, переменная \$TERM в нем устанавливается в значение vt102 (должно хорошо работать на большинстве физических терминалов), а не linux (которое работает правильно только на виртуальных консолях), а также пропущены настройки, касающиеся очистки буфера прокрутки (и поэтому имеющие смысл только на VT).

## 16.1 Виртуальные консоли

Рассмотрим механизм запуска getty@.service, обеспечивающий появление приглашений логина на виртуальных консолях (последовательны терминалы пока оставим в покое). По устоявшейся традиции, init-системы Linux обычно настраивались на запуск фиксированного числа экземпляров getty, как правило, шести (на первых шести виртуальных консолях, с tty1 по tty6).

В systemd мы сделали этот процесс более динамичным: чтобы добиться большей скорости и эффективности, мы запускаем дополнительные экземпляры getty только при необходимости. Например, getty@tty2.service стартует только после того, как вы переключитесь на вторую виртуальную консоль. Отказавшись от обязательного запуска нескольких экземпляров getty, мы сэкономили немного системных ресурсов, а также

<sup>&</sup>lt;sup>55</sup>Прим. перев.: Здесь и в дальнейшем автор использует термин «serial console». Точный перевод этого выражения на русский язык звучит как «консоль, подключаемая к последовательному порту». Однако, для краткости изложения, при переводе используется не вполне корректный, но хорошо знакомый администраторам жаргонизм «последовательная консоль». Также отметим, что в данном документе термины «консоль» и «терминал» используются как синонимы.

 $<sup>^{56}</sup>$ Прим. перев.: Принципы работы с шаблонами и экземплярами служб изложены в главе 10. Для лучшего понимания нижеприведенного материала, рекомендуется перечитать эту главу, если вы успели ее подзабыть.

сделали загрузку системы чуть-чуть быстрее. При этом, с точки зрения пользователя, все осталось так же просто: как только он переключается на виртуальную консоль, на ней запускается getty, которая выводит приглашение к логину. Пользователь может и не подозревать о том, что до момента переключения приглашения не было. Тем не менее, если он войдет в систему и выполнит команду ps, он увидит, что getty запущены только на тех консолях, на которых он уже побывал.

По умолчанию, автоматический запуск getty производится на виртуальных консолях с первой по шестую (чтобы свести к минимуму отличия от привычной конфигурации)<sup>57</sup>. Отметим, что автоматический запуск getty на конкретной консоли производится только при условии, что эта консоль не занята другой программой. В частности, при интенсивном использовании механизма быстрого переключения пользователей графические сеансы могут занять первые несколько консолей (чтобы такое поведение не заблокировало возможность запуска getty, мы предусмотрели специальную защиту, см. чуть ниже).

Две консоли играют особую роль: tty1 и tty6. tty1, при загрузке в графическом режиме, используется для запуска дисплейного менеджера, а при загрузке в многопользовательском текстовом режиме, systemd принудительно запускает на ней экземпляр getty, не дожидаясь переключений  $^{58}$ .

Что касается tty6, то она используется исключительно для автоматического запуска getty, и недоступна другим подсистемам, в частности, графическому серверу<sup>59</sup>. Мы сделали так специально, чтобы гарантировать возможность входа в систему в текстовом режиме, даже если графический сервер займет более пяти консолей.

## 16.2 Последовательные консоли

Работа с последовательными консолями (и всеми остальными видами невиртуальных консолей) реализована несколько иначе, чем с VT. По умолчанию, systemd запускает один экземпляр serial-getty@.service на основной консоли ядра 60 (если она не является виртуальной). Консолью ядра — это та консоль, на которую выводятся сообщения ядра. Обычно она настраивается в загрузчике, путем добавления к параметрам ядра аргумента наподобие console=ttyS061. Таким образом, если пользователь перенаправил вывод ядра на последовательную консоль, то по завершении загрузки он увидит на этой консоли приглашение для логина62. Кроме того, systemd выполняет поиск консолей, предоставляемых системами виртуализации, и запускает serial-getty@.service на первой из этих консолей (/dev/hvc0, /dev/xvc0 или /dev/hvsi0). Такое поведение реализовано специальной программой-генератором — systemd-getty-generator. Генераторы запускаются в самом начале загрузки и автоматически настраивают различные службы в зависимости от соответствующих факторов.

В большинстве случаев, вышеописанного механизма автоматической настройки должно быть достаточно, чтобы получить приглашение логина там, где нужно — без каких-либо дополнительных настроек systemd. Тем не менее, иногда возникает необходимость в ручной настройке — например, когда необходимо запустить getty сразу на нескольких последовательных консолях, или когда вывод сообщений ядра направляется на один терминал, а управление производится с другого. Для решения таких задач

 $<sup>^{57}</sup>$ Тем не менее, это поведение можно легко изменить, задавая параметр NAutoVTs= в файле logind.conf.  $^{58}$ В данном случае нет принципиальной разницы между принудительным запуском и запуском по запросу: первая консоль используется по умолчанию, так что запрос на ее активацию обязательно поступит.

 $<sup>^{59}</sup>$  При необходимости, вы можете легко поменять номер резервируемой консоли (или отключить резервирование), используя параметр ReserveVT= в файле logind.conf.

 $<sup>^{60}</sup>$ Если для ядра настроен вывод в несколько консолей, *основной* считается та, которая идет *первой* в /sys/class/tty/console/active, т.е. указана *последней* в строке параметров ядра.

 $<sup>^{61}</sup>$  Подробнее об этой опции см. в файле kernel-parameters.txt.

 $<sup>^{62}</sup>$ Отметим, что getty, а точнее, **agetty** на такой консоли вызывается с параметром -s, и поэтому не изменяет настроек символьной скорости (baud rate) — сохраняется то значение, которое было указано в строке параметров ядра.

достаточно определить по экземпляру serial-getty@.service для каждого последовательного порта, на котором вы хотите запустить getty<sup>6364</sup>:

```
# systemctl enable serial-getty@ttyS2.service
# systemctl start serial-getty@ttyS2.service
```

После выполнения этих команд, getty будет принудительно запускаться для указанных последовательных портов при всех последующих загрузках.

В некоторых ситуациях может возникнуть необходимость в тонкой настройке параметров getty (например, заданная для вывода сообщений ядра символьная скорость непригодна для интерактивного ceanca). Тогда просто скопируйте штатный шаблон юнита в каталог /etc/systemd/system и отредактируйте полученную копию:

```
# cp /usr/lib/systemd/system/serial-getty@.service /etc/systemd/system/serial-getty@ttyS2.service

# vi /etc/systemd/system/serial-getty@ttyS2.service

... редактируем параметры запуска agetty ...

# ln -s /etc/systemd/system/serial-getty@ttyS2.service /etc/systemd/system/getty.target.wants/

# systemctl daemon-reload

# systemctl start serial-getty@ttyS2.service
```

В приведенном примере создает файл настроек, определяющий запуск getty на порту ttyS2 (это определяется именем, под которым мы скопировали файл — serial-getty@ttyS2.service). Все изменения настроек, сделанные в данном файле, будут распространяться только на этот порт.

Собственно, это все, что я хотел рассказать о последовательных портах, виртуальных консолях и запуске getty на них. Надеюсь, рассказ получился интересным.

# 17 Работа с Journal

В свое время, я уже рассказывал о некоторых возможностях journal (см. главу 13), доступных из утилиты systemctl. Сейчас я попробую рассказать о journal более подробно, с упором на практическое применение его возможностей.

Если вы еще не в курсе, что такое journal: это компонент systemd, регистрирующий сообщения из системного журнала (syslog), сообщения ядра (kernel log) и initrd, а также сообщения, которые процессы служб выводят на STDOUT и STDERR. Полученная информация индексируется и предоставляется пользователю по запросу. Journal может работать одновременно с традиционными демоном syslog (например, rsyslog или syslog-ng), либо полностью его заменять. За подробностями стоит обратиться к первому анонсу.

Јоигпаl был включен в Fedora начиная с F17. В Fedora 18 journal вырос в мощный и удобный механизм работы с системным журналом. Однако, и в F17, и в F18 journal по умолчанию сохраняет информацию только в небольшой кольцевой буфер в каталоге /run/log/journal. Как и все содержимое каталога /run, эта информация теряется при перезагрузке<sup>65</sup>. Такой подход сильно ограничивает использование полезных возможностей journal, однако вполне достаточен для вывода актуальных сообщений от служб в systemctl status. Начиная с Fedora 19, мы собираемся включить сохранение логов на

<sup>63</sup> Отметим, что systemctl enable для экземпляров служб работает только начиная с systemd версии 188 и старше (например, в Fedora 18). В более ранних версиях придется напрямую манипулировать символьными ссылками: ln -s /usr/lib/systemd/system/serial-getty@.service/etc/systemd/system/getty.target.wants/serial-getty@ttyS2.service; systemctl daemon-reload.

<sup>&</sup>lt;sup>64</sup>Прим. перев.: На самом деле, работать с символьными ссылками пришлось бы даже в более свежих версиях systemd (до 209 включительно), так как в файле serial-getty@.service отсутствовала секция [Install], в результате чего попытка выполнения systemctl enable для экземпляра соответствующей службы приводила к закономерной ошибке. Данная проблема была устранена только в systemd 210. В случае использования более старых версий, исправить ее можно и самостоятельно: достаточно скопировать указанный файл из /usr/lib/systemd/system/ в /etc/systemd/system/, после чего дописать в него секцию [Install], содержащую параметр WantedBy=getty.target, и затем выполнить systemctl daemon-reload.

 $<sup>^{65}</sup>$ Прим. перев.: Разумеется, это никак не относится к традиционному демону системного лога, даже если он работает поверх journal.

диск, в каталог /var/log/journal. При этом, логи смогут занимать гораздо больше места $^{66}$ , а значит, смогут вместить больше полезной информации. Таким образом, journal станет еще более удобным.

# 17.1 Сохранение логов на диск

В F17 и F18 вы можете включить сохранение логов на диск вручную:

# # mkdir -p /var/log/journal

После этого рекомендуется перезагрузить систему, чтобы заполнить журнал новыми записями.

Так как теперь у вас есть journal, syslog вам больше не нужен (кроме ситуаций, когда вам совершенно необходимо иметь /var/log/messages в текстовом виде), и вы спокойно можете удалить его:

# yum remove rsyslog

#### 17.2 Основы

Итак, приступим. Нижеприведенный текст демонстрирует возможности systemd 195, входящего в Fedora  $18^{67}$ , так что, если некоторые из описанных трюков не сработают в F17 — пожалуйста, дождитесь F18.

Начнем с основ. Доступ к логам journal осуществляется через утилиту journalctl(1). Чтобы просто взглянуть на лог, достаточно ввести

#### # journalctl

Если вы выполнили эту команду с полномочиями гоот, вы увидите все журнальные сообщения, включая исходящие как от системных компонентов, так и от залогиненных пользователей 68. Вывод этой команды форматируется в стиле /var/log/messages, но при этом добавлены кое-какие улучшения:

- Строки с приоритетом error и выше подсвечены красным.
- Строки с приоритетом notice и warning выделены жирным шрифтом.
- Все отметки времени сформированы с учетом вашего часового пояса.
- Для навигации по тексту используется просмотрщик (pager), по умолчанию less<sup>69</sup>.
- Выводятся *все* доступные данные, включая информацию из файлов, прошедших ротацию (rotated logs).
- Загрузка системы отмечается специальной строкой, отделяющей записи, сгенерированные между (пере)загрузками.

Отметим, что в данной статье не приводятся примеры такого вывода — прежде всего, для краткости изложения, но также и для того, чтобы дать вам повод поскорее попробовать Fedora 18 с systemd 195. Надеюсь, отсутствие таких примеров не помешает вам уловить суть.

<sup>&</sup>lt;sup>66</sup>Прим. перев.: В journal отдельно задаются ограничения на размер для логов во временном хранилище (/run) и в постоянном (/var). При превышении лимита старые журналы удаляются. Так как /run размещается на tmpfs, т.е. в оперативной памяти, для временного хранения по умолчанию установлены более жесткие ограничения. При необходимости, соответствующие настройки можно задать в файле journald.conf.

 $<sup>^{67}</sup>$ Обновление со 195-й версией systemd на момент написания этих строк находится на тестировании и вскоре будет включено в состав Fedora 18.

<sup>&</sup>lt;sup>68</sup>Прим. перев.: А если вы выполнили эту команду от имени непривилегированного пользователя, не входящего в группу adm, и при этом не включили сохранение логов на диск, то вы не увидите ничего — без специальных полномочий пользователь может просматривать только собственный лог, а он по умолчанию велется только если логи записываются на диск.

<sup>&</sup>lt;sup>69</sup>Прим. перев.: В инструментах systemd, включая journalctl, просмотрщик включается только при прямом выводе на экран, и отключается при перенаправлении вывода в файл или передаче его по каналу (shell pipe).

# 17.3 Контроль доступа

Итак, мы получили удобный и эффективный метод просмотра логов. Но для полного доступа к системным сообщениям требуются привилегии гоот, что не всегда удобно — в наше время администраторы предпочитают работать от имени непривилегированного пользователя, переключаясь на гоот только при крайней необходимости. По умолчанию, непривилегированные пользователи могут просматривать в journal только свои собственные логи (сообщения, сгенерированные их процессами). Чтобы предоставить пользователю доступ ко всем системным логам, нужно включить его в группу adm:

#### # usermod -a -G adm lennart

Разлогинившись, а затем вновь залогинившись под именем  $lennart^{70}$ , я могу просматривать сообщения от всех пользователей и системных компонентов<sup>71</sup>:

\$ journalctl

# 17.4 Отслеживание логов в реальном времени

Когда вы запускаете программу journalctl без параметров, она выводит все сообщения, сгенерированные на текущий момент, и возвращает управление оболочке. Однако, иногда бывает полезно отслеживать их появление в режиме реального времени. В классической реализации syslog это осуществлялось командой tail -f /var/log/messages. В journal ее аналог выглядит так:

# \$ journalctl -f

И работает он точно так же: выводит последние десять сообщений, после чего переходит в режим ожидания, и выводит новые сообщения по мере их появления.

# 17.5 Простейшие методы выборки записей

При вызове journalctl без параметров, она выводит все сообщения, начиная с самого первого из сохраненных. Разумеется, это огромный объем информации. На практике иногда бывает достаточно ограничиться сообщениями, сгенерированными с момента последней загрузки системы $^{72}$ :

# \$ journalctl -b

Но часто даже после такой фильтрации записей остается довольно много. Что ж, мы можем ограничиться только наиболее важными. Итак, все сообщения с приоритетом еггог и выше, начиная с момента последней загрузки:

#### \$ journalctl -b -p err

Если вы уже успели перезагрузить систему после того, как произошли интересующие вас события, целесообразнее будет воспользоваться выборкой по времени:

## \$ journalctl --since=yesterday

 $<sup>^{70}</sup>$ Прим. перев.: Для того, чтобы обновить групповые полномочия в уже запущенных сеансах, можно воспользоваться командой newgrp(1): newgrp adm.

<sup>&</sup>lt;sup>71</sup>Прим. перев.: Группа adm была выбрана на основании опыта дистрибутива Debian, в котором она устанавливается в качестве группы-владельца большинства лог-файлов. При этом авторы четко разделяют полномочия групп adm и wheel: если последняя используется для предоставления прав изменять что-либо в системе, то первая дает возможность лишь просматривать системную информацию. Начиная с версии systemd 198, группа-владелец файлов журнала изменена с adm на systemd-journal, однако штатный алгоритм установки systemd все равно выдает права на их чтение группам adm и wheel (через ACL).

 $<sup>^{72}</sup>$  Прим. перев.: Начиная с systemd версии 206, синтаксис опции «-b» был расширен: теперь она позволяет просматривать логи не только за текущую, но и за предыдущие загрузки, например, «-b -1» — прошлая загрузка, «-b -2» — позапрошлая и т.д.

В результате мы увидим все сообщения, зарегистрированные начиная со вчерашнего дня вплоть до настоящего момента. Прекрасно! Разумеется, этот критерий отбора можно комбинировать с другими, например, с -p err. Но, допустим, нам нужно узнать о чемто, что случилось либо 15-го октября, либо 16-го:

```
$ journalctl --since=2012-10-15 --until="2011-10-16 23:59:59"
```

Отлично, мы нашли то, что искали. Но вот вам сообщают, что сегодня ранним утром наблюдались проблемы с CGI-скриптами Арасhe. Ладно, послушаем, что нам скажет индеец:

```
$ journalctl -u httpd --since=00:00 --until=9:30
```

Да, мы нашли это. Хм, похоже, что причиной стала проблема с диском /dev/sdc. Посмотрим, что с ним случилось:

```
$ journalctl /dev/sdc
```

Кошмар, ошибка ввода-вывода<sup>73</sup>! Нужно срочно заменить диск, пока не начались более серьезные проблемы. Ладно, пойдем дальше. Что у нас там случилось с процессом vpnc?

```
$ journalctl /usr/sbin/vpnc
```

Xм, ничего подозрительного. Но, кажется, проблема где-то во взаимодействии между vpnc и dhclient. Посмотрим объединенный и отсортированный по времени список сообщений от этих процессов:

\$ journalctl /usr/sbin/vpnc /usr/sbin/dhclient

Отлично, мы нашли причину проблемы!

# 17.6 Продвинутые методы выборки

Да, это все, конечно, здорово, но попробуем подняться еще на ступеньку выше. Что-бы понять описанные ниже приемы, нужно знать, что systemd добавляет к каждой лог-записи ряд скрытых метаданных. Эти метаданные по структуре напоминают набор переменных окружения, хотя на самом деле дают даже больше возможностей: во-первых, метаданные могут включать большие бинарные блоки данных (впрочем, это скорее исключение — обычно они содержат текст в кодировке UTF-8), и во-вторых, в пределах одной записи поле метаданных может содержать сразу несколько значений (и это тоже встречается нечасто — обычно поля содержат по одному значению). Эти метаданные автоматически собираются и добавляются для каждой лог-записи, безо всякого участия пользователя. И вы легко можете их использовать для более тонкой выборки записей. Посмотрим, как они выглядят:

```
$ journalctl -o verbose -n1
Tue, 2012-10-23 23:51:38 CEST [s=ac9e9c423355411d87bf0ba1a9b424e8;i=4301;b=5335e9cf5d954633bb99ae
PRIORITY=6
SYSLOG_FACILITY=3
__MACHINE_ID=a91663387a90b89f185d4e860000001a
__HOSTNAME=epsilon
__TRANSPORT=syslog
SYSLOG_IDENTIFIER=avahi-daemon
__COMM=avahi-daemon
__EXE=/usr/sbin/avahi-daemon
```

\_SYSTEMD\_CGROUP=/system/avahi-daemon.service

\_SELINUX\_CONTEXT=system\_u:system\_r:avahi\_t:s0

\_SYSTEMD\_UNIT=avahi-daemon.service

<sup>73</sup> Ну ладно, признаюсь, здесь я немножко считерил. Индексирование сообщений ядра по блочным устройствам пока что не принято в апстрим, но Ганс проделал огромную работу, чтобы реализовать эту функциональность, и я надеюсь, что к релизу F18 все будет.

```
_UID=70
_GID=70
_CMDLINE=avahi-daemon: registering [epsilon.local]

MESSAGE=Joining mDNS multicast group on interface wlan0.IPv4 with address 172.31.0.53.
_BOOT_ID=5335e9cf5d954633bb99aefc0ec38c25
_PID=27937
SYSLOG_PID=27937
_SOURCE_REALTIME_TIMESTAMP=1351029098747042
```

(Чтобы не утомлять вас огромным количеством текста, ограничимся одной записью. Ключ -n позволяет задать число выводимых записей, в нашем случае 1. Если указать его без параметра, будут показаны 10 последних записей.)

Задав параметр -o verbose, мы переключили формат вывода — теперь, вместо скупых строчек, копирующих /var/log/messages, для каждой записи выводится полный перечень всех метаданных. В том числе, информация о пользователе и группе, контекст SELinux, идентификатор компьютера и т.д. Полный список общеизвестных полей метаданных приведен на соответствующей странице руководства.

База данных Journal индексируется по *всем* этим полям! И мы можем использовать любое из них в качестве критерия выборки:

# \$ journalctl \_UID=70

Как нетрудно догадаться, в результате будут выведены все сообщения от процессов пользователя с UID 70. При необходимости, критерии можно комбинировать:

```
$ journalctl _UID=70 _UID=71
```

Указание нескольких значений для одного и того же поля эквивалентно логическому ИЛИ. Таким образом, будут выведены записи как от процессов с UID 70, так и от процессов с UID 71.

```
$ journalctl _HOSTNAME=epsilon _COMM=avahi-daemon
```

А вот указание нескольких pазличных полей дает эффект логического И. В результате, будут выведены записи только от процесса avahi-daemon, работающего на хосте с именем epsilon.

Но мы этим не ограничимся! Мы же суровые компьютерщики, нам нужны сложные логические выражения!

```
$ journalctl _HOSTNAME=theta _UID=70 + _HOSTNAME=epsilon _COMM=avahi-daemon
```

При помощи плюса мы можем явно задать логическое ИЛИ, применяя его к разным полям и даже И-выражениям. Поэтому наш пример выведет как записи с хоста theta от процессов с UID 70, так и с хоста epsilon от процесса avahi-daemon $^{74}$ .

# 17.7 И немного магии

Уже неплохо, правда? Но есть одна проблема — мы же не сможем запомнить все возможные значения всех полей журнала! Для этого была бы нужна очень хорошая память. Но journalctl вновь приходит к нам на помощь:

```
$ journalctl -F _SYSTEMD_UNIT
```

Эта команда выведет все значения поля \_SYSTEMD\_UNIT, зарегистрированные в базе данных журнала на текущий момент. То есть, имена всех юнитов systemd, которые писали что-либо в журнал. Аналогичный запрос работает для всех полей, так что найти точное значение для выборки по нему — уже не проблема. Но тут самое время сообщить вам,

 $<sup>^{74}</sup>$ Прим. перев.: Стоит отметить, что приоритет логических операций стандартный: сначала выполняются операции И, и только потом — операции ИЛИ. Используемая в journalctl система записи выражений аналогична принятой в классической алгебре: умножение (имеющее более высокий приоритет) не указывается знаком операции, а обозначается просто последовательной записью величин.

что эта функциональность встроена в механизм автодополнения оболочки $^{75}$ ! Это же просто прекрасно — вы можете просмотреть перечень значений поля и выбрать из него нужно прямо при вводе выражения. Возьмем для примера метки SELinux. Помнится, имя поля начиналось с букв SE...

```
$ journalctl _SE<TAB>
```

и оболочка сразу же дополнит:

```
$ journalctl _SELINUX_CONTEXT=
```

Отлично, и какое там значение нам нужно?

```
$ journalctl _SELINUX_CONTEXT=<TAB><TAB>
kernel
                                                     system_u:system_r:rtkit_daemon_t:s0
system_u:system_r:accountsd_t:s0
                                                     system_u:system_r:syslogd_t:s0
system_u:system_r:avahi_t:s0
                                                     system_u:system_r:system_cronjob_t:s0-s0:c0.c1023
system_u:system_r:bluetooth_t:s0
                                                     system_u:system_r:system_dbusd_t:s0-s0:c0.c1023
{\tt system\_u:system\_r:chkpwd\_t:s0-s0:c0.c1023}
                                                     system_u:system_r:systemd_logind_t:s0
system_u:system_r:chronyd_t:s0
                                                     system_u:system_r:systemd_tmpfiles_t:s0
                                                     {\tt system\_u:system\_r:udev\_t:s0-s0:c0.c1023}
system_u:system_r:crond_t:s0-s0:c0.c1023
                                                     system\_u:system\_r:virtd\_t:s0-s0:c0.c1023 \ c0.c1023
system_u:system_r:devicekit_disk_t:s0
system_u:system_r:dhcpc_t:s0
                                                     system_u:system_r:vpnc_t:s0 sd_t:s0-s0:c0.c1023
system_u:system_r:dnsmasq_t:s0-s0:c0.c1023
                                                     system_u:system_r:xdm_t:s0-s0:c0.c1023
system_u:system_r:init_t:s0
                                                     unconfined_u:system_r:rpm_t:s0-s0:c0.c1023
system_u:system_r:local_login_t:s0-s0:c0.c1023
                                                     unconfined_u:system_r:unconfined_t:s0-s0:c0.c1023
system_u:system_r:lvm_t:s0
                                                     unconfined_u:system_r:useradd_t:s0-s0:c0.c1023
system_u:system_r:modemmanager_t:s0-s0:c0.c1023
                                                     unconfined_u:unconfined_r:unconfined_dbusd_t:s0-s0:c0.c1
system_u:system_r:NetworkManager_t:s0
                                                     unconfined_u:unconfined_r:unconfined_t:s0-s0:c0.c1023
system_u:system_r:policykit_t:s0
```

Ага, нас интересуют записи с меткой PolicyKit! Пользуясь дополнением, вводим:

```
$ journalctl _SELINUX_CONTEXT=system_u:system_r:policykit_t:s0
```

Очень просто, не правда ли! Пожалуй, самое простое из действий, связанных с SELinux ;-) Разумеется, такое дополнение работает для всех полей Journal.

На сегодня все. Впрочем, на странице руководства journalctl(1) можно узнать и о многих других возможностях, не описанных здесь. Например, о том, что journalctl может выводить данные в формате JSON, или в формате /var/log/messages, но с относительными метками времени, как в dmesg.

# 18 Управление ресурсами с помощью cgroups

Важную роль в современных компьютерных системах играют механизмы управления использованием ресурсов: когда вы запускаете на одной системе несколько программ, возникает необходимость распределять между ними ресурсы системы, в соответствии с некоторыми правилами. В частности, это особенно актуально на маломощных встраиваемых и мобильных системах, обладающих очень скудными ресурсами. Но та же задача актуальна и для очень мощных вычислительных кластеров, которые располагают огромными ресурсами, но при этом несут и огромную вычислительную нагрузку.

Исторически, в Linux поддерживался только одна схема управления ресурсами: все процессы получают примерно равные доли процессорного времени или потока вводавывода. При необходимости соотношение этих долей можно изменить при помощи значения *nice*, задаваемого для каждого процесса. Такой подход очень прост, и на протяжении долгих лет покрывал все нужды пользователей Linux. Но у него есть существенный недостаток: он оперирует лишь отдельными процессами, но не их группами. В результате, например, веб-сервер Арасће с множеством СGI-процессов при прочих

 $<sup>^{75}</sup>$ Прим. перев.: В исходной статье речь идет только о bash, однако, начиная с релиза systemd 196, аналогичная функциональность доступна и для zsh.

равных получает гораздо больше ресурсов, чем служба syslog, у которой не так много процессов.

В процессе проектирования архитектуры systemd, мы практически сразу поняли, что управление ресурсов должно быть одной из базовых функций, заложенных в основы его структуры. В современной системе — неважно, серверной или встраиваемой — контроль использования процессора, памяти и ввода-вывода для различных служб нельзя добавлять задним числом. Такая функциональность должна быть доступна изначально, через базовые настройки запуска служб. При этом, ресурсы должны распределяться на уровне служб, а не процессов, как это делалось при помощи значений пісе или POSIX Resource Limits.

В этой статье я попробую рассказать о методах управления механизмами распределения ресурсов между службами systemd. Эта функциональность присутствует в systemd уже долгое время, и давно пора рассказать о ней пользователям и администраторам.

В свое время я пояснял<sup>76</sup>, что контрольные группы Linux (cgroups) могут работать и как механизм группировки и отслеживания процессов, и как инструмент управления использованием ресурсов. Для функционирования systemd необходим только первый из этих режимов, а второй опционален. И именно этот опциональный второй режим дает вам возможность распределять ресурсы между службами. (А сейчас очень рекомендую вам, прежде чем продолжать чтение этой статьи, ознакомиться с базовой информацией о сgroups. Хотя дальнейшие рассуждения и не будут затрагивать низкоуровневые аспекты, все же будет лучше, если у вас сформируется некоторое представление о них.)

Основными контроллерами cgroups, отвечающими за управление ресурсами, являются сри, memory и blkio. Для их использования необходимо, чтобы они были включены на этапе сборки ядра; большинство дистрибутивов (в том числе и Fedora), включают их в штатных ядрах. systemd предоставляет ряд высокоуровневых настроек, позволяющих использовать эти контроллеры, не вникая в технические детали их работы.

# 18.1 Процессор

Если в ядре включен контроллер сри, systemd по умолчанию создает контрольную группу по этому ресурсу для каждой службы. Даже без каких-либо дополнительных настроек это дает положительных эффект: на системе под управлением systemd все службы получают равные доли процессорного времени, независимо от количества процессов, запущенных в рамках службы. Например, на вашем веб-сервере MySQL с несколькими рабочими процессами получит такую же долю процессорного времени, как и Арасће, даже если тот запустил 1000 СGI-процессов. Разумеется, такое поведение при необходимости можно легко отключить — см. опцию DefaultControllers= в файле /etc/systemd/system.conf.

Если равномерное распределение процессорного времени между службами вас не устраивает, и вы хотите выделить определенным службам больше или меньше времени — используйте опцию CPUShares= в конфигурационном файле службы. По умолчанию это значение равно 1024. Увеличивая это число, вы даете службе больше процессорного времени, уменьшая — соответственно, меньше.

Рассмотрим небольшой практический пример. Допустим, вам нужно увеличить для службы Apache относительную долю потребления процессора до 1500. Для

<sup>&</sup>lt;sup>76</sup>Прим. перев.: В указанном документе автор рассказывает, что контрольные группы Linux состоят из двух сущностей: (A) механизма иерархической группировки и маркировки процессов, и (B) механизма, позволяющего распределять ресурсы между полученными группами. Для работы (B) необходимо (A), но не наоборот — (A) может прекрасно работать без (B). Для нормально функционирования systemd (A) необходим, а (B) опционален (он лишь обеспечивает работу некоторых настроек). Вы можете собрать ядро только с необходимой для (A) опцией CONFIG\_CGROUPS=y, отключив все связанные с (B) опцио (такие как сонгід\_совоир\_веревер, сонгід\_совоир\_срчасот=y, conгід\_совоир\_мем\_res\_ctlr=y, conгід\_coroup\_mem\_res\_ctlr=y, conгід\_coroup\_perp=y, conгід\_coroup\_sched=y, conгід\_lelk\_coroup=y, conгід\_lelt\_coroup=y, conгід\_lett\_prid\_coroup=y), и systemd будет нормально работать на такой системе (за исключением того, что связанные с этим контроллерами настройки не будут срабатывать). Однако, если собрать ядро без CONFIG\_CGROUPS=y, функциональность systemd будет сильно ограничена. При этом, автор особо подчеркивает, что все негативные эффекты влияния контрольных групп на производительность обусловлены именно (B), в то время как (A) на производительность практически не влияет.

этого создаем файл «ручных» настроек /etc/systemd/system/httpd.service, который включает в себя все те же опции, что и файл настроек по умолчанию /usr/lib/systemd/system/httpd.service, отличаясь от него только значением CPUShares=

.include /usr/lib/systemd/system/httpd.service

[Service]
CPUShares=1500

Первая строка обеспечивает включение в нашу конфигурацию файла с настройками по умолчанию, сделанными разработчиками Арасhе или его сопровождающими в вашем дистрибутиве (если это включение не указать явно, данный файл будет проигнорирован). Далее, мы указываем тот параметр, который хотим изменить<sup>77</sup>. Сохраняем файл, приказываем systemd перечитать конфигурацию, и перезапускаем Арасhe, чтобы настройки вступили в силу<sup>78</sup>:

```
systemctl daemon-reload
systemctl restart httpd.service
```

Готово!

Обратите внимание, что явное указание значения CPUShares= в конфигурации службы заставит systemd создать для нее контрольную группу в иерархии контроллера сри, даже если этот контроллер не указан в DefaultControllers= (см. выше).

# 18.2 Отслеживание использования ресурсов

Для того, чтобы правильно распределять ресурсы между службами, неплохо бы знать реальные потребности этих служб. Чтобы упростить для вас отслеживание потребления ресурсов службами, мы подготовили утилиту systemd-cgtop, которая находит все имеющиеся в системе контрольные группы, определяет для каждой из них количество потребляемых ресурсов (процессорное время, память и ввод-вывод) и выводит эти данные в динамически обновляемой сводной таблице, по аналогии с программой top. Используя вводимое systemd распределение служб по контрольным группам, эта утилита выводит для служб те же сведения, которые top выводит для отдельных процессов.

К сожалению, по умолчанию cgtop может раздельно отслеживать для каждой службы только потребление процессорного времени, а сведения по использованию памяти и ввода-вывода доступны только для всей системы в целом. Это ограничение возникает из-за того, что в конфигурации по умолчанию контрольные группы для служб создаются только в иерархии контроллера сри, но не memory и blkio. Без создания групп в иерархии этих контроллеров невозможно отследить использование ресурса по службам. Самый простой способ обойти это ограничение — приказать systemd создавать соответствующие группы, добавив memory и blkio в перечень DefaultControllers= в файле system.conf.

<sup>&</sup>lt;sup>77</sup>Прим. перев.: В новых версиях systemd, начиная со 198, можно поступить проще: вместо того, чтобы создавать свой юнит-файл в каталоге /etc и включать в него содержимое штатного (из /usr), достаточно просто создать каталог /etc/systemd/system/httpd.service.d/ и поместить в него файл my\_resource\_limit.conf (суффикс .conf обязателен), в котором указываются только те настройки, которые необходимо изменить (последние две строки вышеприведенного листинга). Это никак не отменяет основного конфигурационного файла юнита (который может находиться в /usr или /etc), однако настройки из .d-каталогов имеют более высокий приоритет и могут перекрывать настройки основного файла. Все вышесказанное относится и к другим примерам из этого раздела.

<sup>&</sup>lt;sup>78</sup>Прим. перев.: systemd версий до 197 (включительно) не имел штатного механизма для изменения параметров контрольных групп «на лету» (без перезапуска службы). Если у вас все же возникнет такая необходимость, вы можете узнать контрольную группу службы командой systemctl show -p ControlGroup имя\_службы.service, и выполнить требуемые настройки напрямую через запись значений в псевдофайлы сgroupfs (разумеется, при следующем запуске службы к ней будут применены параметры, указанные в конфигурационном файле). В версиях systemd со 198 по 204, программа systemctl поддерживала команды set-cgroup-attr, unset-cgroup-attr и get-cgroup-attr позволявшие манипулировать настройками контрольных групп. Начиная с systemd 205, они были заменены командой set-property, работающей с параметрами конфигурации юнитов. Установленные через systemctl настройки сохраняются во вспомогательных конфигурационных файлах, которые размещаются в .d-каталогах (см. примечание выше).

### 18.3 Память

Используя опции MemoryLimit= и MemorySoftLimit=, вы можете ограничивать суммарное потребление оперативной памяти всеми процессами службы. В них указывается предел потребления памяти в байтах<sup>79</sup>. При этом поддерживаются суффиксы K, M, G и T, обозначающие соответственно, килобайт, мегабайт, гигабайт и терабайт (по основанию 1024).

```
.include /usr/lib/systemd/system/httpd.service
[Service]
MemoryLimit=1G
```

По аналогии с CPUShares=, явное указание этих опций заставит systemd создать для службы контрольную группу в иерархии контроллера memory, даже если он не был указан в DefaultControllers=.

# 18.4 Ввод-вывод

Для контроля пропускной полосы ввода-вывода с блочных устройств, доступно несколько настроек. Первая из них — BlockIOWeight=, задающая долю полосы вводавывода для указанной службы. Принцип похож на CPUShares= (см. выше), однако здесь величина относительной доли ограничена значениями от 10 до 1000. По умолчанию, она равна 1000. Уменьшить долю для службы Арасће можно так:

```
.include /usr/lib/systemd/system/httpd.service
[Service]
BlockIOWeight=500
```

При необходимости, вы можете задать такое значение отдельно для каждого устройства:

```
.include /usr/lib/systemd/system/httpd.service
[Service]
BlockIOWeight=/dev/disk/by-id/ata-SAMSUNG_MMCRE28G8MXP-0VBL1_DC06K01009SE009B5252 750
```

При этом, точное название устройства знать не обязательно — достаточно указать интересующий вас каталог:

```
.include /usr/lib/systemd/system/httpd.service
[Service]
BlockIOWeight=/home/lennart 750
```

Если заданный вами путь не указывает на файл устройства, systemd автоматически определит, на каком устройстве расположен указанный файл/каталог, и выставит для этого устройства соответствующую настройку.

Вы можете добавить несколько таких строк, задавая долю пропускной полосы отдельно для различных устройств, и при этом также допускается указать «общее» значение (как в первом примере), которое будет использовано для всех остальных устройств.

В качестве альтернативы относительной доле пропускной полосы, вы также можете ограничивать абсолютную долю, используя настройки BlockIOReadBandwidth= и BlockIOWriteBandwidth=. В них нужно указать устройство или любой находящийся на нем файл/каталог, а также предельную скорость чтения/записи в байтах в секунду:

<sup>&</sup>lt;sup>79</sup>Прим. перев.: Разница между MemorySoftLimit= и MemoryLimit= состоит в том, что первый предел можно превышать, если в системе еще есть достаточное количество свободной памяти. Второй из этих пределов превышать нельзя, независимо от наличия свободной памяти. Подробнее см. раздел «Soft limits» в файле документации. Отметим, что из-за планируемого прекращения поддержки параметра memory.soft\_limit\_in\_bytes на уровне ядра, опция MemorySoftLimit= была удалена из systemd, начиная с версии 208.

```
.include /usr/lib/systemd/system/httpd.service
```

[Service]
BlockIOReadBandwith=/var/log 5M

В результате, для данной службы скорость чтения с устройства, содержащего каталог /var/log, будет ограничена величиной 5 мегабайт в секунду.

По аналогии с вышеописанными CPUShares= и MemoryLimit=, явное указание любой из приведенных настроек пропускной полосы заставит systemd создать для службы контрольную группу в иерархии контроллера blkio.

# 18.5 Прочие параметры

Вышеописанные опции покрывают лишь малую толику настроек, поддерживаемых различными контроллерами Linux cgroups. Мы добавили высокоуровневый интерфейс только к тем настройкам, которые кажутся нам наиболее важным для большинства пользователей. Из соображений удобства мы добавили механизмы, обеспечивающие поддержку крупных единиц измерения (килобайты, мегабайты и т.д.) и автоматическое определение блочных устройств по указанному файлу/каталогу.

В некоторых случаях описанных высокоуровневых настроек может оказаться недостаточно — допустим, вам нужно задать низкоуровневую настройку cgroups, для которой мы (пока) не добавили высокоуровневого аналога. На этот случай мы предусмотрели универсальных механизм задания таких опций в конфигурационных файлах юнитов<sup>80</sup>. Рассмотрим, например, задание для службы параметра *swappiness* (относительная интенсивность использования подкачки для процессов службы). В systemd нет высокоуровневой настройки для этого значения. Однако вы можете задать его, используя низкоуровневую настройку ControlGroupAttribute=:

```
.include /usr/lib/systemd/system/httpd.service
[Service]
ControlGroupAttribute=memory.swappiness 70
```

Как обычно, явное указание настройки, относящейся к какому-либо контроллеру (в нашем случае memory) приведет к автоматическому созданию группы в иерархии данного контроллера.

В дальнейшем, возможно, мы расширим возможности высокоуровневой настройки различных параметров контрольных групп. Если вы часто пользуетесь какими-то из них и полагаете, что для них можно добавить соответствующие опции — не стесняйтесь обращаться к нам. А лучше всего — присылайте сразу патч!

Предупреждение: Обратите внимание, что использование некоторых контроллеров может сильно сказаться на производительности системы. Это та цена, которую приходится платить за контроль над ресурсами. Использование таких контроллеров может ощутимо замедлить некоторые операции. В частности, весьма нелестная в этом плане репутация закрепилась за контроллером memory (хотя, не исключено, что эта проблема уже исправлена в свежих выпусках ядра).

Для углубленного изучения темы, затронутой в этой статье, вы можете обратиться к документации по поддерживаемым настройкам юнитов, а также по контроллерам сри, memory и blkio.

<sup>&</sup>lt;sup>80</sup>Прим. перев.: Описываемый здесь механизм управления низкоуровневыми настройками контрольных групп (ControlGroupAttribute=) присутствовал в systemd до 204 версии включительно. Начиная с версии 205, он был удален по требованию разработчиков сдгоиря. Также были удалены возможности напрямую задавать для юнита контрольную группу (ControlGroup=) и устанавливать права доступа для управления группами (ControlGroupModify=). Взамен, разработчики systemd планируют значительно расширить поддержку высокоуровневых настроек для параметров сдгоиря — сразу после того, как разработчики сдгоиря определятся, какие именно параметры они будут поддерживать. Наличие некоторого хаоса в этой области обусловлено происходящей сейчас полной переработкой реализации контрольных групп на уровне ядра и механизмов работы с ними из пространства пользователя. Техническая сторона данного вопроса раскрыта в статье The New Control Group Interfaces (пока не переведена).

Стоит подчеркнуть, что мы сейчас обсуждали распределение ресурсов между служсбами. В дополнение к этим современным механизмам, systemd также поддерживает и традиционные настройки, касающиеся распределения ресурсов между отдельными процессами. Хотя такие настройки обычно наследуются порожденными процессами, они, тем не менее, все равно ограничивают ресурсы на уровне отдельных процессов. В частности, к ним относятся IOSchedulingClass=, IOSchedulingPriority=, CPUSchedulingPolicy=, CPUSchedulingPriority=, CPUAffinity=, LimitCPU= и т.п. Для их работы не требуют контроллеры сдгоирѕ, и они не так сильно ухудшают производительность. Возможно, мы рассмотрим их в последующих статьях.

# 19 Проверка на виртуальность

Еще в начале разработки systemd, мы внимательно изучали существовавшие на тот момент init-скрипты, выделяя наиболее типичные для них операции. Среди прочих, в составленный нами список попала и такая функция, как определение виртуализации: некоторые скрипты проверяли, запускаются они в виртуальном окружении (например, KVM, VMWare, LXC и т.д.) или на полноценной, физической системе. Часть этих скриптов отказывалась работать на виртуальных системах (например, службы управления устройствами совершенно излишни в виртуальных контейнерах, не имеющих доступа к устройствам), другие же, наоборот, запускались только в определенных виртуальных окружениях (например, всевозможные «guest additions», рекомендуемые к запуску на гостевых системах VMWare и VirtualBox). По-хорошему, в некоторых ситуациях было бы более правильно проверять некоторые другие условия, а не пытаться явно определить наличие виртуализации. Тем не менее, всесторонне изучив вопрос, мы пришли к выводу, что во многих случаях возможность явной проверки такого условия при запуске служб была бы очень кстати. В результате, мы добавили поддержку соответствующей опции настройки юнитов — ConditionVirtualization; кроме того, мы создали небольшую утилиту, которую можно вызывать из скриптов — systemd-detect-virt(1); и наконец, мы предоставили простой интерфейс для шины D-Bus, позволяющий получить информацию о виртуализации даже непривилегированным программам.

Определить, запущен код на виртуальной системе, или на физической, на самом деле не так уж и сложно. В зависимости от того, какие именно механизмы виртуализации вы хотите определить, основная работа сводится к выполнению инструкции CPUID и, возможно, проверке некоторых файлов в /sys и /proc. Основная трудность здесь — точно знать строки, которые нужно искать. Список таких строк необходимо поддерживать в актуальном состоянии. В настоящий момент, systemd определяет следующие механизмы виртуализации:

- Полная виртуализация (т.е. виртуальные машины):
  - qemu
  - kvm
  - vmware
  - microsoft
  - oracle
  - xen
  - bochs
- Виртуализация на уровне ОС (т.е. контейнеры):
  - chroot
  - openvz
  - lxc
  - lxc-libvirt
  - systemd-nspawn

Рассмотрим, как можно использовать эту функциональность.

#### 19.1 Условия на запуск юнитов

При помощи опции ConditionVirtualization, добавленной в секцию [Unit] файла конфигурации юнита, вы можете обеспечить запуск (или наоборот, отмену запуска) данного юнита в зависимости от того, работает ли он на виртуальной системе, или нет. В случае утвердительного ответа, также можно уточнить, какая система виртуализации при этом используется. Например:

```
[Unit]
Name=My Foobar Service (runs only only on guests)
ConditionVirtualization=yes

[Service]
ExecStart=/usr/bin/foobard
```

Помимо «yes» или «no», вы также можете указать идентификатор конкретной системы виртуализации (согласно списку выше, например, «kvm», «vmware» и т.д.), либо «container» или «vm» (что позволит отличить виртуализацию на уровне ОС от полной виртуализации). Кроме того, вы можете добавить перед значением восклицательный знак, и результат проверки будет инвертирован (юнит запустится только в том случае, если указанная технология не используется). Подробности вы можете узнать на странице руководства.

#### 19.2 В скриптах

В скриптах оболочки вы можете выполнить аналогичные проверки при помощи утилиты systemd-detect-virt(1). Например:

Эта утилита возвращает код 0 (успех), обнаружив виртуализацию, или ненулевое значение, если виртуализация не выявлена. Также она выводит идентификатор обнаруженной системы виртуализации (согласно списку выше), если это не было запрещено опцией -q. Кроме того, опции -с и -v позволяют ограничить проверки только механизмами виртуализации на уровне ОС, либо полной виртуализации, соответственно. Подробности см. на странице руководства.

#### 19.3 В программах

Информация о виртуализации также представлена на системной шине:

```
$ gdbus call --system --dest org.freedesktop.systemd1 --object-path /org/freedesktop/systemd1 \
> --method org.freedesktop.DBus.Properties.Get org.freedesktop.systemd1.Manager Virtualization
(<'systemd-nspawn'>,)
```

Если виртуализация не выявлена, это свойство содержит пустую строку. Обратите внимание, что некоторые контейнерные системы не могут быть обнаружены напрямую из непривилегированного кода. Именно поэтому мы не стали создавать библиотеку, а воспользовались шиной D-Bus, которая позволяет корректно решить проблему привилегий.

Стоит отметить, что все эти инструменты определяют только «самый внутренний» из задействованных механизмов виртуализации. Если вы используете несколько систем, вложенных друг в друга, вышеописанные инструменты обнаружат только ту, в которой они непосредственно запущены. В частности, если они работают в контейнере, находящемся внутри виртуальной машины, они увидят только контейнер.

#### 20 Сокет-активация служб и контейнеров

Сокет-активация — это одна из наиболее интересных возможностей systemd. Еще в первом анонсе нашего проекта мы рассказывали о том, как этот механизм улучшает параллелизацию и отказоустойчивость использующих сокеты служб, а также упрощает формирование зависимостей между службами при загрузке. В данной статье я продолжу рассказ о его возможностях — на этот раз речь пойдет об увеличении числа служб и контейнеров, работающих на одной и той же системе, без повышения потребления ресурсов. Другими словами: как можно увеличить количество клиентских сайтов на хостинговых серверах без затрат на новое оборудование.

#### 20.1 Сокет-активация сетевых служб

Начнем с небольшого отступления. Итак, что же такое сокет-активация, и как она работает? На самом деле все довольно просто. systemd создает «слушающие» сокеты (не обязательно IP) от имени вашей службы (которая пока не запущена) и ожидает входящие соединения. Как только в сокет поступает первый запрос, systemd запускает службу и передает ей полученные данные. После обработки запроса, в зависимости от реализации службы, она может продолжать работу, ожидая новых соединений, или завершиться, переложив эту задачу обратно на systemd (который вновь запустит ее при поступлении очередного запроса). При этом, со стороны клиента невозможно отличить, когда служба запущена, а когда — нет. Сокет постоянно остается открытым для входящих соединений, и все они обрабатываются быстро и корректно.

Такая конфигурация позволяет снизить потребление системных ресурсов: службы работают и потребляют ресурсы только тогда, когда это действительно необходимо. Многие интернет-сайты и службы могут использовать это с выгодой для себя. Например, хостеры веб-сайтов знают, что из огромного количества существующих в Интернете сайтов лишь малая часть получает непрерывный поток запросов. Большинство же сайтов, хотя и должны постоянно оставаться доступными, получают запросы очень редко. Используя сокет-активацию, вы можете воспользоваться этим: разместив множество таких сайтов на одной системе и активируя их службы только при необходимости, вы получаете возможность «оверкоммита»: ваша система будет обслуживать сайтов больше, чем формально позволяют ее ресурсы<sup>81</sup>. Разумеется, увлекаться оверкоммитом не стоит, иначе в моменты пиковой нагрузки ресурсов может действительно не хватить.

С помощью systemd вы без труда можете организовать такую схему. Множество современных сетевых служб уже поддерживают сокет-активацию «из коробки» (а в те, которые пока не поддерживают, ее не так уж и сложно добавить в устеми механизм управления экземплярами служб позволяет подготовить универсальные шаблоны конфигурации служб, и в соответствии с ними для каждого сайта будет запускаться свой экземпляр службы. Кроме того, не стоит забывать, что systemd предоставляет внушительный арсенал механизмов обеспечения безопасности и разграничения доступа, который позволит изолировать клиентские сайты друг от друга (например, службы каждого клиента будут видеть только его собственный домашний каталог, в то время как каталоги всех остальных пользователей будут им недоступны). Итак, в конечном итоге вы получаете надежную и масштабируемую серверную систему, на сравнительно небольших ресурсах которой функционирует множество безопасно изолированных друг от друга служб — и все это реализовано штатными возможностями вашей ОС<sup>83</sup>.

<sup>81</sup>Прим. перев.: Стоит отметить, что подобная схема работает только при условии, что для каждого клиентского сайта запускаются отдельные процессы служб, хотя это и происходит в рамках одного хоста. Не очень распространенный в отчественном хостинге вариант: обычно следующей опцией после shared-хостинга (одна служба на всех клиентов) идет VPS (каждому клиенту по виртуальному хосту).

<sup>82</sup>Прим. перев.: Начиная с версии 209, в состав systemd входит утилита systemd-socket-proxyd, позволяющая использовать сокет-активацию даже для служб, которые ее не поддерживают.

<sup>&</sup>lt;sup>83</sup>Прим. перев.: В качестве практического примера использования сокет-активации служб systemd в промышленных серверных платформах, можно предложить вот эту статью, наглядно описывающую применение этой и других технологий (мониторинг, использование Journal, ограничение ресурсов и доступа) на примере Node.js.

Подобные конфигурации уже используются на рабочих серверах ряда компаний. В частности, специалисты из Pantheon используют такую схему для обслуживания масштабируемой инфраструктуры множества сайтов на базе Drupal. (Стоит упомянуть, что заслуга ее внедрения в компании Pantheon принадлежит Дэвиду Штрауссу. Дэвид, ты крут!)

#### 20.2 Сокет-активация контейнеров

Все вышеописанные технологии уже реализованы в ранее вышедших версиях systemd. Если ваш дистрибутив поддерживает systemd, вы можете воспользоваться этими механизмами прямо сейчас. А теперь сделаем шаг вперед: начиная с systemd 197 (и, соответственно, с Fedora 19), мы добавили поддержку сокет-активации виртуальных контейнеров с полноценными ОС внутри. И я считаю это действительно важным достижением.

Сокет-активация контейнеров работает следующим образом. Изначально, systemd хост-системы слушает порты от имени контейнера (например, порт SSH, порт вебсервера и порт сервера СУБД). При поступлении на любой из этих портов входящего запроса, systemd запускает контейнер и передает ему все его сокеты. Внутри контейнера, еще один systemd (init гостевой системы) принимает эти сокеты, после чего вступает в работу вышеописанная схема обычной сокет-активации служб. При этом, SSH-сервер, веб-сервер и СУБД-сервер «видят» только ОС контейнера — хотя они были активированы сокетами, созданными на хосте! Для клиента все эти тонкости скрыты. Таким образом, мы получаем виртуальный контейнер с собственной ОС, активируемый при поступлении входящего сетевого соединения, причем совершенно прозрачно для клиента<sup>84</sup>.

Внутри контейнера функционирует полноценная ОС, причем ее дистрибутив не обязательно совпадает с дистрибутивом хост-системы. Например, вы можете установить на хосте Fedora, и запускать на нем несколько контейнеров с Debian. Контейнеры имеют собственные init-системы, собственные SSH-серверы, собственные списки процессов и т.д., но при этом пользуются некоторыми механизмами ОС хоста (например, управлением памятью).

К настоящему моменту сокет-активация контейнеров поддерживается лишь встроенным в systemd простейшим контейнерным менеджером — systemd-nspawn. Мы надеемся, что соответствующая возможность вскоре появится и в libvirt-lxc<sup>85</sup>. А пока, за отсутствием альтернатив, рассмотрим использование этого механизма на примере systemd-nspawn.

Начнем с установки файлов ОС контейнера в выбранный каталог. Детальное рассмотрение этого вопроса выходит далеко за рамки нашего обсуждения, и при том детально рассмотрено во многих статьях и руководствах. Поэтому ограничусь лишь несколькими наиболее важными замечаниями. В частности, команда для установки Fedora будет выглядеть следующим образом:

```
$ yum --releasever=19 --nogpg --installroot=/srv/mycontainer/ --disablerepo='*' \
> --enablerepo=fedora install systemd passwd yum fedora-release vim-minimal
```

а для Debian —

\$ debootstrap --arch=amd64 unstable /srv/mycontainer/

Также см. последние абзацы страницы руководства systemd-nspawn(1). Стоит отметить, что в настоящее время реализация системного аудита в Linux не поддерживает виртуальные контейнеры, и ее включение в ядре хоста вызовет множество ошибок при попытке запустить контейнер. Отключить ее можно добавлением audit=0 в строку параметров загрузки ядра хоста.

<sup>&</sup>lt;sup>84</sup>Кстати говоря, это еще один аргумент в пользу важности быстрой загрузки для серверных систем. <sup>85</sup>Прим. перев.: Патчи, реализующие эту возможность, были подготовлены и приняты разработчиками libvirt во второй декаде июля 2013 г., и входят в libvirt начиная с версии 1.1.1.

Разумеется, внутри контейнера должен должен быть установлен systemd версии не ниже 197. Установить его и произвести другие необходимые настройки можно при помощи того же systemd-nspawn (пока что в режиме аналога chroot, т.е. без параметра -b). После этого можно попробовать загрузить ОС контейнера, используя systemd-nspawn уже с параметром -b.

Итак, ваш контейнер нормально загружается и работает. Подготовим для него service-файл, при помощи которого systemd сможет запускать и останавливать виртуальное окружение. Для этого, создадим на хост-системе файл /etc/systemd/system/mycontainer.service со следующим содержанием:

```
[Unit]
Description=My little container

[Service]
ExecStart=/usr/bin/systemd-nspawn -jbD /srv/mycontainer 3
KillMode=process
```

Теперь мы можем запускать и останавливать эту службу командами systemctl start и stop. Однако, пока что мы не можем войти в эту систему<sup>86</sup>. Чтобы исправить это упущение, настроим на контейнере SSH-сервер, причем таким образом, что подключение к его порту активировало весь контейнер, а затем активировало сервер, работающий внутри. Начнем с того, что прикажем хосту слушать порт SSH для контейнера. Для этого создадим на хосте файл /etc/systemd/system/mycontainer.socket:

```
[Unit]
Description=The SSH socket of my little container
[Socket]
ListenStream=23
```

После того, как мы запустим этот юнит командой systemctl start, systemd будет слушать 23-й TCP-порт хоста. В примере выбран именной 23-й, потому что 22-й скорее всего окажется занят SSH-сервером самого хоста. пspawn виртуализует списки процессов и точек монтирования, но не сетевые стеки, поэтому порты хоста и гостей не должны конфликтовать $^{87}$ .

Пока что systemd, работающий внутри контейнера, не знает, что делать с тем сокетами, которые ему передает systemd хоста. Если вы попробуете подключиться к порту 23, контейнер запустится, но сетевое соединение немедленно будет закрыто, так как данному сокету не соответствует пока никакой сервер. Давайте это исправим!

Настройка сокет-активации службы SSH была детально рассмотрена в одной из предыдущих статей, поэтому ограничусь приведением содержимого необходимых для этого конфигурационных файлов. Файл настроек для сокета (/srv/mycontainer/etc/systemd/system/sshd.socket)<sup>88</sup>:

<sup>&</sup>lt;sup>86</sup>Прим. перев.: Ручной запуск на хосте соответствующей команды systemd-nspawn -b во время работы такой службы просто создаст *еще один контейнер*. Хотя корневой каталог у них один и тот же, пространства имен (например, списки процессов) у каждого будут свои. Подключиться к работающему контейнеру можно при помощи утилиты nsenter, которая включена в состав util-linux начиная с версии 2.23 (на момент написания исходной статьи этой утилиты еще не существовало).

<sup>&</sup>lt;sup>87</sup>Прим. перев.: До выхода 209 версии systemd, возможности по виртуализации сети в systemd-nspawn были весьма ограниченными (поддерживалась только полная изоляция сети от хоста), что весьма затрудняло использование описываемой технологии. Впрочем, опытные администраторы легко могли найти обходные пути, например: присваивание хосту дополнительного IP-адреса (безо всякой виртуализации, командой ip addr add) и привязка слушающих сокетов к конкретным адресам (в параметре ListenStream= сокет-файлов и/или в директиве ListenAddress файла sshd\_config хоста). Начиная с systemd версии 209, systemd-nspawn предоставляет довольно широкие возможности по виртуализации сети: проброс сетевого интерфейса хоста в контейнер (--network-interface=), а также создание в контейнере виртуального сетевого интерфейса (--network-veth), связывающего его с хостом. Такой виртуальный интерфейс при необходимости может быть объединен в мост с интерфейсами хоста (--network-bridge=), что обеспечит доступ из контейнера к соответствующим сегментам сети. Подробности см. на странице руководства systemd-nspawn(1).

 $<sup>^{88}</sup>$ Прим. перев.: Обратите внимание на разницу между файлами конфигурации сокетов на хосте и в контейнере. Внутри контейнера используются параметры Accept=yes и StandardInput=socket, которые

```
[Unit]
Description=SSH Socket for Per-Connection Servers

[Socket]
ListenStream=23
Accept=yes

Соответствующий ему файл конфигурации службы
(/srv/mycontainer/etc/systemd/system/sshd@.service):

[Unit]
Description=SSH Per-Connection Server for %I

[Service]
ExecStart=-/usr/sbin/sshd -i
StandardInput=socket
```

После чего, добавим наш сокет в зависимости к цели sockets.target, чтобы systemd создавал его автоматически при succession создавал его автоматически при succession создавал его succession со succession его succession его

```
$ chroot /srv/mycontainer ln -s /etc/systemd/system/sshd.socket \
> /etc/systemd/system/sockets.target.wants/
```

Собственно, все. После того, как мы запустим на хосте юнит mycontainer.socket, systemd начнет прослушивать TCP-порт 23. При подключении к этому порту, systemd запустит контейнер и передаст сокет ему. Внутри контейнера свой systemd, в соответствии с файлом sshd.socket, примет этот сокет и запустит для нашего соединения экземпляр sshd@.service, что позволит нам залогиниться в контейнер по SSH.

Если нам нужно запуститьунтри контейнера другие службы с сокет-активацией, мы можем добавить в mycontainer.socket дополнительные сокеты. Все они будут прослушиваться, обращение к любому из них приведет к активации контейнера, и все эти сокеты будут переданы контейнеру при его активации. Внутри контейнера они будут обработаны соответствии с настройками имеющихся там сокет-юнитов. Те сокеты, для которых соответствующих юнитов не найдется, будут закрыты<sup>90</sup>, а те сокеты, которые будут настроены для прослушивания внутри контейнера, но не получены от хоста, будут активированы и доступны изнутри контейнера (а если это сетевые или файловые unix-сокеты, то и извне).

Итак, давайте отступим чуть назад и полюбуемся на результаты наших трудов. Что мы получили в итоге? Возможность настраивать на одном хосте множество контейнеров с полноценными ОС внутри, причем контейнеры запускаются только по запросу, что позволяет снизить потребление системных ресурсов и, соответственно, увеличить количество контейнеров (по сравнению с принудительной их активацией при загрузке хоста).

Разумеется, описанный подход работает только для контейнерной виртуализации, и неприменим к полной, т.е. может быть использован только с технологиями наподобие libvirt-lxc или nspawn, но не с qemu/kvm или xen.

не задействованы на хосте. Это обусловлено тем фактом, что внутри контейнера сокет-активация производится в стиле inetd (служба получает только один сокет, причем замкнутый на ее потоки STDIN и STDOUT), в то время как на стороне хоста используется штатный стиль активации systemd, при котором запущенному процессу (в данном случае systemd-nspawn) просто передаются открытые файловые дескрипторы (fd) всех сокетов. Одно из достоинств такого подхода — возможность передавать сразу несколько сокетов, что позволяет активировать внутри контейнера несколько серверов.

<sup>89</sup>Прим. перев.: Возиться вручную с командой 1n здесь совершенно необязательно. Можно просто добавить в файл sshd.socket секцию [Install], содержащую параметр WantedBy=sockets.target, после чего добавление правильного симлинка будет выполняться куда более очевидной командой systemctl --root=/srv/mycontainer enable sshd.socket.

<sup>90</sup>Прим. перев.: Стоит особо отметить, что описанная технология работает только для служб, поддерживающих сокет-активацию в режимах inetd (все классические inetd-службы, кроме встроенных) или systemd (обычно зависят от библиотеки libsystemd-daemon.so, либо содержат в исходниках заголовочный файл sd-daemon.h). Службы, которые сами открывают себе слушающий сокет и не содержат кода для приема уже открытого сокета, так активировать нельзя. Если вы будете администрировать несколько таких контейнеров, вас наверняка порадует одна из возможностей journal: при запуске на хосте утилиты journalctl с ключом -m, она автоматически обнаружит журналы гостевых контейнеров и объединит их вывод с выводом журнала хоста<sup>91</sup>. Ловко, не правда ли?

Необходимый минимум технологий для сокет-активации контейнеров, присутствует в systemd, начиная с версии 197. Тем не менее, наша работа в этой области еще не закончена, и в ближайшее время мы планируем доработать некоторые моменты. Например, сейчас, даже если все серверные службы внутри контейнера закончили обработку запросов и завершились, контейнер все равно продолжает функционировать и потреблять ресурсы хоста. Мы просто обязаны реализовать возможность автоматического завершения работы гостевой системы в такой ситуации. Причем у нас уже есть готовые наработки в этой области — мы можем задействовать уже существующую инфраструктуру, обеспечивающую автоматическое засыпание/выключение ноутбука при отсутствии активных задач и пользователей.

Впрочем, пора закругляться, а то статья получается чересчур длинной. Надеюсь, что вы смогли продраться через все эти длинные и скучные рассуждения о виртуализации, сокетах, службах, различных ОС и прочем колдунстве. Также надеюсь, что эта статья станет хорошей отправной точкой при конфигурировании мощных и хорошо масштабируемых серверных систем. За дополнительной информацией обращайтесь к документации или приходите на наш IRC-канал. Спасибо за внимание!

### 21 Интеграция с контейнерами

В последнее время, все большую популярность набирает тема использования Linux-контейнеров, а вместе с ней на первый план выходят различные реализации систем управления контейнерами, такие, как libvirt-lxc, LXC и Docker. В данной статье я попробую рассказать о некоторых механизмах интеграции между systemd и подобными системами, обеспечивающих унифицированное, «бесшовное» управление службами, работающими на хосте и в его контейнерах.

В центре нашего внимания будут находиться контейнеры операционных систем (OS containers), в которых запускается собственный процесс init. Работающая внутри такого контейнера система во многом аналогична полноценной ОС, выполняющейся на физическом компьютере<sup>92</sup>. Бо́льшая часть описанного в данной статье применима ко всем программам для управления контейнерами, разработанным с учетом рекомендаций по интеграции с systemd (в частности, такая интеграция обеспечена в libvirt-lxc). Однако, для простоты изложения, в практических примерах мы будем использовать systemd-nspawn, минималистичную утилиту для управления контейнерами, поставляемую в комплекте с systemd. Она использует те же низкоуровневые механизмы, что и другие системы управления контейнерами, но отличается предельной простотой использования, пусть даже в ущерб гибкости, универсальности и настраиваемости. Мы сами активно используем эту утилиту при разработке и тестировании systemd.

Итак, начнем. Первой нашей задачей является развертывание в отдельном каталоге образа гостевой операционной системы:

```
# yum -y --releasever=20 --nogpg --installroot=/srv/mycontainer \
> --disablerepo='*' --enablerepo=fedora \
> install systemd passwd yum fedora-release vim-minimal
```

<sup>&</sup>lt;sup>91</sup>Прим. перев.: Этот трюк работает благодаря опции -j, которую мы передаем программе systemd-nspawn при запуске контейнера (см. файл юнита выше). В соответствии с ней, в каталоге /var/log/journal хоста создается символьная ссылку на соответствующий каталог гостя. При этом, так как сообщения от гостей имеют другие machine ID, journalctl хоста не выводит их, если явно не указать -m. Подробности см. на страницах руководства systemd-nspawn(1) и journalctl(1).

 $<sup>^{92}</sup>$ Прим. перев.: Этим они отличаются от контейнеров приложений (apps containers), в которых запускается только само приложение и его вспомогательные процессы. Стоит отметить, что из-за широкого использования механизмов cgroups и namespaces в systemd, практически любой service-юнит можно превратить в контейнер приложения при помощи ряда настроек в его конфигурационном файле. См. главы 6, 12, 18.

Эта команда загрузит пакеты, необходимых для создания минимального образа Fedora 20, и установит их в каталог /srv/mycontainer. Аналогичные команды существуют и для других дистрибутивов, в частности, некоторые из них приведены в разделе примеров страницы руководства systemd-nspawn(1).

Наш контейнер практически готов, осталось лишь задать для него пароль root:

```
# systemd-nspawn -D /srv/mycontainer
Spawning container mycontainer on /srv/mycontainer
Press ^] three times within 1s to kill container.
-bash-4.2# passwd
Changing password for user root.
New password:
Retype new password:
passwd: all authentication tokens updated successfully.
-bash-4.2# ^D
Container mycontainer exited successfully.
#
```

Мы использовали systemd-nspawn в «режиме chroot», чтобы получить командную оболочку внутри контейнера (не запуская гостевую систему целиком), и из этой оболочки задать пароль root. На этом предварительная настройка заканчивается. Теперь мы можем загрузить ОС внутри контейнера и войти в нее, используя заданный нами пароль:

```
$ systemd-nspawn -D /srv/mycontainer -b
Spawning container mycontainer on /srv/mycontainer.
Press ~] three times within 1s to kill container.
systemd 208 running in system mode. (+PAM +LIBWRAP +AUDIT +SELINUX +IMA +SYSVINIT +LIBCRYPTSETUP +GCRYPT +AC
Detected virtualization 'systemd-nspawn'.
Welcome to Fedora 20 (Heisenbug)!
[ OK ] Reached target Remote File Systems.
      ] Created slice Root Slice.
      ] Created slice User and Session Slice.
  OK
      ] Created slice System Slice.
  OK
      ] Created slice system-getty.slice.
  OK
      ] Reached target Slices.
      ] Listening on Delayed Shutdown Socket.
  OK ] Listening on /dev/initctl Compatibility Named Pipe.
  OK ] Listening on Journal Socket.
        Starting Journal Service...
[ OK ] Started Journal Service.
  OK ] Reached target Paths.
        Mounting Debug File System...
        Mounting Configuration File System...
        Mounting FUSE Control File System...
         Starting Create static device nodes in /dev...
        Mounting POSIX Message Queue File System...
        Mounting Huge Pages File System...
[ OK ] Reached target Encrypted Volumes.
[ OK ] Reached target Swap.
         Mounting Temporary Directory...
         Starting Load/Save Random Seed...
  OK ] Mounted Configuration File System.
  OK
      ] Mounted FUSE Control File System.
  OK
      ] Mounted Temporary Directory.
  OK
      ] Mounted POSIX Message Queue File System.
  OK ] Mounted Debug File System.
  OK ] Mounted Huge Pages File System.
  OK ] Started Load/Save Random Seed.
```

```
OK ] Started Create static device nodes in /dev.
  OK ] Reached target Local File Systems (Pre).
[ OK ] Reached target Local File Systems.
         Starting Trigger Flushing of Journal to Persistent Storage...
         Starting Recreate Volatile Files and Directories...
[ OK ] Started Recreate Volatile Files and Directories.
         Starting Update UTMP about System Reboot/Shutdown...
  OK ] Started Trigger Flushing of Journal to Persistent Storage.
  OK ] Started Update UTMP about System Reboot/Shutdown.
  OK ] Reached target System Initialization.
  OK ] Reached target Timers.
  OK
      ] Listening on D-Bus System Message Bus Socket.
      ] Reached target Sockets.
  OK ] Reached target Basic System.
         Starting Login Service...
         Starting Permit User Sessions...
         Starting D-Bus System Message Bus...
[ OK ] Started D-Bus System Message Bus.
         Starting Cleanup of Temporary Directories...
  OK ] Started Cleanup of Temporary Directories.
  OK ] Started Permit User Sessions.
         Starting Console Getty...
  OK ] Started Console Getty.
  OK ] Reached target Login Prompts.
  OK ] Started Login Service.
  OK ] Reached target Multi-User System.
  OK ] Reached target Graphical Interface.
Fedora release 20 (Heisenbug)
Kernel 3.18.0-0.rc4.git0.1.fc22.x86_64 on an x86_64 (console)
mycontainer login: root
Password:
-bash-4.2#
```

Наш испытательный стенд готов. Начнем рассмотрение механизмов интеграции systemd и контейнеров с утилиты machinectl. Запустив ее без параметров, мы получим список работающих в данный момент контейнеров:

```
$ machinect1

MACHINE CONTAINER SERVICE
mycontainer container nspawn

1 machines listed.
```

Komanda machinectl status позволяет получить детальную информацию о выбранном контейнере:

```
—dbus.service

—5414 /bin/dbus-daemon --system --address=systemd: --nofork --nopidfile --systemd-act...

—systemd-journald.service

—5383 /usr/lib/systemd/systemd-journald

—systemd-logind.service

—5411 /usr/lib/systemd/systemd-logind

—console-getty.service

—5416 /sbin/agetty --noclear -s console 115200 38400 9600
```

В частности, она отображает дерево контрольных групп и процессов контейнера, его IP-адреса и корневой каталог.

Komanda machinectl login позволяет войти внутрь работающего контейнера, запустив в нем еще одну командную оболочку:

```
# machinectl login mycontainer
Connected to container mycontainer. Press ^] three times within 1s to exit session.
Fedora release 20 (Heisenbug)
Kernel 3.18.0-0.rc4.git0.1.fc22.x86_64 on an x86_64 (pts/0)
mycontainer login:
```

Команда machinectl reboot перезагружает контейнер:

# machinectl reboot mycontainer

Команда machinectl poweroff выключает контейнер:

# machinectl poweroff mycontainer

Пожалуй, этих минимальных сведений о machinectl должно быть достаточно. Стоит заметить, что ее функциональность не ограничиваются приведенными здесь командами. За подробностями рекомендуем обратиться к странице руководства. Еще раз отметим, что данные команды применимы не только к контейнерам на базе systemd-nspawn, но и к другим системам управления контейнерами, реализованным с учетом наших рекомендаций, в частности, libvirt-lxc.

Помимо machinectl, в systemd существует и ряд других инструментов, упрощающих работу с контейнерами. В частности, большинство управляющих утилит systemd имеют встроенную поддержку контейнеров: при помощи ключа -М вы можете указать имя нужного вам контейнера, и соответствующая утилита будет работать так, как будто запущена внутри этого контейнера<sup>93</sup>. Например (не забудьте снова запустить наш тестовый контейнер, если вы его до этого выключили):

```
# hostnamectl -M mycontainer set-hostname "wuff"
```

Приведенная здесь команда hostnamectl(1) устанавливает в локальном контейнере mycontainer имя хоста wuff».

А вот пример использования того же ключа -M в программе systemctl(1):

```
# systemctl -M mycontainer
UNTT
                                     I.OAD ACTIVE SUB
                                                             DESCRIPTION
                                     loaded active mounted
- . mount
                                                             Huge Pages File System
dev-hugepages.mount
                                     loaded active mounted
dev-mqueue.mount
                                     loaded active mounted
                                                             POSIX Message Queue File System
proc-sys-kernel-random-boot_id.mount loaded active mounted
                                                             /proc/sys/kernel/random/boot_id
[...]
time-sync.target
                                     loaded active active
                                                             System Time Synchronized
timers.target
                                     loaded active active
                                                             Timers
systemd-tmpfiles-clean.timer
                                     loaded active waiting
                                                             Daily Cleanup of Temporary Directories
```

 $<sup>^{93}</sup>$ Прим. перев.: Поддержка данной опции добавлена в systemctl, journalctl, loginctl, machinectl, hostnamectl, timedatectl, localectl, busctl, systemd-analyze, systemd-run начиная с systemd 209, в systemd-cgls — с systemd 203.

```
LOAD = Reflects whether the unit definition was properly loaded.

ACTIVE = The high-level unit activation state, i.e. generalization of SUB.

SUB = The low-level unit activation state, values depend on unit type.

49 loaded units listed. Pass --all to see loaded but inactive units, too.

To show all installed unit files use 'systemctl list-unit-files'.
```

Как нетрудно догадаться, эта команда выводит список активных юнитов гостевой системы контейнера. (Чтобы не загромождать нашу статью лишним текстом, часть листинга пропущена.)

Перезапустить службу внутри гостевой системы также не представляет проблемы:

#### # systemctl -M mycontainer restart systemd-resolved.service

Поддержка контейнеров в утилите systemctl не ограничивается ключом -М. Она имеет еще и ключ - $\mathbf{r}$  (рекурсивный режим)<sup>94</sup>, позволяющий выводить объединенный список юнитов для хоста и всех работающих гостевых систем:

```
# systemctl -r
UNIT
                                                   ACTIVE SUB
                                                                   DESCRIPTION
boot.automount
                                           loaded active waiting
                                                                   EFI System Partition Automount
                                                                   Arbitrary Executable File Formats File S
proc-sys-fs-binfmt_misc.automount
                                           loaded active waiting
sys-devices-pci0000:00-0000:00:02.0-drm-card0-card0\x2dLVDS\x2d1-intel_backlight.device loaded active plugge
[...]
timers.target
                                           loaded active active
                                                                   Timers
                                           loaded active waiting
                                                                   Daily man-db cache update
mandb.timer
systemd-tmpfiles-clean.timer
                                           loaded active waiting
                                                                   Daily Cleanup of Temporary Directories
mycontainer:-.mount
                                           loaded active mounted
                                           loaded active mounted Huge Pages File System
mycontainer:dev-hugepages.mount
mycontainer:dev-mqueue.mount
                                           loaded active mounted POSIX Message Queue File System
[...]
mycontainer:time-sync.target
                                           loaded active active
                                                                   System Time Synchronized
mycontainer:timers.target
                                           loaded active active
                                                                   Timers
mycontainer:systemd-tmpfiles-clean.timer loaded active waiting Daily Cleanup of Temporary Directories
      = Reflects whether the unit definition was properly loaded.
ACTIVE = The high-level unit activation state, i.e. generalization of SUB.
       = The low-level unit activation state, values depend on unit type.
```

Как видно из листинга, сначала выводится список юнитов хоста, после которого идет список юнитов нашего контейнера. Перед именами юнитов гостевой системы, через двоеточие, указывается имя контейнера. (По традиции, листинг сокращен.)

191 loaded units listed. Pass --all to see loaded but inactive units, too.

To show all installed unit files use 'systemctl list-unit-files'.

Komanda systemctl list-machines опрашивает процессы init всех работающих контейнеров, и по результатам выводит список работающих систем (хостовой и всех гостевых), с указанием их текущего состояния и наличия ошибок загрузки.

```
# systemctl list-machines
NAME.
             STATE.
                    FAILED JOBS
delta (host) running
                          0
                                0
mycontainer running
                          0
                               0
miau
             degraded
                          1
                                Λ
waldi
             running
                          Ω
4 machines listed.
```

<sup>&</sup>lt;sup>94</sup>Прим. перев.: Поддержка этой опции при выводе списка юнитов появилась начиная с systemd 212, при выводе списков таймеров и сокетов (systemctl list-timers и systemctl list-sockets) — начиная с systemd 213.

Для большей наглядности мы запустили еще два контейнера. В одном из них произошла ошибка запуска юнита, поэтому его состояние характеризуется как «degraded».

А теперь обсудим поддержку контейнеров в утилите journalctl(1). Во-первых, она позволяет использовать описанную выше опцию -М:

```
# journalctl -M mycontainer -n 8
Nov 12 16:51:13 wuff systemd[1]: Starting Graphical Interface.
Nov 12 16:51:13 wuff systemd[1]: Reached target Graphical Interface.
Nov 12 16:51:13 wuff systemd[1]: Starting Update UTMP about System Runlevel Changes...
Nov 12 16:51:13 wuff systemd[1]: Started Stop Read-Ahead Data Collection 10s After Completed Startup.
Nov 12 16:51:13 wuff systemd[1]: Started Update UTMP about System Runlevel Changes.
Nov 12 16:51:13 wuff systemd[1]: Startup finished in 399ms.
Nov 12 16:51:13 wuff sshd[35]: Server listening on 0.0.0.0 port 24.
Nov 12 16:51:13 wuff sshd[35]: Server listening on :: port 24.
```

Во-вторых, стоит упомянуть опцию -m (режим слияния), выводящую объединенный поток журнальных записей хоста и всех его гостевых систем<sup>95</sup>.:

```
# journalctl -m -e
```

(Здесь вывод команды опущен полностью. Думаю, вам будет несложно представить себе, как он выглядит.)

Поддержка контейнеров присутствует не только в утилитах systemd, но и в программах из комплекта  $procps^{96}$ :

```
# ps -eo pid,machine,args
PID MACHINE
  1 -
                    /usr/lib/systemd/systemd --switched-root --system --deserialize 20
[...]
2915 -
                    emacs contents/projects/containers.md
3403 -
                   [kworker/u16:7]
3415 -
                    [kworker/u16:9]
4501 -
                   /usr/libexec/nm-vpnc-service
4519 -
                   /usr/sbin/vpnc --non-inter --no-detach --pid-file /var/run/NetworkManager/nm-vpnc-bfda86
4749 -
                   /usr/libexec/dconf-service
4980 -
                    /usr/lib/systemd/systemd-resolved
5006 -
                    /usr/lib64/firefox/firefox
5168 -
                    [kworker/u16:0]
5192 -
                    [kworker/u16:4]
5193 -
                    [kworker/u16:5]
5497 -
                   [kworker/u16:1]
5591 -
                   [kworker/u16:8]
5711 -
                   sudo -s
5715 -
                   /bin/bash
5749 -
                   /home/lennart/projects/systemd/systemd-nspawn -D /srv/mycontainer -b
5750 mycontainer
                   /usr/lib/systemd/systemd
5799 mycontainer
                   /usr/lib/systemd/systemd-journald
5862 mycontainer
                   /usr/lib/systemd/systemd-logind
5863 mycontainer
                   /bin/dbus-daemon --system --address=systemd: --nofork --nopidfile --systemd-activation
5868 mycontainer
                   /sbin/agetty --noclear --keep-baud console 115200 38400 9600 vt102
5871 mycontainer
                   /usr/sbin/sshd -D
6527 mycontainer
                   /usr/lib/systemd/systemd-resolved
[...]
```

Здесь приводится (сокращенный) список процессов хоста и всех гостевых систем. Во втором столбце указывается имя контейнера («-» соответствует системе хоста).

<sup>&</sup>lt;sup>95</sup>Прим. перев.: Чтобы данная опция действительно работала именно так, необходимо, чтобы в каталоге /var/log/journal хоста присутствовали символьные ссылки на каталоги с логами гостевых систем, либо было выполнено их bind-монтирование. См. примечание 91. Стоит заметить что, помимо логов контейнеров, в этом каталоге могут оказаться и логи других компьютеров, если у вас настроен их сбор с помощью systemd-journal-remote(8) или иных инструментов.

<sup>&</sup>lt;sup>96</sup>Прим. перев.: Начиная с выпуска procps 3.3.8.

Ho наша работа по поддержке взаимодействия с контейнерами этим не ограничивается. В частности, мы добавили такую поддержку в «sd-bus» — разрабатываемую нами клиентскую библиотеку D-Bus/kdbus. Если вызов sd\_bus\_open\_system() позволяет подключаться к шине вашей локальной системы, то sd\_bus\_open\_system\_container() открывает соединение к шине выбранного гостевого контейнера, обеспечивая прямой доступ к ее интерфейсам и методам.

sd-login.h и D-Bus интерфейс демона machined предоставляют API для реализации поддержки контейнеров в сторонних программах. В частности, они содержат функции для определения имени контейнера по PID процесса, получения списка работающих контейнеров и т.д.

systemd-networkd также имеет встроенную поддержку контейнеров. Когда он запускается внутри контейнера, он автоматически задействует DHCP-клиент и выполняет настройку IPv4LL-адреса<sup>97</sup> на виртуальном сетевом интерфейсе с именем host0 (имя и назначение этого интерфейса оговаривается в наших рекомендациях, которые должны поддерживаться вашей системой управления контейнерами). Когда networkd работает на хост-системе, он предоставляет функции DHCP-сервера и настраивает IPv4LL-адреса на всех виртуальных интерфейсах с именами вида ve-имя\_контейнера.

И наконец, последний из рассматриваемых в этой статье аспектов интеграции systemd и контейнеров: взаимодействие с NSS. В составе свежих версий systemd <sup>98</sup> поставляется NSS-модуль nss-mymachines, позволяющий преобразовывать имена контейнеров в их IP-адреса при помощи вызовов gethostbyname() и getaddrinfo(). Разумеется, это применимо лишь к контейнерам, которые имеют собственное сетевое пространство имен (netns), т.е. свой сетевой стек. Команда systemd-nspawn, приведенная выше, запускает контейнер в сетевом стеке хоста, поэтому, чтобы продемонстрировать работу обсуждаемых механизмов, нам придется перезапустить этот контейнер с отдельным сетевым стеком, в котором systemd-nspawn создаст виртуальный сетевой интерфейс (veth), связывающий контейнер с хостом:

```
# machinectl poweroff mycontainer
# systemd-nspawn -D /srv/mycontainer --network-veth -b
```

Теперь, если в контейнере и на хосте работает systemd-networkd, мы можем обращаться к контейнеру через сеть просто по его имени, которое при помощи модуля nss-mymachines будет автоматически преобразовано в его IP-адрес $^{99}$ :

```
# ping mycontainer
PING mycontainer (10.0.0.2) 56(84) bytes of data.
64 bytes from mycontainer (10.0.0.2): icmp_seq=1 ttl=64 time=0.124 ms
64 bytes from mycontainer (10.0.0.2): icmp_seq=2 ttl=64 time=0.078 ms
```

Разумеется, преобразование имен контейнеров в IP-адреса и обратно работает не только для утилиты ping, но и для всех остальных программ, использующих функции libc gethostbyname() и getaddrinfo(), в том числе и для нашей любимой и незаменимой ssh.

Вот и все, о чем я хотел рассказать в данной статье. Мы кратко прошлись по основным моментам интеграции systemd и контейнеров. Изложение не претендует на полноту, и очень многие детали оказались «за бортом» — о них вы можете узнать из документации. Кроме того, в настоящее время мы продолжаем работу над более тесной интеграцией с контейнерами, так что ожидайте новых возможностей в этой области с ближайшими выпусками systemd.

<sup>97</sup>Прим. перев.: Механизм IPv4LL предоставляет простой метод автоматической настройки сетевых адресов в пределах одного сегмента. Сетевому интерфейсу присваивается случайно выбранный незанятый IP-адрес из специально зарезервированного диапазона 162.254.0.0/16.

<sup>&</sup>lt;sup>98</sup>Прим. перев.: Начиная с версии 216.

<sup>&</sup>lt;sup>99</sup>Прим. перев.: Для корректной работы модуля nss-mymachines, он должен быть указан в конфигу-рационном файле /etc/nsswitch.conf, в строке hosts. В частности, в поставляемом с systemd варианте этого файла, данная строчка выглядит так: «hosts: files mymachines resolve myhostname». Помимо mymachines, в ней фигурируют и другие NSS-модули systemd: resolve отвечает за взаимодействие с кэширующим DNS-сервером systemd-resolved, а myhostname обеспечивает корректное преобразование системного имени хоста в IP-адрес 127.0.0.2, даже при отсутствии соответствующей записи в /etc/hosts.

В завершение стоит отметить, что концепция машины (machine) применима не только к контейнерам, но и, в некоторой степени, к полноценным виртуальным машинами. Однако, в случае виртуальных машин, доступ к гостевым системам с хоста реализуется несколько сложнее, чем в контейнерах — вместо прямого доступа к системным вызовам, приходится использовать взаимодействие через сеть 100.

В любом случае, надеюсь, что статья для кого-то оказалась полезной. За подробностями обращайтесь к документации (начать изучение темы можно со ссылок, приведенных в этой статье).

## А FAQ (часто задаваемые вопросы) $^{101}$

Также смотрите статью Tips & Tricks<sup>102</sup>.

#### Boпрос: Как изменить текущий уровень выполнения (runlevel)?

Ответ: В systemd уровни выполнения оформлены в виде целевых состояний (target units). Команда перехода в заданное состояние выглядит так:

#### # systemctl isolate runlevel5.target

Отметим, что концепция уровней исполнения уже порядком устарела, и вместо номеров уровней удобнее оперировать более выразительными именами целевых состояний:

#### # systemctl isolate graphical.target

Подобные команды изменят только текущий уровень выполнения. Их действие никак не повлияет на последующие загрузки системы.

## Вопрос: Как изменить уровень выполнения, в который система грузится по умолчанию?

Ответ: Соответствующее целевое состояние задается символьной ссылкой /etc/systemd/system/default.target. Для его смены достаточно перезаписать эту ссылку $^{103}$ . Например, так:

# ln -sf /usr/lib/systemd/system/multi-user.target /etc/systemd/system/default.target или так

# ln -sf /usr/lib/systemd/system/graphical.target /etc/systemd/system/default.target

#### Вопрос: Как узнать текущий уровень выполнения?

Ответ: В один и тот же момент времени может быть активно несколько целевых состояний, поэтому понятие текущего уровня выполнения (единственного и однозначно определенного) применимо уже далеко не всегда. Узнать, какие состояния сейчас активны, вы можете при помощи команды

#### \$ systemctl list-units --type=target

Если вам нужна именно одна цифра, вы можете воспользоваться классической командой runlevel, однако, по изложенным выше причинам, она далеко не всегда способна адекватно оценить текущую ситуацию.

<sup>100</sup>Прим. перев.: Можно предположить, что здесь автор пытается намекнуть на опцию -H [user@]host[:container], позволяющую обращаться к другим хостам и их контейнерам через сеть при помощи SSH-транспорта, реализованного в шине D-Bus. Эта опция поддерживается в большинстве управляющих утилит systemd (systemctl, loginctl, machinectl, hostnamectl, timedatectl, localectl, busctl, systemd-analyze, systemd-run).

 $<sup>^{101}</sup>$ Прим. перев.: Перевод статьи «Frequently Asked Questions» с официального сайта проекта, по состоянию на 2013-05-26 08:17:02 (коммит 8cf2b).

 $<sup>^{102}</sup>$ Прим. перев.: На самом деле, смотреть там особо не на что. Бо́льшая часть приведенного там материала вполне соответствует формату FAQ, и поэтому была перенесена в текущую главу. Исключением являются только «cgroup tree» и «ps with cgroups», но они подробно рассмотрены в главе  $^{2}$ .

<sup>103</sup>Прим. перев.: Начиная с systemd 205, в программу systemctl были добавлены команды set-default и get-default, упрощающие подобные действия, например, systemctl set-default multi-user.target.

## Вопрос: Я изменил service-файл, но пакетный менеджер перезаписывает мои изменения при каждом обновлении. Что делать?

Ответ: Наиболее разумным решением будет скопировать исходный файл из /usr/lib/systemd/system в /etc/systemd/system и внести изменения в полученную копию. Юнит-файлы из /etc защищены от посягательств пакетного менеджера, и при этом имеют приоритет над файлами из /usr. Если же вы захотите вернуться к настройкам по умолчанию, достаточно будет просто удалить или переименовать созданный вами файл<sup>104</sup>.

Вопрос: Служба foo.service по умолчанию запускается только при поступлении входящего соединения (или подключении определенного оборудования, или при появлении заданного файла). Как сделать так, чтобы она запускалась сразу при загрузке?

Ответ: Достаточно поместить символьную ссылку на соответствующий service-файл в каталог multi-user.target.wants/.

```
# ln -sf /usr/lib/systemd/system/foobar.service \
> /etc/systemd/system/multi-user.target.wants/foobar.service
# systemctl daemon-reload
```

В это каталоге содержатся ссылки на все юниты, которые нужно запустить в состоянии multi-user (эквивалент уровня выполнения 3, т.е. загрузка с запуском всех служб, но не графического интерфейса). Так как цель graphical.target тянет по зависимости и multi-user.target, то ваша служба будет запущена также и при «графических» загрузках.

#### Вопрос: Я хочу запустить еще один экземпляр getty, как это сделать?

Ответ: Для запуска getty на последовательном порту, достаточно запустить соответствующий экземпляр службы serial-getty@.service:

```
# systemctl start serial-getty@ttyS2.service
```

Чтобы обеспечить автоматически запуск getty на этом порту при каждой загрузке, нужно поместить соответствующую символьную ссылку в каталог getty.target.wants/ $^{105}$ :

```
# ln -s /usr/lib/systemd/system/serial-getty@.service \
> /etc/systemd/system/getty.target.wants/serial-getty@ttyS2.service
# systemctl daemon-reload
```

Обратите внимание, что на виртуальных терминалах getty запускаются автоматически, как только пользователь переключается на данный терминал. Максимальное количество таких терминалов задается параметром NAutoVTs= в файле logind.conf(7). Также см. главу 16.

#### Вопрос: Как узнать, какой службе принадлежат вот эти процессы?

Ответ: Для этого можно воспользоваться командой рв

<sup>&</sup>lt;sup>104</sup>Прим. перев.: Начиная с версии systemd 198, необязательно копировать файл целиком, если вы хотите добавить/изменить отдельные настройки. Можно просто создать в /etc/systemd/system/ под-каталог имя\_службы.service.d, а в нем — файл с именем, заканчивающимся на .conf, например, mysettings.conf, после чего вписать в этот файл необходимые настройки. Они будут применены «поверх» настроек из штатного файла (расположенного в /usr).

<sup>&</sup>lt;sup>105</sup>Прим. перев.: Приведенная в оригинале команда systemctl enable serial-getty@ttyS2.service в systemd версии 209 и ниже работать не будет. Подробнее см. примечание 64.

```
930 root
             name=systemd:/systemd-1/ntpd.service /usr/sbin/ntpd -n
932 root
             name=systemd:/systemd-1/crond.service /usr/sbin/crond -n
935 root
             name=systemd:/systemd-1/auditd.service /sbin/auditd -n
             name=systemd:/systemd-1/auditd.service \_ /sbin/audispd
943 root
                                                         \_ /usr/sbin/sedispatch
964 root
             name=systemd:/systemd-1/auditd.service
937 root
             name=systemd:/systemd-1/acpid.service /usr/sbin/acpid -f
941 rpc
             name=systemd:/systemd-1/rpcbind.service /sbin/rpcbind -f
             name=systemd:/systemd-1/rsyslog.service /sbin/rsyslogd -n -c 4
944 root
947 root
             name=systemd:/systemd-logger.service /lib/systemd/systemd-logger
950 root
             name=systemd:/systemd-1/cups.service /usr/sbin/cupsd -f
             name=systemd:/systemd-1/messagebus.service/bin/dbus-daemon--system --address=systemd:--nof
955 dbus
969 root
             name=systemd:/systemd-1/getty@.service/tty6 /sbin/mingetty tty6
970 root
             name=systemd:/systemd-1/getty@.service/tty5 /sbin/mingetty tty5
             name=systemd:/systemd-1/getty@.service/tty1 /sbin/mingetty tty1
971 root
973 root
             name=systemd:/systemd-1/getty@.service/tty4 /sbin/mingetty tty4
974 root
             name=systemd:/user/lennart/2
                                                 login -- lennart
1824 lennart name=systemd:/user/lennart/2
                                                  \_ -bash
             name=systemd:/systemd-1/getty@.service/tty3 /sbin/mingetty tty3
975 root
             name=systemd:/systemd-1/polkitd.service /usr/libexec/polkit-1/polkitd
988 root
994 rtkit
             name=systemd:/systemd-1/rtkit-daemon.service/usr/libexec/rtkit-daemon
```

или просто посмотреть /proc/\$PID/cgroup. Также см. главу 2.

Вопрос: Почему вы не используете inotify для отслеживания изменений в настройках?

Ответ: К сожалению, реализовать это весьма проблематично. За подробностями вы можете обратиться к обсуждению в  $bugzilla^{106}$ .

Вопрос: У моей службы есть как штатный service-файл, так и init-скрипт (с тем же именем). Какой из этих файлов главнее — /usr/lib/system/system/foobar.service или /etc/init.d/foobar?

Ответ: При наличии обоих этих файлов, приоритет всегда отдается штатному service-файлу, независимо от того, включен ли запуск соответствующего скрипта (например, через chkconfig) или нет. Обратите внимание, что отключение юнит-файла (в частности, через systemctl disable) приведет к полному отключению службы, даже если init-скрипт при этом будет включен.

Вопрос: Как заставить journalctl выводить полные (не сокращенные) строки?

Ответ: Используйте

# journalctl --full

Вопрос: Моя служба пытается получить приоритет реального времени, но получает ошибку EPERM, хотя обладает всеми необходимыми привилегиями. А без вашего systemd все работало!

Ответ: По умолчанию, systemd помещает каждую системную службу в собственную контрольную группу контроллера сри. К сожалению, из-за существующего в реализации данного контроллера ограничения, это приводит к невозможности получения приоритета реального времени для служб. Подробное обсуждение этой проблемы и методы ее решения смотрите в приложении G.

Вопрос: Моя служба настроена на запуск после network.target, однако она все равно запускается раньше, чем появляется сеть. Почему?

Ответ: Это длинная история. См. приложение F.

<sup>106</sup>Прим. перев.: Вкратце, суть проблемы состоит в том, что перемещение/переименование файла не является атомарной операцией, а состоит из удаления одного файла и создания другого. Эти операции могут следовать в произвольном порядке с некоторым интервалом, что может привести к временному исчезновению службы, либо к появлению двух конфликтующих служб.

#### Bonpoc: systemd монтирует в /tmp tmpfs. Как это отключить?

Ответ: Это тоже долгая история. См. приложение Е.

#### Вопрос: Как просмотреть список работающих служб?

Ответ: Запустите команду systemctl без параметров $^{107}$ :

\$	systemctl					
U	UNIT	LOAD	ACTIVE	SUB	JOB	DESCRIPTION
a	ccounts-daemon.service	loaded	active	running		Accounts Service
a	td.service	loaded	active	running		Job spooling tools
a	vahi-daemon.service	loaded	active	running		Avahi mDNS/DNS-SD Stack
b	luetooth.service	loaded	active	running		Bluetooth Manager
С	colord-sane.service	loaded	active	running		Daemon for monitoring attached scanners and registering
С	colord.service	loaded	active	running		Manage, Install and Generate Color Profiles
С	rond.service	loaded	active	running		Command Scheduler
С	ups.service	loaded	active	running		CUPS Printing Service
ď	lbus.service	loaded	active	running		D-Bus System Message Bus
١.						

#### Вопрос: Как узнать текущее состояние службы?

Ответ: Воспользуйтесь командой systemctl status:

#### Вопрос: Как отследить зависимости между юнитами?

Ответ: Допустим, вы хотите узнать, какие юниты будут запущены при активации multi-user.target:

```
$ systemctl show -p "Wants" multi-user.target
Wants=rc-local.service avahi-daemon.service rpcbind.service
NetworkManager.service acpid.service dbus.service atd.service crond.service
auditd.service ntpd.service udisks.service bluetooth.service cups.service
wpa_supplicant.service getty.target modem-manager.service portreserve.service
abrtd.service yum-updatesd.service upowerd.service test-first.service
pcscd.service rsyslog.service haldaemon.service remote-fs.target
plymouth-quit.service systemd-update-utmp-runlevel.service sendmail.service
lvm2-monitor.service cpuspeed.service udev-post.service mdmonitor.service
iscsid.service livesys.service livesys-late.service irqbalance.service
iscsi.service netfs.service
```

 $<sup>^{107}</sup>$ Прим. перев.: systemctl без параметров выведет состояние всех активных юнитов (в т.ч. сокетов, устройств, точек монтирования, целевых состояний, таймеров, и т.д.). Чтобы ограничиться только службами, добавьте параметр -t service. Чтобы вывести все службы/юниты, включая неактивные, добавьте параметр -a.

Bместо Wants вы можете использовать другие типы зависимостей: WantedBy, Requires, RequiredBy, Conflicts, ConflictedBy, Before, After 108109.

Вопрос: Как узнать, что будет запущено при загрузке системы в заданное целевое состояние?

Ответ: Вы можете заставить systemd рассчитать «начальную» транзакцию, определяющую алгоритм загрузки в заданное состояние foobar.target:

```
$ systemd --test --system --unit=foobar.target
```

Обратите внимание, что эта команда предназначена исключительно для отладки, и ее работа на самом деле не ограничивается расчетом транзакции, поэтому не стоит вызывать ее в скриптах.

### В Диагностика неполадок<sup>110</sup>

#### В.1 Диагностика проблем с загрузкой

Eсли система зависает во время загрузки, прежде всего нужно разобраться, на каком этапе возникает проблема — до запуска systemd, или после.

Для этого надо удалить из командной стоки ядра параметры quiet и rhgb. При работе systemd на экран выводятся примерно такие сообщения:

```
Welcome to Fedora BEPCUЯ (имя релиза)!
Starting название...

[ ОК ] Stared название...
```

(Пример можно посмотреть на скриншоте.)

Если у вас есть доступ к оболочке, это значительно упрощает диагностику и решение проблем. В том случае, когда до приглашения входа в систему дело так и не доходит, попробуйте переключиться на другую виртуальную консоль, нажав  $CTRL-ALT-F<uu\phi pa>$ . При проблемах, связанных с запуском графического сервера, может возникать ситуация, когда на первой консоли (tty1) приглашение ко входу отсутствует, но все остальные консоли при этом работают нормально.

Если ни на одной из виртуальных консолей приглашение так и не появилось — попробуйте выждать еще не менее 5 минут. Только после этого можно будет считать процесс загрузки окончательно зависшим. Если подвисание обусловлено всего лишь сбоем при запуске какой-то службы, то после истечения тайм-аута проблемная служба будет убита, и загрузка продолжится. Другой вариант — отсутствует устройство, которое должно быть смонтировано для нормальной работы системы. В этом случае загрузка будет остановлена, и система перейдет в аварийный режим (emergency mode).

#### В.1.1 Если у вас нет доступа к оболочке

Если система не предоставила вам ни нормального приглашения, ни аварийной оболочки, то для диагностики проблемы нужно выполнить следующие действия:

 $<sup>^{108}</sup>$ Прим. перев.: Разница между \*s и \*edBy — в направлении зависимости. Например, если цель multi-user.target запрашивает запуск (Wants) службы rc-local.service, то она будет указана в свойстве WantedBy этой службы. Интересно, что свойство ConflictedBy существует, однако задать его напрямую нельзя — оно формируется только на основании Conflicts других служб. Что касается разницы между Wants и Requires, то первое является пожеланием, а второе требованием. Если требуемый (required) юнит не сможет запуститься, то не запустится и сам зависящий от него юнит. Пожелания (wants) не накладывают такого ограничения — будет сделана попытка запуска зависимого юнита, но результат ее никак не отразится на зависящем юните. А указания  $nop_{\mathcal{R}} \partial_{\mathcal{R}} a$  запуска (Before, After) вообще не формируют зависимостей и работают только тогда, когда такие зависимости, прямо или косвенно, уже заданы.

<sup>&</sup>lt;sup>109</sup>Прим. перев. Отметим, что начиная с systemd 198, systemctl поддерживает специализированную команду list-dependencies, позволяющую отследить прямые и косвенные («рекурсивные») зависимости заданного юнита.

 $<sup>^{110}</sup>$ Прим. перев.: Перевод статьи «Debugging systemd Problems» с официального сайта проекта, по состоянию на 2017-01-29 06:18:38 (коммит 903f7).

- Попытайтесь перезагрузить систему, нажав CTRL—ALT—DEL. Если после этого перезагрузки не произойдет обязательно укажите данное обстоятельство, когда будете писать отчет об ошибке (bugreport). Чтобы перезагрузить систему, вы можете воспользоваться SysRq или «аппаратным» методом.
- При следующей загрузке попробуйте воспользоваться некоторыми нижеописанными стратегиями.

Вывод диагностических сообщений на последовательную консоль Если у вас под рукой есть терминал последовательной консоли, либо дело происходит в виртуальной машине (в частности, virt-manager позволяет просматривать вывод виртуальной машины на последовательную консоль: меню Вид (View) ⇒ Текстовые консоли (Text Consoles)), вы можете попросить systemd выводить на эту консоль подробную отладочную информацию о ходе загрузки, добавив к параметрам ядра следующие аргументы<sup>111</sup>:

systemd.log\_level=debug systemd.log\_target=console console=ttyS0,38400

Вышеприведенный способ удобен для диагностики проблем, непосредственно связанных с systemd. Если же сбой происходит при запуске системных служб (например, сети), целесообразно перенаправить на консоль вывод системного журнала:

systemd.journald.forward\_to\_console=1 console=ttyS0,38400

#### Загрузка в восстановительном (rescue) или аварийном (emergency) режимах

Чтобы загрузиться в восстановительном режиме, добавьте к параметрам ядра systemd.unit=rescue.target, или просто 1. Это режим эффективен для решения проблем, возникающих на этапе запуска обычных служб, когда ключевые компоненты системы уже инициализированы. В такой ситуации, вы можете просто отключить проблемную службу. Если же загрузка не доходит даже до восстановительного режима — попробуйте менее требовательный, аварийный режим.

Для загрузки напрямую в режим аварийной оболочки, добавьте к параметрам ядра systemd.unit=emergency.target, или просто emergency. Обратите внимание, что в аварийном режиме корневая система по умолчанию монтируется в режиме «только для чтения», поэтому перед восстановительными работами, связанными с записью на диск, необходимо перемонтировать ее в режиме «для чтения и записи»:

mount -o remount, rw /

Как правило, аварийная оболочка используется для исправления некорректных записей в /etc/fstab. После внесения необходимых изменений, скомандуйте systemctl daemon-reload, чтобы systemd увидел ваши исправления.

Если не работает даже аварийный режим, попробуйте загрузиться напрямую в оболочку, добавив к параметрам ядра init=/bin/sh. Такая ситуация может возникнуть вследствие повреждения бинарного файла systemd, либо библиотек, которые он использует. В этом случае может помочь переустановка соответствующих пакетов.

Если не срабатывает даже init=/bin/sh, остается лишь попробовать загрузиться с другого носителя.

<sup>111</sup> Прим. перев.: Стоит упомянуть еще об одном отладочном инструменте — netconsole. Это механизм ядра, позволяющий отправлять содержимое буфера kmsg (см. dmesg(8)) по сети на заданный компьютер. Обратите внимание, что его настройка через командную строку ядра (параметр netconsole=...) работает только если он вкомпилирован в ядро монолитно. Если же он собран модулем, его необходимо настраивать через /etc/modprobe.d/\*.conf или configfs (впрочем, некоторые версии modprobe поддерживают чтение параметров модулей из командной строки ядра, так что можно попробовать добавить туда netconsole.netconsole=...), а также задавать его принудительную подгрузку через параметр ядра modules-load=netconsole. Кроме того, при этом надо обеспечить перенаправление логов systemd в буфер ядра — соответствующие параметры см. в разделе В.1.2.

Отладочная оболочка Вы можете включить специальную отладочную оболочку, которая запускается в отдельной консоли на раннем этапе загрузки и позволяет собрать необходимую диагностическую информацию, а также провести восстановительные операции. Для включения отладочной оболочки скомандуйте

systemctl enable debug-shell.service

или укажите

systemd.debug-shell=1

в строке параметров ядра при загрузке.

**Совет:** Если вышеприведенная команда **systemctl enable** сообщает об ошибке соединения с системным менеджером (такое возможно, например, если вы загрузились с помощью другой операционной системы), вы можете запустить ее в «автономном режиме», явно указав параметр --root=:

systemctl --root=/ enable debug-shell.service

Отладочная оболочка будет запущена с правами root на консоли tty9 при следующей загрузке системы. Чтобы переключиться на нее, нажмите CTRL-ALT-F9. Оболочка запускается на самом раннем этапе загрузки и позволяет вам проверять состояние служб, читать системные журналы, выявлять зависшие задачи (командой systemctl list-jobs) и т.д.

**Предупреждение:** Используйте эту оболочку только для отладки! Не забудьте отключить ее после того, как разберетесь с проблемами. Оставлять доступную всем и каждому оболочку с правами **root**, мягко говоря, небезопасно.

Проверка параметров ядра Для корректной загрузки системы необходимо, чтобы каталог /dev был заполнен, хотя бы частично. Убедитесь, что ядро Linux собрано с опциями CONFIG\_DEVTMPFS и CONFIG\_DEVTMPFS\_MOUNT. Кроме того, для корректной работы systemd рекомендуется включить поддержку контрольных групп и fanotify (опции CONFIG\_CGROUPS и CONFIG\_FANOTIFY соответственно). Отключение этих опций может привести к появлению сообщений об ошибках вида «Failed to get D-Bus connection: No connection to service manager.» при попытке запуска systemctl.

#### В.1.2 Если у вас есть доступ к оболочке

Если вам все-таки удалось получить доступ к оболочке системы, вы можете воспользоваться ею для сбора диагностической информации. Загрузите систему со следующими параметрами ядра:

```
systemd.log_level=debug systemd.log_target=kmsg log_buf_len=1M printk.devkmsg=on
```

В соответствии с ними, systemd будет выводить максимально подробные сообщения о процессе загрузки, и направлять их в кольцевой буфер ядра (предпоследний параметр обеспечивает соответствующее увеличение размера буфера, последний параметр снимает ограничение на скорость вывода сообщений в буфер). Дождавшись запуска оболочки, вы можете просмотреть полученный журнал:

journalctl -b

Отправляя отчет об ошибке, перенаправьте вывод этой команды в файл и присоедините его к отчету.

Также, вы можете просмотреть список операций, чтобы выявить зависшие задачи:

systemctl list-jobs

Операции, находящиеся в состоянии «waiting», будут запущены на исполнение только после того, как завершатся операции, выполняемые в данный момент (состояние «running»).

#### В.2 Диагностика проблем с выключением системы

При зависании системы во время выключения, как и в случае с загрузкой, рекомендуется подождать *минимум 5 минут*, чтобы отличить полное зависание системы от временного подвисания из-за проблем с отдельными службами. Также стоит проверить, реагирует ли система на нажатие CTRL—ALT—DEL.

Если процесс остановки системы (при выключении или перезагрузке) зависает полностью, прежде всего нужно убедиться, способно ли ядро Linux выключить или перезагрузить систему. Для этого воспользуйтесь одной из команд:

```
reboot -f
poweroff -f
```

Если хотя бы одна из этих команд не сработает — значит, проблема скорее всего не в systemd, а в ядре.

#### В.2.1 Система очень долго выключается

Если ваша система все же может выключиться/перезагрузиться, но этот процесс длится подозрительно долго, выполните нижеописанные операции:

• Загрузите систему со следующими параметрами ядра:

systemd.log\_level=debug systemd.log\_target=kmsg log\_buf\_len=1M printk.devkmsg=on enforcing=0

• Cоздайте файл /usr/lib/systemd/system-shutdown/debug.sh, добавьте ему право на запуск и запишите в него следующие строки:

```
#!/bin/sh
mount -o remount,rw /
dmesg > /shutdown-log.txt
mount -o remount,ro /
```

• Перезагрузите систему.

После этого вы можете самостоятельно проанализировать файл /shutdown-log.txt, u/или присоединить его к вашему сообщению об ошибке.

#### В.2.2 Система не может выключиться самостоятельно

Если процесс выключения или перезагрузки вашей системы не завершается даже через несколько минут, и вышеописанный метод с shutdown-log не сработал, вы можете собрать диагностическую информацию другими методами (которые мы уже рассматривали применительно к проблемам загрузки):

- Используйте последовательную консоль 112.
- Воспользуйтесь отладочной оболочкой она полезна не только на ранних стадиях загрузки, но и на поздних стадиях остановки системы.

#### В.3 Просмотр состояния службы и ее журнала

Когда при запуске службы происходит сбой, systemd выводит весьма абстрактное сообщение об ошибке:

```
# systemctl start foo.service
Job failed. See system journal and 'systemctl status' for details.
```

 $<sup>^{112}\</sup>Pi$ рим. перев.: Здесь опять же стоит напомнить про netconsole (см. примечание 111).

При этом сама служба может выводить собственное сообщение, но вы (пока что) его не видите. Дело в том, что запуск служб происходит не из вашей оболочки, а из процесса systemd, и поэтому вывод программы не привязан к вашей консоли. Тем не менее, это вовсе не означает, что выводимые сообщения теряются. По умолчанию, потоки STDOUT и STDERR, принадлежащие запускаемым службам, перенаправляются в системный журнал (journal). Туда же попадают и сообщения, отправляемые с помощью функции syslog(3). Кроме того, systemd записывает код выхода сбойных процессов. Посмотреть собранные данные можно, например, так:

В нашем примере, служба запустилась как процесс с идентификатором (PID) 1329, после чего завершилась с кодом выхода 1. Если вы запустили команду systemctl status от имени пользователя root, либо от имени пользователя, входящего в группу adm, вы также увидите последние несколько строчек, записанные службой в журнал. В нашем примере служба выдала всего одно сообщение («Failed to parse config»).

Чтобы просмотреть весь журнал целиком, воспользуйтесь командой journalctl.

Если одновременно с journal вы используете и классический демон системного лога (например, rsyslog), то все сообщения из журнала будут переданы также и этому демону, который запишет их в традиционные лог-файлы (в какие именно — зависит от его настроек, обычно /var/log/messages).

#### В.4 Подготовка сообщений об ошибках

Если вы собираетесь отправить сообщение об ошибке systemd, пожалуйста, включите в него диагностическую информацию, в частности, содержимое системных журналов. Журналы должны быть полными (без вырезок) и не заархивированными.

Прежде всего, отправьте сообщение в багтрекер своего дистрибутива. Если же вы твердо уверены, что проблема именно в апстримном systemd, проверьте сначала список уже известных ошибок. Если вы не найдете в нем своего случая — заводите новую запись.

#### В.4.1 Что нужно включить в сообщение об ошибке

По возможности, пожалуйста, укажите в самом сообщении, либо присоедините к нему, следующую информацию:

- Строку параметров ядра. Ее можно найти в файле конфигурации загрузчика (например, /boot/grub2/grub.cfg) или в специальном файле /proc/cmdline.
- Файл journal.txt, полученный после выполнения команды

```
journalctl -b > journal.txt
```

Перед ее выполнением желательно загрузиться с параметрами ядра

systemd.log\_level=debug systemd.log\_target=kmsg log\_buf\_len=1M printk.devkmsg=on

• Файл systemd-dump.txt, полученный в результате выполнения команды<sup>113</sup>

```
systemd-analyze dump > systemd-dump.txt
```

 $<sup>^{113}</sup>$ Прим. перев.: В версиях systemd до 206 включительно, вместо systemd-analyze dump нужно было использовать systemctl dump.

Файл systemd-test.txt, полученный при помощи команды
 //usr/bin/systemd --test --system --log-level=debug > systemd-test.txt 2>&1

### C Совместимость с SysV<sup>114</sup>

systemd обеспечивает высокий уровень совместимости с поведением классической системы инициализации SysV init, реализованной во многих дистрибутивах. Это касается как непосредственного взаимодействия с пользователем, так и поддержки API для скриптов. Тем не менее, существует ряд ограничений, обусловленных техническими соображениями, а также особенностями дизайна systemd и/или дистрибутивов. Ниже приведен список таких ограничений. Большая их часть затрагивает дистрибутивноспецифичные расширения SysV init, и поэтому будет ощутима только для пользователей отдельных дистрибутивов.

- Если разработчики вашего дистрибутива отказались от SysV init-скрипта в пользу штатного юнит-файла, прямой вызов этого скрипта (например, /etc/init.d/foobar start), очевидно, работать не будет. Лучше воспользоваться стандартной и универсальной командой /sbin/service foobar start, которая одинаково хорошо работает как с systemd, так и с SysV init. Отметим, что прямое обращение к скрипту в любом случае не вполне корректно, так как запущенная служба унаследует часть контекста выполнения (переменные окружения, umask, ограничения по ресурсам, идентификаторы аудита, и т.д.) от пользовательской оболочки, из которой был запущен скрипт. Вызов скрипта через /sbin/service исправляет этот недостаток, пусть и частично. Кроме того, стоит заметить, что стандарт LSB предписывает обращаться к службам только через /sbin/service. (Вышеуказанное ограничение не распространяется на дистрибутивы, которые одновременно поддерживают и init-скрипты, и юнит-файлы. В таких дистрибутивах даже прямое обращение к скрипту при необходимости будет преобразовано в соответствующий запрос к systemd<sup>115</sup>.)
- Информация о зависимостях служб, прописанная в LSB-заголовке скрипта, играет существенную роль. Большинство реализаций SysV в различных дистрибутивах практически не используют эту информацию, либо используют ее очень ограниченно. Вследствие этого, информацию о зависимостях часто указывали некорректно или не полностью. В отличие от подобных реализаций, systemd интерпретирует эти заголовки корректно, и использует содержащуюся в них информацию при выполнении различных операций со службами (а не только в момент их установки, как это делают некоторые другие реализации SysV<sup>116</sup>).
- Все операции со скриптами ограничены по времени при помощи тайм-аутов. В отличие от классических SysV-систем, где зависший init-скрипт полностью останавливает загрузку, systemd ограничивает максимальную длительность работы скрипта пятью минутами.
- Службы запускаются в совершенно чистом контексте исполнения. Они уже не наследуют контекст у оболочки, из которой был вызван их скрипт. В частности, это касается специфических переменных, таких как \$HOME. Как следствие, скрипты, их использующие, не смогут работать корректно.
- Службы и их скрипты не могут читать с STDIN для них этот поток подключен к /dev/null. Следовательно, интерактивные init-скрипты не поддерживаются (в

 $<sup>^{114}</sup>$ Прим. перев.: Перевод статьи «Compatibility with SysV» с официального сайта проекта, по состоянию на 2016-06-21 15:06:36 (коммит 3b3b2).

<sup>&</sup>lt;sup>115</sup>Прим. перев.: Такое поведение задают разработчики дистрибутива, при помощи корректировки файла, содержащего стандартные функции для init-скриптов (например, /etc/rc.d/init.d/functions в Fedora или /etc/rc.status в openSUSE). Этот файл вызывается практически из всех init-скриптов в самом начале их работы.

<sup>116</sup>Прим. перев.: Например, insserv, используемый как дополнение к SysV init в Debian (а ранее и в openSUSE).

частности, игнорируется используемый в LSB-заголовках скриптов Debian флаг X-Interactive). К счастью, большинство дистрибутивов все равно не поддерживало интерактивные init-скрипты. Если вашему скрипту нужно запросить пароль для зашифрованного диска или SSL-ключа, вы можете воспользоваться для этого специальным механизмом, предоставляемым systemd (см. описание и страницу руководства).

- Дополнительные команды для init-скриптов (кроме стандартных, таких, как start, stop, status, restart, reload, try-restart, force-reload<sup>117</sup>) не поддерживаются<sup>118</sup>.
- Также не поддерживается возможность указывать после стандартных команд скрипту дополнительные параметры. Такое расширение SysV не прописано ни в каких стандартах, и реализация его поддержки была бы весьма проблематичной.
- Переопределение команды restart не поддерживается. Она реализована непосредственно в systemd как последовательное выполнение команд stop и start.
- systemd останавливает только те службы, которые выполняются. Традиционный SysV init при завершении работы системы запускает все скрипты, предписанные К\*-ссылками для текущего уровня исполнения. systemd в аналогичной ситуации действует более последовательно, и не пытается остановить те службы, которые не были запущены.
- Для уровней исполнения 0 и 6 все S\*- и К\*-ссылки игнорируются. При завершении работы системы останавливаются все работающие службы, и никаких новых SysVслужб не запускается.
- Если systemd не знает PID главного процесса службы, он не сможет отслеживать ее работу. В частности, если этот процесс «самостоятельно» (без сигнала от системного менеджера) завершит работу, systemd не будет знать о том, что служба остановилась. Поэтому настоятельно рекомендуется указывать в init-скрипте предложенный Red Hat заголовок-комментарий pidfile:, позволяющий systemd найти PID-файл вашей службы и получить из него PID главного процесса. Из-за того, что в некоторых init-скриптах запускаются дополнительные процессы, выполняющие предварительную настройку для нужд службы, в общем случае systemd не должен рассматривать завершение процесса, запущенного из init-скрипта, как завершение работы всей службы. Именно поэтому для корректного отслеживания ее статуса systemd требуется явное указание PID-файла. (Обратите внимание, что заголовок pidfile: можно указывать в init-скрипте не более одного раза.)
- Поддержка уровней исполнения (runlevels) в systemd имеет некоторые ограничения. Хотя все уровни исполнения SysV имеют соответствующие им целевые состояния (target units), далеко не все целевые состояния имеют соответствующие им уровни исполнения. Это обусловлено тем, что механизм целевых состояний отличается гораздо бо́льшей гибкостью и эффективностью, чем система уровней исполнения. Как следствие, в некоторых случаях попытка узнать текущий уровень исполнения (например, при помощи /sbin/runlevel) может вернуть просто «N» (т.е. «уровень выполнения неизвестен»), что приведет к нарушению работы скриптов, использующих явную проверку текущего уровня исполнения. Избегайте подобных проверок.

 $<sup>^{-117}</sup>$ Прим. перев.: Точный список «стандартных» команд для SysV init-скриптов зависит от используемого дистрибутива. Так уж исторически сложилось, что практически каждый дистрибутив использовал собственные стандарты интерфейсов SysV init. Это отразилось и на «заглушках», используемых для обратной совместимости. Выше приведен список команд, которые поддерживаются как в Fedora, так и в openSUSE.

 $<sup>^{11\</sup>hat{8}}$ Прим. перев.: В частности, это ограничение касается специфичных для init-скрипта /etc/init.d/iptables команд save и panic.

- /sbin/chkconfig и аналогичные программы могут выводить некорректную информацию о состоянии службы (включена/отключена). Они оперируют только init-скриптами, игнорируя штатные юнит-файлы. Кроме того, они опираются на механизм уровней выполнения, который поддерживается не полностью (см. выше).
- По умолчанию, уровни исполнения 2, 3 и 4 являются эквивалентами целевого состояния multi-user.target. Если включить службу на одном из них, то она будет включена и на остальных. Впрочем, это лишь настройка по умолчанию, и ничто не мешает вам определить их независимо. Тем не менее, мы рекомендуем отказаться от уровней исполнения в пользу более гибкого механизма целевых состояний systemd.
- Дистрибутивно-специфичные квази-уровни исполнения, используемые для организации запуска скриптов на ранних стадиях загрузки, больше не поддерживаются <sup>119</sup>. Примерами таких уровней являются S в Debian и b в openSUSE. Разумеется, это никак не затрагивает поддержку обычных уровней исполнения, которую мы намерены сохранять еще очень долго.
- В системах с SysV, изменение init-скриптов и любых других файлов, отвечающих за настройку процесса загрузки (например, /etc/fstab), обычно вступают в силу немедленно. В то же время, в системах с systemd, init-скрипты и другие конфигурационные файлы, влияющие на процесс загрузки, перечитываются только после выполнения команды systemctl daemon-reload (обратите внимание, что некоторые команды, например, systemctl enable и systemctl disable, выполняют данную операцию автоматически) это сделано специально, для обеспечения консистентности вносимых изменений, и позволяет избежать ситуации, когда считывание происходит непосредственно в момент редактирования конфигурации администратором 121.

## D Предсказуемые имена сетевых интерфейсов<sup>122</sup>

Начиная с версии 197, systemd/udev присваивает сетевым интерфейсам (Ethernet, WLAN, WWAN $^{123}$ ) стабильные, предсказуемые имена. Новая схема именования несколько отличается от классической (eth0, eth1, wlan0, ...), однако при этом лишена и многих ее недостатков.

#### D.1 Зачем?

Классическая схема именования сетевых интерфейсов, используемая ядром, предполагает последовательное присвоение интерфейсам имен eth0, eth1 и т.д., по мере опроса оборудования соответствующими драйверами (device probing). На современных системах такой опрос не обеспечивает гарантированного соблюдения одного и того же порядка поступления ответов. Вследствие этого, соответствие имен реальным интерфейсам не является чем-то фиксированным, и очень может быть, что интерфейс, который

 $<sup>^{119}\</sup>Pi_{\mbox{\footnotesize pum}}.$  перев.: Начиная с версии 196, см. коммит 3cdeb от 16 ноября 2012 г.

<sup>120</sup> Прим. перев.: Стоит отметить, что на самом деле все немного сложнее. В частности, даже в системе с systemd изменения в исполняемом коде SysV init-скриптов должны вступать в действие немедленно. В то же время, изменения в их заголовках (оформленных в виде комментариев и содержащих служебную информацию, в частности, о зависимостях между службами), а также сделанные «вручную» (командами 1n и rm) изменения символьных ссылок в /etc/rc?.d/ действительно срабатывают только после systemct1 daemon-reload. Это обусловлено тем, что симлинки и информация из заголовков используются при генерации unit-файлов на основе init-скриптов, которая осуществляется программой systemd-sysv-generator(8) в начале процесса загрузки, а также каждый раз после выполнения systemct1 daemon-reload. Аналогично и с /etc/fstab, на основе которого systemd-fstab-generator(8) генерирует набор mount-юнитов.

 $<sup>^{121}\</sup>Pi$ рим. перев.: Пример подобной проблемы рассмотрен примечании 106.

 $<sup>^{122}</sup>$ Прим. перев.: Перевод статьи «Predictable Network Interface Names» с официального сайта проекта, по состоянию на 2016-11-17 17:52:54 (коммит fe089).

 $<sup>^{123}</sup>$ Прим. перев.: WWAN (Wireless Wide Area Network) — относительно новый термин, обозначающий технологии глобальных беспроводных компьютерных сетей, такие, как GPRS, 3G, WiMAX и т.д.

сейчас называется eth0, при следующей загрузке превратится в eth1. Такая ситуация приводит к целому ряду проблем, в частности, к проблемам с безопасностью: в настройках брандмауэра интерфейсы идентифицируются как раз по именам.

Существует несколько подходов к решению этой проблемы. В течение многих лет udev поддерживал механизм постоянной привязки имен к интерфейсам на основе МАС-адресов. Такой подход имел множество недостатков, в том числе: требование доступности корневого каталога на запись (что возможно далеко не всегда); необходимость внесения изменений в образ системы после загрузки на новом оборудовании; привязка к МАС-адресам, которые далеко не всегда являются фиксированными (в частности, это касается многих встраиваемых систем и механизмов виртуализации). Тем не менее, основная проблема такого подхода состояла в том, что он использовал имена из того же адресного пространства (ethX), что и ядро. Вследствие этого, возникали ситуации «гонки» между udev и ядром, когда udev пытался присвоить интерфейсу имя, которое ядро уже выдало другому интерфейсу, что приводило к сбою операции переименования. Вследствие перечисленных недостатков, данный механизм был удален из systemd/udev<sup>124</sup>.

Другая попытка решения обсуждаемой проблемы — biosdevname, программа, формирующая имена интерфейсов на основании их физического расположении на материнской плате. Соответствующая информация запрашивается у BIOS. В чем-то такая схема похожа на ту, которую udev уже давно использует для формирования стабильных символьных ссылок на различные устройства (/dev/\*/by-path/\*), но, тем не менее, в ее основе лежат несколько иные алгоритмы (udev, формируя свои символьные ссылки, опирается на идентификационные данные, предоставленные ядром, в то время как biosdevname использует свои собственные схемы).

И наконец, многие дистрибутивы в своих сетевых скриптах поддерживают механизмы, позволяющие присваивать интерфейсам имена, выбранные пользователем (например, internet0, dmz0, ...). Если бы не необходимость явного вмешательства пользователя, это было бы замечательным решением.

Мы пришли к выводу, что наилучшим вариантом для настроек по умолчанию будет схема, являющаяся обобщением и развитием механизма biosdevname. Присвоение интерфейсам имен на основании информации об их физическом расположении имеет ряд существенных достоинств: такие имена формируются автоматически, всегда предсказуемы, а также остаются неизменными даже при добавлении и удалении оборудования, что позволяет без лишних проблем заменять сломанные сетевые устройства. Тем не менее, такие выглядят немного сложнее, чем привычные eth0 и wlan0, например: enp5s0.

#### D.2 Что именно было изменено в версии 197?

В версии 197 мы добавили в systemd/udevd встроенную поддержку нескольких различных механизмов именования сетевых интерфейсов, получив в итоге схему, похожую на biosdevname, но отличающуюся большей гибкостью и максимально приближенную к алгоритмам идентификации устройств, используемым в ядре. В частности, udev теперь штатно поддерживает следующие схемы именования сетевых интерфейсов:

- 1. Имена устройств, встроенных в материнскую плату, формируются на основании информации от прошивки<sup>125</sup>, например: eno1.
- 2. Имена устройств, подключенных в слоты PCI Express, формируются также на основании информации от прошивки, например: ens1.
- 3. Имена устройств формируются исходя из физического расположении точки подключения оборудования, например, enp2s0.
- 4. Имена устройств формируются на основе их MAC-адресов, например, enx78e7d1ea46da.

 $<sup>^{124}</sup>$ Прим. перев.: См. коммит  $^{3}$ е $^{214}$  от  $^{3}$  апреля  $^{2012}$  года, в котором, среди прочего, был удален каталог src/udev/src/rule\_generator.

<sup>125</sup>Прим. перев.: BIOS, (U)EFI, SPARC Boot PROM, ....

5. Используются классические, непредсказуемые имена, присвоенные ядром, например, eth0.

По умолчанию, systemd 197 при именовании сетевых интерфейсов последовательно пытается применить схемы 1–3 (для первых двух требуется информация от прошивки). Если ни одна из них не подходит, используется схема 5. Что касается схемы 4 — она не задействована по умолчанию, однако ее можно включить вручную.

Вышеописанная комбинированная схема используется лишь *в последнюю очередъ*. Если у вас установлена программа biosdevname, для именования сетевых устройств будет использоваться именно она. Кроме того, приоритет предоставляется любым правилам, добавленным пользователем или разработчиками дистрибутива.

#### D.3 Еще раз, что здесь хорошего?

Достоинства нашей новой схемы:

- Имена интерфейсов остаются неизменными после перезагрузок.
- Имена интерфейсов остаются неизменными при добавлении или удалении устройств (если ваша прошивка это позволяет).
- Имена интерфейсов остаются неизменными при обновлении/изменении ядра и драйверов<sup>126</sup>.
- Имена интерфейсов остаются неизменными при замене сломанных сетевых карт новыми
- Имена формируются автоматически, безо всякого вмешательства пользователя.
- Имена являются предсказуемыми: достаточно просто взглянуть на вывод lspci, чтобы узнать, как будет называться конкретное устройство.
- Изменения в аппаратной конфигурации не приводят к необходимости записи в каталог /etc.
- Полная поддержка систем, корень которых доступен только для чтения.
- Логика именования аналогична той, которая используется udev для формирования стабильных символьных ссылок в каталоге /dev (by-path).
- Работает как на х86, так и на других архитектурах.
- Работает одинаково во всех дистрибутивах, использующих systemd/udev.
- От этой схемы очень легко отказаться (см. ниже).

Есть ли у нее недостатки? Да. Раньше, если на компьютере имелся всего один сетевой интерфейс, можно было с высокой долей вероятности утверждать, что он называется eth0. Теперь же, прежде чем администратор начнет настраивать сеть, он должен как минимум просмотреть список сетевых интерфейсов.

#### D.4 Мне не нравится ваша схема. Как ее отключить?

У вас есть три варианта:

1. Вы можете полностью отключить новую схему, вернувшись к классическим непредсказуемым именам. Для этого достаточно заблокировать (замаскировать) link-файл udev, отвечающий за именование интерфейсов

 $<sup>^{126}</sup>$ Прим. перев.: На самом деле, не все так просто. Если, в результате обновлении ядра/драйверов, в них появится ранее отсутствовавшая поддержка вашей прошивки, не исключена вероятность, что имена некоторых интерфейсов перейдут с третьей схемы на первую или вторую. Будьте готовы к такому развитию событий.

```
ln -s /dev/null /etc/systemd/network/99-default.link
```

- 2. Вы можете вручную назначить интерфейсам наиболее понятные для вас имена (например, internet0, dmz0, lan0). Для этого создайте соответствующие link-файлы в каталоге /etc/systemd/network и укажите в них нужные вам имена (или схемы именования) для одного, нескольких или сразу всех интерфейсов 127. За подробностями вы можете обратиться к странице руководства systemd.link(5).
- 3. Вы можете указать параметр net.ifnames=0 в строке параметров ядра (отключает использование предсказуемых имен для текущей загрузки).

#### D.5 Как именно работает новая схема?

Подробности технической реализации описаны в блоке комментариев в исходном коде  $net_id$  built-in. Ознакомьтесь с ним, если у вас возникают вопросы, касающиеся расшифровки новых имен $^{128}$ .

Предсказуемые имена сетевых интерфейсов формируются на основании:

- индексов встроенных в материнскую плату устройств (по информации от прошивки)
- индексов hotplug-слотов PCI-E (по информации от прошивки)
- физического расположения точки подключения оборудования
- МАС-адресов

ww -- WWAN

http://www.freedesktop.org/wiki/Software/systemd/PredictableNetworkInterfaceNames

Первые два символа в имени определяют тип интерфейса:
en -- ethernet
sl -- SLIP (IP через последовательный порт)
wl -- WLAN

Последующие символы определяеются используемой схемой:

b<number> -- для устройств, подключенных по шине BCMA (<number> соответствует BCMA bus core number)

c<br/>c<br/>bus\_id> -- для устройств, адресуемых через Channel Command Words (CCW).<br/>
<br/>
<br/>
cootbetctbyet CCW bus-ID для простого (использующего один субканал) или группированного (использующего несколько субканалов) устройства, указывается без ведущих нулей [s390]

o<index>[n<phys\_port\_name>|d<dev\_port>] -- для устройств, встроенных в материнскую плату

s<slot>[f<function>] [n<phys\_port\_name>|d<dev\_port>] -- для hotplug-слотов x<MAC> -- при именовании по MAC-адресу

-- на основании физического расположения PCI-устройства

[P<domain>]p<bus>s<slot>[f<function>][u<port>][..][c<config>][i<interface>]

-- идентификационная цепочка для USB-устройств

v<slot> -- номер слота для VIO-устройств (IBM PowerVM)

a<vendor><model>i<instance> -- идентификатор ACPI для устройств, подключенных через шину платформы (ARM64)

Все многофункциональные (multi-function) PCI-устройства содержат в своем имени номер функции "f<function>" (отсчитываются от нуля).

<sup>127</sup> Прим. перев.: Там же можно изменить используемую по умолчанию схему именования, скопировав файл/usr/lib/systemd/network/99-default.link и поменяв значение параметра NamePolicy= на нужное значение.

 $<sup>^{128}</sup>$ Прим. перев.: Далее приводится перевод упомянутого блока комментариев. Последним коммитом, затронувшим данный файл, на момент перевода является 86a48 от 18 мая 2017 г.

При именовании по расположению устройства, индекс PCI-домена "P<domain>" указывается только в том случае, если он отличен от нулевого.

Для USB-устройства формируется полная цепочка номеров портов хабов, через которые оно подключено. Если итоговая строка будет длиннее 15 символов, она не экспортируется.

Стандартные значения config == 1 и interface == 0 опускаются.

#### Примеры:

Подключенная к PCI сетевая карта, которая идентифицируется прошивкой по индексу "1":

ID\_NET\_NAME\_ONBOARD=eno1

ID\_NET\_NAME\_ONBOARD\_LABEL=Ethernet Port 1

Сетевая карта, включенная в hotplug PCI-слот, который идентифицируется прошивкой:

/sys/devices/pci0000:00/0000:00:1c.3/0000:05:00.0/net/ens1

ID\_NET\_NAME\_MAC=enx000000000466

ID\_NET\_NAME\_PATH=enp5s0

ID\_NET\_NAME\_SLOT=ens1

Multi-function PCI устройство с двумя портами:

/sys/devices/pci0000:00/0000:00:1c.0/0000:02:00.0/net/enp2s0f0

ID\_NET\_NAME\_MAC=enx78e7d1ea46da

ID\_NET\_NAME\_PATH=enp2s0f0

/sys/devices/pci0000:00/0000:00:1c.0/0000:02:00.1/net/enp2s0f1

ID\_NET\_NAME\_MAC=enx78e7d1ea46dc

ID\_NET\_NAME\_PATH=enp2s0f1

#### Подключенная к PCI WLAN-карта:

/sys/devices/pci0000:00/0000:00:1c.1/0000:03:00.0/net/wlp3s0

ID\_NET\_NAME\_MAC=wlx0024d7e31130

ID\_NET\_NAME\_PATH=wlp3s0

#### Встроенный USB 3G модем:

/sys/devices/pci0000:00/0000:00:1d.0/usb2/2-1/2-1.4/2-1.4:1.6/net/wwp0s29u1u4i6

ID\_NET\_NAME\_MAC=wwx028037ec0200

ID\_NET\_NAME\_PATH=wwp0s29u1u4i6

#### Подключенный по USB Android-смартфон:

/sys/devices/pci0000:00/0000:00:1d.0/usb2/2-1/2-1.2/2-1.2:1.0/net/enp0s29u1u2

ID\_NET\_NAME\_MAC=enxd626b3450fb5

ID\_NET\_NAME\_PATH=enp0s29u1u2

#### Группированный ССW-интерфейс на s390:

/sys/devices/css0/0.0.0007/0.0.f5f0/group\_device/net/encf5f0

ID\_NET\_NAME\_MAC=enx026d3c00000a

ID\_NET\_NAME\_PATH=encf5f0

## Е Специальные файловые системы<sup>129</sup>

Итак, вы запустили программу mount(8), и увидели в ее выводе множество странных файловых систем, не указанных в /etc/fstab. У вас могут возникнуть вопросы: «Как от них избавиться?» или «Как задать для них параметры монтирования?».

В Linux предусмотрено несколько способов взаимодействия программ из пространства пользователя с ядром. Наиболее популярными механизмами являются системные вызовы (syscall), интерфейсы Netlink, а также виртуальные файловые системы (ФС), такие, как /proc и /sys. Подобные ФС являются лишь программными интерфейсами, и не обеспечивают долговременного хранения данных (в частности, между перезагрузками системы). Они просто используют классические механизмы работы с файлами для предоставления доступа к различным данным и настройкам. Кроме того, существуют специальные ФС, используемые программами для собственных нужд, в частности, для хранения сегментов разделяемой памяти (shared memory), временных файловых систем. Ниже представлен список таких ФС, поддерживаемых в типовых Linux-системах:

- /sys предоставляет доступ к драйверам и устройствам, а также некоторым другим параметрам ядра;
- /proc дает доступ к информации о выполняемых процессах, настройкам ядра, а также другим параметрам;
- /dev отображает файлы устройств (device nodes);
- /run содержит файлы и сокеты, используемые программами;
- /tmp хранит временные и часто изменяемые объекты (X);
- /sys/fs/cgroup (и другие файловые системы, смонтированные в подкаталогах этого каталога) позволяют работать с иерархией контрольных групп;
- /sys/kernel/security, /sys/kernel/debug (X), /sys/kernel/config (X) предоставляют доступ к специализированным механизмам ядра;
- /sys/fs/selinux используется для взаимодействия с SELinux;
- /dev/shm содержит объекты разделяемой памяти;
- /dev/pts обеспечивает доступ к псевдо-TTY устройствам;
- /proc/sys/fs/binfmt\_misc используется для регистрации в ядре дополнительных бинарных форматов (X);
- /dev/mqueue содержит объекты IPC-механизма mqueue (X);
- /dev/hugepages позволяет программам запрашивать выделение «гигантских» страниц памяти (X);
- /sys/fs/fuse/connections обеспечивает доступ к FUSE-соединениям (X);
- /sys/firmware/efi/efivars предоставляет доступ к переменным EFI;

systemd монтирует все эти файловые системы на ранних стадиях загрузки, даже если они не указаны явно в /etc/fstab. В зависимости от настроек вашего ядра, некоторые из перечисленных выше ФС могут быть недоступны, и наоборот, могут присутствовать другие специальные ФС, не приведенные в этом списке. Все эти механизмы играют важную роль во взаимодействии ядра с программами и программ между собой. Именно поэтому они подключаются автоматически, безо всякого участия пользователя. Необдуманное вмешательство в их работу (отключение или изменение параметров) может

<sup>129</sup>Прим. перев.: Перевод статьи «API File Systems» с официального сайта проекта, по состоянию на 2015-02-20 15:48:02 (коммит e2db9).

нарушить нормальную работу ваших программ, так как они утратят доступ к необходимым для них интерфейсам.

В абсолютном большинстве случаев достаточно настроек, используемых по умолчанию. Однако, могут возникнуть ситуации, когда необходимо изменить параметры монтирования специальных ФС, либо полностью отключить монтирование некоторых из них.

Несмотря на то, что эти  $\Phi$ С по умолчанию отсутствуют в /etc/fstab, ничто не мешает вам их туда добавить. Параметры монтирования, которые вы при этом укажете, будут автоматически применяться к соответствующим  $\Phi$ С. Проще говоря: если вам нужно изменить параметры монтирования для специальных  $\Phi$ С, просто добавьте их в /etc/fstab с указанием соответствующих опций. Кроме параметров монтирования, так можно изменить и сам тип файловой системы (в частности, перенести /tmp из tmpfs на раздел физического диска).

Также вы можете полностью отключить монтирование некоторых (но не всех) специальных систем, если это действительно необходимо. Отключаемые  $\Phi C$  в списке выше отмечены (X). Для их отключения, достаточно заблокировать (замаскировать) соответствующий юнит:

#### systemctl mask dev-hugepages.mount

В результате выполнения такой операции, соответствующая  $\Phi C$  больше не будет монтироваться по умолчанию, начиная со следующей загрузки системы. О том, что такое блокировка юнита, вы можете прочитать в главе 5.

На всякий случай отметим, что применение к специальным ΦС параметров монтирования, указанных в /etc/fstab, обеспечивается службой systemd-remount-fs.service.

## Зачем вы мне все это рассказываете? Я просто хочу убрать tmpfs из /tmp!

У вас есть три варианта:

1. Вы можете отключить любое монтирование в /tmp, в результате чего содержимое данного каталога будет храниться на том же разделе, что и корень. Для этого достаточно выполнить команду

systemctl mask tmp.mount

- 2. Вы можете смонтировать в /tmp обычную файловую систему, размещенную на диске. Для этого достаточно создать соответствующую запись в /etc/fstab.
- 3. Если вы хотите оставить в /tmp tmpfs, но при этом задать для нее другой размер это тоже делается через внесение в /etc/fstab соответствующей записи, предписывающей монтирование tmpfs в /tmp с нужным вам значением параметра size=.

## F Запуск служб после появления сети<sup>130</sup>

Итак, ваша служба настроена на запуск только после достижения цели network.target, однако, несмотря на это, она все равно запускается до появления сети. У вас возникают вопросы: «Почему так происходит?» и «Как это исправить?».

В некоторых LSB-совместимых скриптах инициализации, при описания зависимостей используется сущность (facility) \$network. Определение этой сущности в стандарте довольно расплывчато и оставляет широкий простор для различных трактовок. Вот примеры некоторых из них:

 Запущен демон управления сетью (например, NetworkManager или systemdnetworkd).

- Все заданные в настройках сетевые интерфейсы переведены в состояние UP и получили IP-адреса.
- Все имеющиеся физические сетевые интерфейсы, на которых зарегистрирована несущая (link beat), получили IP-адреса. Наличие или отсутствие явных настроек роли не играет.
- Доступен DNS-сервер.
- Доступна некоторая выбранная сетевая служба.
- Доступен некий абстрактный «интернет».
- Все заданные в настройках ethernet-интерфейсы переведены в состояние UP, однако процесс настройки PPP-интерфейсов еще не начался.
- Активирован некий профиль сетевых настроек, задающий одно из условий выше. В разных профилях могут использоваться разные условия.
- Выполняется некоторый набор условий (выбор условий определяется физическим расположением системы).
- Настроен как минимум один глобальный адрес IPv4.
- Настроен как минимум один глобальный адрес IPv6.
- Настроен как минимум один глобальный адрес IPv4 или IPv6.

Этот список можно продолжать и дальше. Каждый предложенный в нем вариант можно использовать в качестве критерия появления сети, однако ни один из них не подходит в качестве варианта по умолчанию, пригодного для абсолютного большинства задач.

Современные компьютерные сети живут в очень динамичном ритме: компьютеры перемещаются между сетями, сетевые настройки меняются, устройства подключаются и отключаются, виртуальные сети настраиваются, перенастраиваются и выключаются. Наличие сетевого соединения не является чем-то постоянным и безусловным. В разные моменты времени компьютер может быть подключен к разным сетям. И это справедливо не только для мобильных устройств (смартфонов, планшетов и ноутбуков), но и, в определенной мере, для встраиваемых и серверных систем. Программы, которые считают, что сеть является чем-то неизменным и непрерывно доступным, не могут нормально функционировать в таких условиях. Хорошо написанная программа должна корректно реагировать на изменение состояния сети, и не унывать в беде. Если нужный ей сервер не доступен в настоящий момент, она должна не зависать по тайм-ауту, а пытаться достучаться к нему снова и снова. Если сетевое соединение утрачено, она должна отреагировать на это. Реализовать такое реагирование в коде демона, на самом деле, не так уж и сложно. Существует множество хорошо известных сетевых служб, которые уже давно поддерживают такую возможность. Подобные службы можно запускать в любой момент, они устойчивы к сбоям, и работают корректно во всех возможных ситуациях.

\$network предназначена для поддержки программ, созданных в предположении, что сеть доступна постоянно (т.е. написанных не очень аккуратно). Конкретные требования таких программ могут сильно отличаться. Например, IMAP-серверу будет достаточно наличия IP-адреса, на котором можно слушать. В то время как для клиентов сетевых файловых систем требуется требуется доступность и работоспособность сервера, а также, опционально, наличие работоспособного DNS. Таким образом, конкретные требования к \$network сильно зависят от решаемой задачи.

По соображениям надежности, загрузка системы не должна зависеть от второстепенных служб. В частности, отсутствие ответа от DHCP-сервера не должно завешивать процесс загрузки системы (за исключением ситуаций, когда сетевое соединение действительно необходимо для работы системы, например, при загрузке по сети).

#### F.1 Как это реализовано в systemd

B systemd существует сразу три юнита (целевых состояния, target units), в совокупности берущих на себя роль LSB-сущности \$network 131:

- network.target не играет существенной роли в процессе загрузки системы. Активация данного целевого состояния лишь показывает, что программа управления сетью была запущена. А вот будет ли к этому моменту настроена сеть не регламентируется. Основное назначение данного юнита синхронизация операций при остановке системы. Так как порядок остановки юнитов обратен порядку их запуска, все юниты, в описании которых указано After=network.target, при выключении системы будут остановлены до того, как отключится сеть. Это позволит программам корректно закрывать все сетевые соединения, а не оставлять их «повисшими». Обратите внимание, что network.target является пассивным юнитом: вы не можете запустить его ни вручную (через systemctl start), ни через зависимости своих служб (Wants и Requires). Активацией и деактивацией данного юнита занимается программа, управляющая сетью в вашей системе. В юнит-файлах служб, использующих сеть, целесообразно указывать After=network.target, но ни в коем случае не Wants=network.target, и уж тем более не Requires=network.target<sup>132</sup>.
- network-online.target активируется только после появления сети. Трактовка понятия «появилась сеть» остается на совести разработчиков программы, управляющей сетью<sup>133</sup>. Обычно оно подразумевает, что одному или нескольким сетевым интерфейсам присвоены маршрутизируемые ІР-адреса. Основная задача обсуждаемого юнита — обеспечить задержку запуска отдельных служб до того момента, как появится сеть. Данный юнит является активным, т.е. его можно указывать в зависимостях служб, которым необходима запущенная сеть (и, в то же время, нельзя указывать в зависимостях у самой службы управления сетью). По умолчанию, этот юнит автоматически прописывается в зависимости к точкам монтирования всех удаленных файловых систем (например, NFS, SMBFS/CIFS), приведенным в файле /etc/fstab. Таким образом, монтирование этих файловых систем начнется только после того, как появится сеть. Однако, если таких точек монтирования не указано, а также отсутствуют службы, явно требующие по зависимостям данный юнит, он вообще не активируется в процессе загрузки системы, что позволяет избежать нежелательных задержек в случае проблем с сетью. Настоятельно рекомендуется не злоупотреблять зависимостями от этого юнита. В частности, для серверных приложений, как правило, такая зависимость избыточна (обычно, сервер может работать даже в отсутствие внешней сети, обслуживая локальные соединения). Основная задача обсуждаемого юнита — своевременный запуск клиентских программ, которые не могут работать без сети.

<sup>&</sup>lt;sup>131</sup>Прим. перев.: Приведенные здесь сведения применимы только к systemd версий 213 и выше, в которых появился юнит network-online.target. О том, как сущность \$network работала в предыдущих версиях systemd, желающие могут прочитать в примечании 135.

<sup>&</sup>lt;sup>132</sup>Прим. перев.: Концепция активных и пассивных юнитов более подробно пояснена на странице руководства systemd.special (7). Она описывает взаимосвязь двух классов служб: потребители (consumers) и поставщики (providers). Например, служба управления сетью является поставщиком (сети), а демон торрент-клиента — потребителем. Синхронизация между ними может осуществляться посредством как пассивных, так и активных целевых состояний. Разница между активными и пассивными целевыми юнитами состоит в том, что для активных целей Requires/Wants зависимости прописываются в юнитфайле службы-потребителя, а для пассивных — в юнитфайле службы-поставщика. Никакой магии здесь нет — это просто соглашение между авторами юнит-файлов. В рамках этого же принципа, в конфигурационные файлы пассивных юнитов добавляется директива RefuseManualStart=yes, запрещающая их активацию «вручную».

<sup>133</sup>Прим. перев.: Определением момента готовности сети обычно занимается отдельная утилита. В NetworkManager это nm-online, в systemd-networkd — systemd-networkd-wait-online(8). В случае NM, сеть считается готовой после появления на любом из управляемых им устройств корректного IP-адреса (глобального или локального), в случае networkd — после того, как для всех интерфейсов, прописанных в его конфигурации, завершится процесс настройки (успешно или с ошибкой), причем как минимум для одного интерфейса настройка должна завершиться успешно.

• network-pre.target<sup>134</sup> активируется до того, как начнется настройка сетевых интерфейсов. Основная функция этого юнита — своевременный запуск служб, выполняющих настройку брандмауэра. Таким образом, к моменту появления сети брандмауэр будет уже готов к отражению возможных атак. Указанный юнит является пассивным — вы не можете запустить его вручную, и его нельзя указывать в качестве Requires/Wants-зависимости в юнит-файлах службы управления сетью. Напротив, такие зависимости должны прописываться у тех служб, которые должны быть запущены до появления сети. В юнит-файле службы управления сетью целесообразно указать After=network-pre.target, но не Wants=network-pre.target/Requires=network-pre.target.  ${
m B}$  то же время, в юнит-файлах служб, которые должны быть запущены до появления сети (например, уже обсуждавшиеся выше службы брандмауэра), наоборот, рекомендуется указывать Before=network-pre.target и Wants=network-pre.target. Таким образом, данное целевое состояние будет активироваться в нужный момент только в том случае, если у какой-либо из ваших служб действительно имеется такая зависимость. Если же подобных служб нет, network-pre.target не будет активироваться вообще.

Когда systemd встречает в LSB-заголовках init-скриптов зависимость network, он преобразовывает ее в зависимости mats=network-online.target и After=network-online.target, что позволяет обеспечить поведение, более или менее соответствующее требованиям  $LSB^{135}$ .

За дальнейшими подробностями вы можете обратиться к странице руководства systemd.special(7).

#### F.2 Короче, как заставить network.target работать?

Это зависит от конфигурации вашей системы и конкретных требований ваших служб (см. выше). Многие службы управления сетью предоставляют возможность принудительной активации network-online.target, в результате чего network.target по своему эффекту становится практически эквивалентной network-online.target.

Eсли вы используете NetworkManager, вы можете задействовать специальную службу NetworkManager-wait-online.service:

#### systemctl enable NetworkManager-wait-online.service

Если же вы используете systemd-networkd, соответствующая служба будет называться systemd-networkd-wait-online.service:

#### systemctl enable systemd-networkd-wait-online.service

Включение такой службы позволит гарантировать, что загрузка продолжится только после того, как все заданные в настройках сетевые интерфейсы будут переведены в состояние UP и получат IP-адреса. Максимальное время ожидания — 90 секунд<sup>136</sup>.

<sup>134</sup> Прим. перев.: Поддержка данного юнита добавлена в systemd-networkd начиная с systemd 214. Тогда же в официальной документации появились первые упоминания о нем. Однако, ничто не мешает использовать этот юнит и в более ранних версиях systemd — достаточно скопировать соответствующий конфигурационный файл в каталог /etc/systemd/system.

<sup>135</sup> Прим. перев.: Трансляция LSB-сущности \$network в network-online.target введена в systemd начиная с systemd 213. В systemd версий до 212 включительно, \$network транслировалась в network.target. Что приводило к довольно неожиданным эффектам — как уже упоминалось выше, активация network.target вовсе не означает, что сеть уже настроена. В связи с этим, официальная документация рекомендовала привязывать network.target к моменту запуска сети, например, через NetworkManager-wait-online.service. Соответствующие команды приведены чуть ниже по тексту. Они действуют даже в новых версиях systemd, но особого смысла уже не несут — задача синхронизации решается юнитом network-online.target, который в случае необходимости активируется автоматически (реализовано в юнит-файлах systemd-networkd 213 и выше, NetworkManager 0.9.9.95 и выше).

<sup>136</sup>Прим. перев.: У NetworkManager в апстримной конфигурации по умолчанию сейчас используется значение 30 секунд. См. параметр --timeout программы nm-online в файле настроек службы /usr/lib/system/system/NetworkManager-wait-online.service. У systemd-networkd время ожидания ограничивается тайм-аутом systemd для запуска служб, по умолчанию 90 секунд.

Обратите внимание, что включение подобных служб может сильно замедлить загрузку. Обе эти службы по умолчанию отключены $^{137}$ .

Как альтернативный вариант, вы можете поменять непосредственно юнит-файл той службы, которая нуждается в сети, добавив туда опции After=network-online.target и  $Wants=network-online.target^{138}$ .

#### **F.3** А что делать нам, разработчикам?

Если вы — не администратор, а разработчик сетевой службы, то вам стоит задуматься не о том, что делать с network.target, а о том, как можно исправить вашу службу, чтобы она нормально реагировала на изменение состояния сети. Это позволит порадовать ваших пользователей (когда программа работает без дополнительной возни — это не может не радовать), а также уменьшит количество сообщений об ошибках (так как ваша программа уже не будет паниковать по пустякам). Кроме того, системы ваших пользователей будут грузиться быстрее, потому что их уже не будет задерживать необходимость ожидать появления сети (в случае с медленным DHCP-сервером, прогресс может быть весьма ощутимым).

Можно предложить несколько подходов к решению этой задачи:

- Отслеживайте изменений конфигурации сети при помощи rtnetlink и реагируйте соответствующим образом. Это наиболее правильный, но далеко не всегда самый простой способ.
- Если вы разрабатываете серверное приложение: слушайте только адреса [::], [::1], 0.0.0.0 и 127.0.0.1. Все эти псевдо-адреса должны быть доступны постоянно. Если ваша программа будет слушать только их, ей будут глубоко безразличны изменения конфигурации сети.
- Если вы разрабатываете серверное приложение и вам нужно слушать некий заданный адрес: воспользуйтесь опцией IP\_FREEBIND, доступной на Linux-системах. Она позволит вашей программе слушать даже те адреса, которые не присвоены локальным сетевым интерфейсам (в данный момент или вообще), что также сделает ваш код устойчивым к изменению сетевой конфигурации.

# G Моя служба не может получить приоритет realtime<sup>139</sup>

Итак, у вас есть служба, которая требует приоритет реального времени (realtime). Однако, когда вы пытаетесь запустить ее на системе, работающей под управлением systemd, ваша служба не может получить этот приоритет, хотя обладает всеми необходимыми для этого привилегиями. Вы хотите понять, почему так происходит, и как это можно исправить.

<sup>137</sup>Прим. перев.: У внимательного читателя может возникнуть вопрос: как же определяется момент активации network-online.target, если юниты, отвечающие за ожидание сети, отключены? На самом деле все довольно просто: при установке NetworkManager/systemd-networkd соответствующие \*-wait-online-юниты прописываются в зависимости к network-online.target при помощи симлинков в /etc/systemd/system/network-online.target.wants. В результате, когда какая-нибудь служба укажет зависимость от network-online.target, будет автоматически активирована и соответствующая служба \*-wait-online. Если таких служб нет, то и активации не произойдет. Однако, если вы принудительно включите службу \*-wait-online при помощи приведенных выше команд, она будет прописана в зависимости уже к multi-user.target, а значит, будет активироваться при каждой загрузке.

<sup>&</sup>lt;sup>138</sup>Прим. перев.: Собственно, этот путь и является единственно разумным в большинстве случаев. Привязка network.target к network-online.target, описанная выше, фактически, является пережитком проблем старых версий systemd (212 и ниже), когда, по воле его разработчиков, LSB-сущность \$network транслировалась в network.target.

 $<sup>^{139}</sup>$ Прим. перев.: Перевод статьи «My Service Can't Get Realtime!» с официального сайта проекта, по состоянию на 2013-05-18 08:20:36 (коммит 2f77b).

#### В чем же дело?

По умолчанию, systemd помещает каждую системную службу в свою контрольную группу в иерархии контроллера сри. Такое поведение дает очень полезный эффект: службы с множеством рабочих потоков (например, Арасhe с сотнями ССІ-процессов), получают примерно такую же долю процессорного времени, как и службы с небольшим количеством рабочих потоков (например, MySQL). Проще говоря, процессорное время распределяется уже не между процессами, а между службами.

К сожалению, в настоящее время реализация сри-контроллера в Linux имеет один существенный недостаток: она требует явного задания realtime-бюджета времени (RT budget) для своих контрольных групп. Если же бюджет группы не задан, то ее процессы не смогут получить приоритет реального времени (соответствующая операция будет завершаться с ошибкой ЕРЕВМ — «недостаточно полномочий»). systemd не может присваивать такой бюджет каждой группе, просто потому, что не знает, как его правильно делить между ними. Бюджет выдается в абсолютных единицах времени, и их общее количество ограничено. Мы не можем предложить механизм распределения бюджета, который бы подходил по умолчанию для большинства случаев. Поэтому, в конфигурации по умолчанию, приоритет реального времени недоступен для системных служб.

#### Как это исправить?

Обойти это ограничение несложно. Существует несколько различных путей:

- Можно просто отключить использование сри-контроллера по умолчанию для системных служб. Для этого, задайте в файле /etc/systemd/system.conf параметр DefaultControllers= равным пустой строке, после чего перезагрузите систему. (Либо вы можете отключить контроллер сри на этапе сборки ядра. systemd не пытается использовать контроллеры, которые не поддерживаются ядром.)
- Также вы можете отключить группировку по сри только для конкретных служб. Для этого отредактируйте конфигурацию службы, добавив параметр

#### ControlGroup=cpu:/

в секцию [Service]. В результате, процессы данной службы будут помещены не в собственную контрольную группу (как это делалось по умолчанию), а в корневую контрольную группу иерархии сри. Процессы из корневой группы располагают полным realtime-бюджетом.

• И наконец, вы можете явно выделить своей службе некоторый бюджет. Для этого добавьте в секцию [Service] строку наподобие

ControlGroupAttribute=cpu.rt\_runtime\_us 500000

Подробнее о правильном распределении бюджета читайте в документации к ядру.

Последние две опции неприменимы к SysV-службам. Тем не менее, вы можете подготовить для таких служб соответствующие service-файлы, которые, помимо упомянутых выше параметров, содержат вызов соответствующего init-скрипта с аргументом start в ExecStart=, и с аргументом stop — в ExecStop=. (Также имеет смысл задать для них параметры RemainAfterExit=1 и Type=forking.)

Отметим, что все вышесказанное касается только системных служб, и не затрагивает пользовательские сеансы. По умолчанию, программы пользователя размещаются в корневой группе контроллера сри, и поэтому вышеописанные ограничения их не касаются.

Мы надеемся, что в будущем ядро будет исправлено таким образом, чтобы не требовать явного задания realtime-бюджета для получения приоритета реального времени (а при получении такого приоритета, бюджет процесса должен автоматически выделяться

из бюджета ближайшей родительской группы). В идеале, мы хотели бы распространить практику выделения сри-групп не только на системные службы, но и на пользовательские сеансы, чтобы уравнять пользователей в правах на процессорное время, вне зависимости от того, сколько процессов запускает каждый конкретный пользователь.